“ ”

| | | |
|---|---|---|
| 学　　校 | 南京财经大学 | |
| 参赛队号 | 26103270035 | |
| 队员姓名 | 1. | 王晗硕 |
| | 2. | 赵创新 |
| | 3. | 蒲泽杰 |

“ ”

**题　目：** 算力约束下大语言模型的数据质量与资源配置建模

## 摘　要：

围绕数据质量、领域配比和算力投入如何影响大语言模型的损失与能力，本文依次建立质量评价、广义标度律、资源优化和能力前沿模型，区分实测、半合成检验与条件外推。

针对问题一，本文将 22 项质量指标统一方向，经熵权–CRITIC 赋权和四维有限补偿聚合得到质量分。严格互斥尾部使 231 个指标对中 228 对可识别，其中 80 对为强冲突候选。七域质量均值以 arxiv 的 0.7953 最高、github 的 0.5171 最低。结构化曲率模型（SCM）与稳定稀疏交互模型（SCI）刻画配比效应。**SCI 在 1M 固定检验集上的排序相关为 0.9770**。据此在训练配比凸包内给出安全与风险候选。

针对问题二，建立融合规模、质量和配比的广义标度律（SAED）。B1 识别规模指数 $\alpha = 0.3400$, $\beta = 0.2799$。B6 识别质量系数 $\kappa = 0.4597$，**B7 新质量水平的半合成外层检验均方根误差为 0.04671**。256 个同配方样本在 1M 与 60M 尺度的损失排序 Spearman 相关为 0.9658。后续以无衰减作为名义情景，将尚未识别的配比幅度尺度指数 $\gamma_p$ 列为敏感性维度。

针对问题三，构建计入基础训练、长上下文注意力和追加质量治理的算力约束优化模型。三类质量成本与三档预算形成九个名义情景。各情景比较三个配比，$p_{\text{safe}}$ 均为候选集内最优。指数型成本下，预算从 $10^{19}$ 增至 $10^{24}$ FLOPs 时，**预测损失由 3.02336 降至 1.88628**，质量治理预算份额由 25.60% 降至 1.33%。以 21 个预设情景检验有限候选决策稳定性。

针对问题四，以训练算力为规模变量构建动态能力前沿，用 Shapley 方法分解训练算力扩张与非规模时间变化，并核算剩余项。经留出检验的 Loss–Benchmark 桥用于条件性跨问核对。预训练组三项变化分别为 4.65、7.31 和 6.56 分。以 C5 校准的桥在 C6 新增模型上的留出检验均方根误差为 8.97 分。截止日前的近期训练算力年倍数估计为 0.13，95% 区间为 [0.02, 8.47]。在预设“延续”情景下，**预训练组 12、24 个月能力前沿的条件中位数分别为 40.73、43.47 分**。3 个月滚动回测为预训练组和对话/微调组各提供 3 个有效折，期间前沿保持稳定。长期结果以条件情景外推形式报告。

**关键词：** 大语言模型, 数据质量, 领域配比, 广义标度律, 算力配置, 能力前沿

# 目录


**1 问题重述** . . . . . 4

1.1 研究背景 . . . . . 4
1.2 建模任务 . . . . . 4
1.2.1 问题一：数据质量与领域配比 . . . . . 4
1.2.2 问题二：跨维度数据融合与广义标度律 . . . . . 4
1.2.3 问题三：算力预算下的联合优化 . . . . . 4
1.2.4 问题四：技术演进与能力前沿 . . . . . 4

**2 问题分析** . . . . . 5

2.1 建模思路 . . . . . 5
2.1.1 问题一的分析 . . . . . 5
2.1.2 问题二的分析 . . . . . 5
2.1.3 问题三的分析 . . . . . 5
2.1.4 问题四的分析 . . . . . 5

**3 模型假设与符号说明** . . . . . 5

3.1 模型假设 . . . . . 5
3.2 主要符号 . . . . . 6

**4 问题一的建模与求解** . . . . . 6

4.1 问题分析与数据划分 . . . . . 6
4.2 质量指标预处理与综合评分 . . . . . 7
4.2.1 列表压缩、方向统一与量纲处理 . . . . . 7
4.2.2 熵权与指标对比强度赋权（CRITIC） . . . . . 7
4.3 指标冲突的识别与消解 . . . . . 8
4.3.1 指标对与样本层面的冲突定义 . . . . . 8
4.3.2 有限补偿的最终质量分 . . . . . 9
4.4 由样本质量到领域质量 . . . . . 11
4.5 17 域配比与损失的定量关系 . . . . . 11
4.5.1 目标、基线模型与结构化曲率模型 . . . . . 11
4.5.2 稳定稀疏交互增强 . . . . . 13
4.5.3 固定检验集上的模型比较 . . . . . 14
4.6 质量映射、配比推荐与外推边界 . . . . . 15
4.6.1 质量分能否改进配比预测 . . . . . 15
4.6.2 均值保持的逐域风险预测 . . . . . 17
4.6.3 训练配比支撑域内的候选推荐 . . . . . 17
4.6.4 尺度外推边界 . . . . . 18

**5 问题二的建模与求解** . . . . . 20

5.1 数据口径与建模路线 . . . . . 20
5.2 规模骨架与跨来源迁移 . . . . . 20
5.2.1 经典标度律估计 . . . . . 20
5.2.2 假设 H1：规模坐标可迁移 . . . . . 21
5.3 质量与配比的跨附件桥接 . . . . . 23
5.3.1 假设 H3：质量作用于可约损失 . . . . . 23
5.3.2 假设 H2：配比排序迁移及幅度识别边界 . . . . . 25

5.4 广义标度律及资源替代 . . . 26
5.4.1 模块化模型与识别边界 . . . 26
5.4.2 边际效用、弹性与等效资源 . . . 26
5.4.3 领域再分配与质量–参数替代 . . . 28
5.5 验证、算力前沿与外推边界 . . . 29
**6 问题三的建模与求解 . . . 31**
6.1 输入口径与有限候选配比 . . . 31
6.2 相对质量治理与资源优化 . . . 32
6.3 数值求解与体制判据 . . . 33
6.4 三档预算的名义配置 . . . 33
6.5 连续预算、状态转移与上下文响应 . . . 34
6.6 条件不确定性、遗憾与等效算力 . . . 37
**7 问题四的建模与求解 . . . 38**
7.1 能力指标、样本口径与时间轴 . . . 38
7.2 C8 逐任务重建与能力增长的异质性 . . . 40
7.3 训练算力主口径下的规模与非规模贡献 . . . 40
7.3.1 参数量诊断与等能力线 . . . 40
7.3.2 训练 FLOPs 前沿与 Shapley 分解 . . . 42
7.4 算力增长的变化点与条件情景 . . . 44
7.5 损失–能力桥接及问题三的增量接口 . . . 45
7.6 12 与 24 个月能力前沿的情景预测 . . . 46
7.7 口径敏感性与结论边界 . . . 47
**8 模型评价与适用边界 . . . 48**
8.1 模型的主要成果 . . . 48
8.2 结果的适用范围 . . . 49
8.3 推广方向 . . . 49
**参考文献 . . . 49**
**附录 A 图表目录 . . . 52**
**附录 B 数据角色与补充结果 . . . 55**
B.1 训练、检验与情景数据的分工 . . . 55
B.2 22 项质量指标的方向与权重 . . . 55
B.3 质量域到配方域的映射 . . . 56
B.4 标度律参数与识别状态 . . . 56
**附录 C 计算顺序与结果复核 . . . 58**
C.1 AI 工具使用说明 . . . 58
**附录 D 关键计算代码 . . . 58**
D.1 问题一：指标赋权与质量冲突消解 . . . 58
D.2 问题二：经典标度律与质量乘子 . . . 58
D.3 问题三：广义损失与稳健决策 . . . 59
D.4 问题四：损失–能力桥接与月度前沿 . . . 59

# 1 问题重述

## 1.1 研究背景

大语言模型的验证集交叉熵损失受模型参数量 $N$、训练数据量 $D$ 及数据组成影响，模型能力可由多个下游任务评测得分衡量。高质量语料趋于稀缺，单纯扩大模型或数据规模会受到数据供给与算力预算制约。提升数据质量 $Q$、调整训练领域配比 $\boldsymbol{p}$ 和增加上下文长度也会改变训练效果。其中，质量提升与长文本处理需要额外算力。因此，需要在统一的数据与算力口径下，刻画各因素对损失和能力的作用，并据此研究有限预算中的资源配置。

题目给出了质量信号与配方实验数据（附件 A）、模型规模与训练轨迹数据（附件 B），以及能力评测和上下文信息（附件 C）。前三问以验证集交叉熵损失为主要观测量，第四问以多维评测得分刻画能力，并要求建立损失与评测结果的联系。四问在统一分析框架下依次涉及质量与配比评价、广义标度律、算力约束优化以及技术演进预测，形成完整模型链。

## 1.2 建模任务

### 1.2.1 问题一：数据质量与领域配比

对 A1 抽样集及 A2、A3 扩展集的全部质量信号进行预处理，将方向不同、部分为列表形式的 22 项指标统一为“越高越好”，建立样本级质量评分，并说明向语料或领域聚合的方法。对同一文本上相互矛盾的指标评价定义冲突、分析原因、建立消解规则，用原始文本和扩展集检验评分及冲突结论。利用 A4–A15 建立 17 个训练领域的配比 $\boldsymbol{p}$ 与交叉熵损失的定量关系，解释单域及领域组合的影响。在 A6–A11 上检验，并用 A12–A15 讨论外推稳健性。质量域与配方域不完全对应，若将 $Q$ 引入配比模型，须说明跨域映射及依据。

### 1.2.2 问题二：跨维度数据融合与广义标度律

经典标度律描述损失随 $N$、$D$ 的变化，题目要求纳入问题一得到的 $Q$ 与 $\boldsymbol{p}$，形成可估计、可检验的广义关系。附件 A 与 B 的实验独立，需提出连接两类数据规律的假设。附件 A 信息通过问题一的输出引入，直接拟合和验证的数据来自附件 B。除参数估计与模型验证外，需分析各因素边际效用和弹性、领域间的替代或互补关系，并推导数据质量提升与模型规模扩张相互替代的条件。真实观测、半合成补充数据及外推估计应按来源分别解释。

### 1.2.3 问题三：算力预算下的联合优化

在总算力约束下，配置参数量 $N$、数据量 $D$、质量 $Q$ 与领域配比 $\boldsymbol{p}$，目标是改善模型损失。成本同时包含基础训练、质量提升和长文本注意力三部分。质量成本函数可选用或改进题目给出的形式。上下文长度 $L_{\mathrm{ctx}}$ 依据 C7 确定可行范围，作为外生量参与成本计算及敏感性分析，不作为寻优变量。需要比较至少三个不同量级预算下的最优配置，给出“结构性转移”的数学定义与识别方法，讨论质量成本形式对结果的影响，并解析注意力开销与基础训练开销相当时的临界上下文长度。

### 1.2.4 问题四：技术演进与能力前沿

结合附件 C 的历史评测、模型规模与算力数据，区分由规模扩张带来的能力增长和架构、对齐、数据工程等非规模技术进步的贡献。需要明确综合能力指标、开源模型筛选规则、预训练模型与对话或微调模型的分类，以及模型时间轴的统计口径。利用可比的 Loss–Benchmark 桥接数据建立交叉熵损失与多维评测得分的映射，分析映射误差。在算力增长放缓等情景下预测未来 12 或 24 个月开源模型的能力前沿，并给出不确定性范围。对附件 C8 的逐任务评测数据还须进行聚合分析，以避免仅凭汇总得分判断能力变化。

# 2 问题分析

## 2.1 建模思路

### 2.1.1 问题一的分析

本文先将 22 项质量信号统一方向并综合赋权。指标对冲突使用严格互斥的高低尾部定义，样本级再以四维分极差识别失衡并计算最终质量分。扩展集采用冻结的域内切点和非重叠余集核验。对 17 域配比先拟合对数线性基线，再用单域曲率项与稳定筛选的跨域交互项刻画损失。随后在训练侧通过交叉验证选模，并对固定检验集的回顾性排序结果及代理推荐的未实测边界分别报告。

### 2.1.2 问题二的分析

以 B1 拟合经典参数量–数据量标度律，分层检验跨来源规模结构。再用 B6 选择并估计质量响应形式，再由 B7 的新质量水平作半合成外层检验。A6–A9 的 1M–60M 相同配方支持排序迁移，但缺少训练 token 数和独立质量观测，无法识别配比作用幅度的尺度指数。综合模型以各配比自己的质量起点归一化，分析边际效用、质量与规模替代以及条件外推。未识别的配比尺度函数纳入结构敏感性情景。

### 2.1.3 问题三的分析

以问题二的广义标度律为损失代理，把参数量、训练数据量、问题一导出的三个有限配比候选和追加质量治理纳入同一算力预算。分别求各配比的数值解后比较预测损失，再沿连续预算寻找质量投资的状态转移，并将已核验的分支交叉与仅由数值状态二分得到的位置分开。最后利用 C7 上下文长度和联合桥参数情景评估条件稳健性，同时标明高预算外推及标度律参数联合不确定性尚未覆盖的边界。

### 2.1.4 问题四的分析

先以 C1 的六维综合分定义能力前沿，核对许可证、模型类型和提交、发布两条时间轴，再用 C8 的逐任务结果检验汇总分中的能力差异。对可与 C4 唯一匹配的模型，以实测训练算力建立高分位前沿，将观测变化分解为算力扩张、非规模时间漂移和未解释项。C3 提供较长时期的描述性参照。随后用 C5 校准损失–能力桥，在 C6 新增模型上检验，再把问题三的最优损失增量作为高度依赖预算外推的条件核对接入当前实测前沿。算力变化点与增长情景只使用预测截止日前的 C4 记录。最后比较候选预测器与 Persistence 基线的滚动误差及前沿刷新次数，再给出 12、24 个月的条件情景和期限扩张经验区间。

# 3 模型假设与符号说明

## 3.1 模型假设

附件中的样本数、字段范围和配比重复关系均为观测事实，不列为模型假设。四问额外使用下列可定位的计算约定与识别假设。

1. **固定预处理口径。**质量指标的方向、截尾与缺失填补参数以及熵权–CRITIC 权重只由 A1 确定，再用于 A2、A3；扩展集冲突复核的尾部切点由 A1 相应领域子集估计并冻结。此约定用于问题一的非重叠扩展余集检验，避免用复核数据重定阈值。
2. **跨附件质量坐标桥。**问题一的 $Q_A = Q^{\text{res}}$ 与 B6/B7 的 $Q_B$ 没有共同标定实验，使用 $T(Q_A; c_Q) = \text{clip}[1 - c_Q(1 - Q_A), 0, 1]$ 对齐，中心设 $c_Q = 1$，并检查 $0.75, 1.25$。因此质量–规模替代的数值是桥接条件下的预测，不是已识别的跨附件因果效应。
3. **模块化闭合与配比尺度。**问题二在没有同时操纵 $N, D, Q_A, \mathbf{p}$ 的实验条件下，采用可分离的广义标度律，并以各配比自身的质量起点归一化。A6–A9 的相同配方只支持排序迁移；幅度尺度指数 $\gamma_p$ 未识别。问题二、三的名义情景设 $\gamma_p = 0$，正指数仅用于敏感

性分析。

4. **有限候选资源决策。**问题三仅在问题一正式导出的 $\mathbf{p}_{\text{risk}}, \mathbf{p}_{\text{safe}}, \mathbf{p}_{\text{measured}}$ 中选择；$\mathbf{p}_{\text{ref}}$ 作为模型内参考，不进入方案选择。题目给出的质量成本函数与设定的注意力系数决定预算换算。所得最优值是候选集合、代理损失模型及给定预算情景内的数值解；全部连续配比空间与目标尺度的实测效果须另行评估。
5. **能力前沿的操作口径。**问题四以 C1 许可证白名单界定可研究复现的开放模型，以提交日期排序能力记录、以发布日期描述模型年代。C1 与 C4 唯一匹配后的训练 FLOPs 表示模型训练规模；非规模时间漂移汇总同时期多种变化，未单独识别算法的因果贡献。
6. **预测信息集与跨问增量。**问题四的算力变化点和增长情景只从 2025 年 3 月 13 日以前可见的 C4 记录估计。问题三的最优损失曲线通过锚定增量接入 C1 实测前沿；超出问题三非远距离预算范围时，这一接口用于跨问题条件核对。累计前沿模型施加不下降约束，长期经验区间按有效短期回测残差与历史正向刷新幅度扩张。

### 3.2 主要符号

表 3.1 符号说明表

| 符号 | 含义及来源 |
|---|---|
| $N, D$ | 参数量、训练 token 数（B 中十亿单位先换算） |
| $C, C_i$ | 总算力预算、单模型训练 FLOPs（$C_i$：C4） |
| $L, E$ | 验证集交叉熵损失、标度律渐近项（B1） |
| $\mathbf{p}, \mathcal{P}_{\text{exec}}$ | 17 域配比、三个有限候选（问题一） |
| $Q_A, Q_B, T$ | 问题一与 B6/B7 的质量坐标及桥接映射 |
| $Q_{0,A}(\mathbf{p})$ | 配比加权的质量治理起点 |
| $Q^{\text{lin}}, Q^{\text{res}}, \text{CI}$ | 线性分、几何聚合分、四维极差（A1–A3） |
| $\alpha, \beta$ | 参数轴与数据轴指数（B1） |
| $\kappa, c_Q$ | 质量响应系数（B6）、情景质量桥系数 |
| $\psi_{p,0}, \gamma_p$ | 配比结构因子、待识别的尺度指数 |
| $L_{\text{ctx}}, \eta_{\text{att}}$ | 外生上下文长度（C7）、注意力成本系数 |
| $g(Q_A)$ | 质量成本函数（题目） |
| $S, F_t, G$ | 六维综合分（C1）、累计前沿、情景年算力倍数（C4） |

## 4 问题一的建模与求解

### 4.1 问题分析与数据划分

本问有两条相互关联的任务线。其一，利用 A1–A3 的质量信号，把方向、量纲和字段类型不同的 22 项指标转换为可比较的样本质量分，并检验指标冲突是否会使简单加权评分失真。其二，利用 A4–A15 的配方实验，刻画 17 个训练域的份额对 13 个验证域交叉熵损失的影响。质量信号所属的七个域与配方实验的 17 个域并不一致，本文按 A16 的对应关系建立跨域映射，使两类数据在统一坐标下参与建模。

A1 含 51,230 条质量记录，A2 的 arxiv 扩展集含 17,523 条，A3 的 github 扩展集含 203,752 条。A1 中相应域的记录已包含在扩展集中，合并统计时按样本 ID 去重；验证扩展结论时则使用与 A1 不重叠的余集。配比实验中，A4/A5 的 512 组 1M 参数模型用于拟合

与训练内部选择；A6/A7、A8/A9、A10/A11 分别是 1M、60M、1B 尺度的固定检验集，样本数为 256、256、64。A12–A15 对应 10B、70B 尺度的幂律外推表，属于估计损失而非该尺度的新训练观测。全文将固定检验集用于回顾性比较，将外推表用于敏感性讨论。

术语上，验证集是计算模型交叉熵损失的语料；固定检验集是 A6–A11 中未参与 A4/A5 拟合与选模的配比记录；验证域指逐域损失对应的 13 个领域。配比指 17 域份额向量 **p**，配方指按该向量确定的一项训练组合。

## 4.2 质量指标预处理与综合评分

### 4.2.1 列表压缩、方向统一与量纲处理

22 项指标中有 14 项标量和 8 项列表型信号。单元素教育价值分直接取值；二分类 fluency_en 与 ad_en 的两个 logit 经 softmax 化为类别概率；四项 ModernBERT 六级评分取类别序号的概率期望；QuRating 的四个同尺度分量取均值。二分类的类别语义通过不同文本域的分布对照判定：广告指标最终转为广告概率，再作为负向指标处理。三个 DSIR 文档级累加量先除以词数，以减弱文档长度对样本评分的混淆。上述教育价值、编码器评分、四维质量评分和重要性重采样信号的公开方法背景分别见文献 [1–4]；本题实际使用的字段与取值以附件 A 为准。

将处理后的指标分为 13 项正向、6 项负向、3 项区间型。对正、负向指标，只在 A1 上计算第 1 与第 99 百分位阈值 $l_j, u_j$，并在三个数据集上固定使用：

$$z_{ij} = \frac{\mathrm{clip}(v_{ij}; l_j, u_j) - l_j}{u_j - l_j}, \qquad x_{ij} = \begin{cases} z_{ij}, & j \text{ 为正向指标,} \\ 1 - z_{ij}, & j \text{ 为负向指标.} \end{cases} \tag{4.1}$$

对词数、句子数和平均词长，采用合理区间内得分为 1、两侧向 0 递减的分段函数；词数区间为 $[50, 10^5]$，平均词长区间为 $[3, 10]$，句子数下限为 3、上限取 A1 的第 95 百分位。词数和句子数在 $\log(1+v)$ 尺度计算，平均词长在线性尺度计算。两侧截点与缺失填补所用中位数均由 A1 确定并冻结。此处理使全部 $x_{ij} \in [0, 1]$ 且含义一致，即数值越高代表相应方面的质量越好。区间选择参考语料过滤规则的量级 [5]，具体分位端点由本题 A1 数据确定。

### 4.2.2 熵权与指标对比强度赋权（CRITIC）

仅按单一指标的离散程度赋权，容易使高度相关的指标重复计分。我们在 A1 上分别计算熵权和 CRITIC 权重；后者是依据指标标准差和指标间相关性确定权重的客观赋权法 [6]。令 $n$ 为 A1 样本数，$x_{ij}$ 为式(4.1)所得分数，则

$$\begin{aligned} p_{ij} &= \frac{x_{ij}}{\sum_{r=1}^{n} x_{rj}}, & e_j &= -\frac{\sum_{i=1}^{n} p_{ij} \log p_{ij}}{\log n}, \\ w_j^E &= \frac{1 - e_j}{\sum_k (1 - e_k)}, & C_j &= \sigma_j \sum_k (1 - r_{jk}), \\ w_j^C &= \frac{C_j}{\sum_k C_k}, & w_j &= \frac{\sqrt{w_j^E w_j^C}}{\sum_k \sqrt{w_k^E w_k^C}}. \end{aligned} \tag{4.2}$$

其中 $r_{jk}$ 是指标 $j, k$ 在 A1 上的 Pearson 相关系数，$\sigma_j$ 是指标 $j$ 的样本标准差；计算熵时约定 $0 \log 0 = 0$。组合权重 $w_j$ 固定后直接用于 A2、A3。实算的四个维度权重依次为语义价值 0.4065、语言表达 0.2084、信息结构 0.1145、干净度 0.2706；单项最高的是专业性指标，权重 0.1371。

从单项权重看，表4.1列出组合权重最高的六项。专业性指标的熵权为 0.1791，高于其

CRITIC 权重 0.0952，合成后为 0.1371；这说明两种赋权依据并不完全一致。推理性与行末标点占比的组合权重分别为 0.0826 和 0.0808。表中权重只衡量 A1 指标在当前归一化和样本分布下对综合分的贡献，不把指标权重解释为训练损失的因果贡献。

表 4.1　A1 组合权重最高的六项质量指标

| 指标 | 维度 | 熵权 | CRITIC 权重 | 组合权重 |
|---|---|---|---|---|
| 专业性 | 语义价值 | 0.1791 | 0.0952 | 0.1371 |
| 推理性 | 语义价值 | 0.1207 | 0.0512 | 0.0826 |
| 行末标点占比 | 语言表达 | 0.0887 | 0.0667 | 0.0808 |
| 大写字母占比 | 干净度 | 0.0612 | 0.0661 | 0.0668 |
| 文本洁净度 | 干净度 | 0.0688 | 0.0545 | 0.0643 |
| 英语流畅度 | 语言表达 | 0.0599 | 0.0619 | 0.0639 |

将指标划为上述四维，记维度 $d$ 的指标集为 $\mathcal{J}_d$，定义

$$W_d = \sum_{j \in \mathcal{J}_d} w_j, \qquad S_{id} = \frac{\sum_{j \in \mathcal{J}_d} w_j x_{ij}}{W_d}, \qquad Q_i^{\text{lin}} = \sum_{d=1}^{4} W_d S_{id}. \tag{4.3}$$

线性分 $Q^{\text{lin}}$ 是对四个质量侧面的完全可补偿平均。它提供可解释的质量分参照，但对于某一维度极低、另一维度极高的文本可能掩盖质量短板，因此最终评分在冲突诊断后确定。

## 4.3　指标冲突的识别与消解

### 4.3.1　指标对与样本层面的冲突定义

方向统一以后，以指标的交叉尾部刻画同一文本受到的相反评价。令 $q_j^{25}, q_j^{75}$ 为指标 $j$ 在 A1 上的第 25、75 百分位数，采用严格互斥的尾部标记

$$H_{ij} = \mathbf{1}(x_{ij} > q_j^{75}), \qquad L_{ij} = \mathbf{1}(x_{ij} < q_j^{25}). \tag{4.4}$$

等于分位切点的观测归入中性区。区间型指标在平台值上可能满足 $q_j^{25} = q_j^{75}$；若同时使用非严格不等号，同一样本会被标为高、低两类，使下式中的两个事件重叠。式(4.4)保证 $H_{ij}L_{ij} = 0$，因而每个样本对一组指标至多贡献一次冲突。指标对 $(j, k)$ 的冲突率及独立参照值分别为

$$c_{jk} = \frac{1}{n}\sum_i (H_{ij}L_{ik} + L_{ij}H_{ik}), \qquad e_{jk} = \pi_j^H \pi_k^L + \pi_j^L \pi_k^H, \qquad \rho_{jk} = \frac{c_{jk}}{e_{jk}}, \tag{4.5}$$

其中 $\pi_j^H, \pi_j^L$ 为实际严格尾部比例，不强制等于 0.25。若 $e_{jk} = 0$，则该指标对的倍率不可识别，不参与筛选或组间比较。A1 的 231 对中有 228 对可识别、3 对不可识别；代码检查高低尾部重叠数为 0，冲突率最大为 0.2979，均在概率范围内。$\rho_{jk} > 1$ 表示交叉尾部冲突比独立参照更常出现，但不等价于全样本相关系数为负。以 $\rho_{jk} > 1$ 且 $z_{jk} = (c_{jk} - e_{jk})/\sqrt{e_{jk}(1 - e_{jk})/n} > 3$ 为预设的强冲突筛选规则，可识别指标对中有 80 对满足条件。该筛选未作 231 次比较的多重校正，不据此宣称统计显著。

按 $\rho_{jk}$ 排序的前五对见表4.2。最高倍率来自“独特词占比—词数”，其交叉尾部共现率为 0.0895，约为独立参照 0.0263 的 3.40 倍。按绝对冲突率看，“一元词熵—独特词占比”达到 0.2979，但其独立参照也较高，因此倍率为 2.39。两个口径分别回答“冲突出现多少”

和“相对边际分布有多意外”，不应混为同一排序。表内 Spearman 是全样本秩相关，与尾部倍率描述的局部结构也不等价。

表 4.2　A1 中冲突倍率最高的五组可识别指标对

| 指标对 | 冲突率 $c$ | 独立参照 $e$ | 倍率 $\rho$ | Spearman |
|---|---|---|---|---|
| 独特词占比 / 词数 | 0.0895 | 0.0263 | 3.40 | $-0.437$ |
| 高频 3gram 占比 / 词数 | 0.0860 | 0.0264 | 3.25 | $-0.279$ |
| 专业性 / 平均词长 | 0.0587 | 0.0198 | 2.96 | $-0.316$ |
| 一元词熵 / 独特词占比 | 0.2979 | 0.1247 | 2.39 | $-0.648$ |
| 高频 2gram 占比 / 句子数 | 0.0475 | 0.0219 | 2.17 | $-0.132$ |

指标对揭示冲突来源，样本级处置则用四维分的极差定义冲突强度指数（CI）：

$$\mathrm{CI}_i = \max_d S_{id} - \min_d S_{id}, \qquad \mathrm{CI}_i \geq 0.5 \implies \text{记为冲突样本.} \tag{4.6}$$

本文以预设阈值 0.5 筛选高冲突样本，为进一步核验提供候选清单。基于维度分，A1 的冲突样本占比为 19.77%，平均冲突强度为 0.377；尾部切点修正后，两项样本级统计保持稳定。分领域看，c4 与 stackexchange 的冲突占比分别为 63.25% 和 1.79%，揭示了冲突分布的领域异质性。跨维度与同维度指标对的冲突倍率中位数分别为 0.778 和 0.582，单侧 Mann–Whitney 检验得到 $p = 0.137$；跨评分器类型与同类型的中位数分别为 0.872 和 0.622，$p = 0.152$。两项探索性比较为后续分层检验提供了量化线索。CI 与词数对数的 Spearman 相关系数为 0.064，体现出冲突评分较低的长度依赖度。

### 4.3.2　有限补偿的最终质量分

为防止某一维度的低分被其他维度完全抵消，在相同权重 $W_d$ 下使用幂平均族 $M_s = (\sum_d W_d S_{id}^s)^{1/s}$。$s = 1$ 对应线性分；取 $s \to 0$ 的加权几何平均作为最终评分：

$$Q_i^{\mathrm{res}} = \prod_{d=1}^{4} \max(S_{id}, 0.01)^{W_d}. \tag{4.7}$$

在各维得分为正时，$\partial Q_i^{\mathrm{res}} / \partial S_{id} = W_d Q_i^{\mathrm{res}} / S_{id}$，低分维度得到更大的边际关注，但仍保留其余维度信息。A1 中冲突样本的 $Q^{\mathrm{res}} - Q^{\mathrm{lin}}$ 平均为 $-0.0608$，非冲突样本为 $-0.0169$；下调幅度与 CI 的 Spearman 相关为 0.935。这说明几何聚合实现了对失衡文本更强的软惩罚。将幂指数从 1 调至 $-2$ 后，惩罚逐渐增强；本问取 $s = 0$，避免使用最小值规则所造成的信息丢弃。

图4.1直接比较两种样本评分。冲突强度较高的样本相对等值线下移更明显，说明几何聚合对失衡的维度分数施加了更强的软惩罚。图4.2进一步按冲突强度汇总质量下调量，便于核对这种关系是否只由少数极端样本驱动。

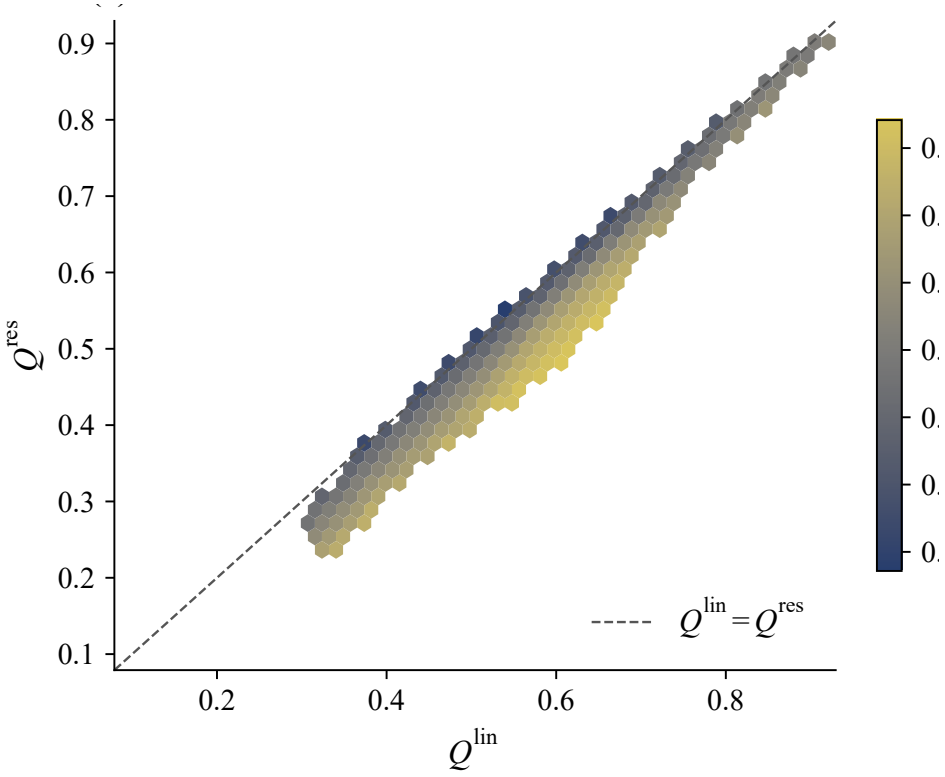



图 4.1　线性质量分 $Q^{lin}$ 与有限补偿评分 $Q^{res}$ 的样本关系。颜色表示冲突强度，虚线表示两种评分相等。

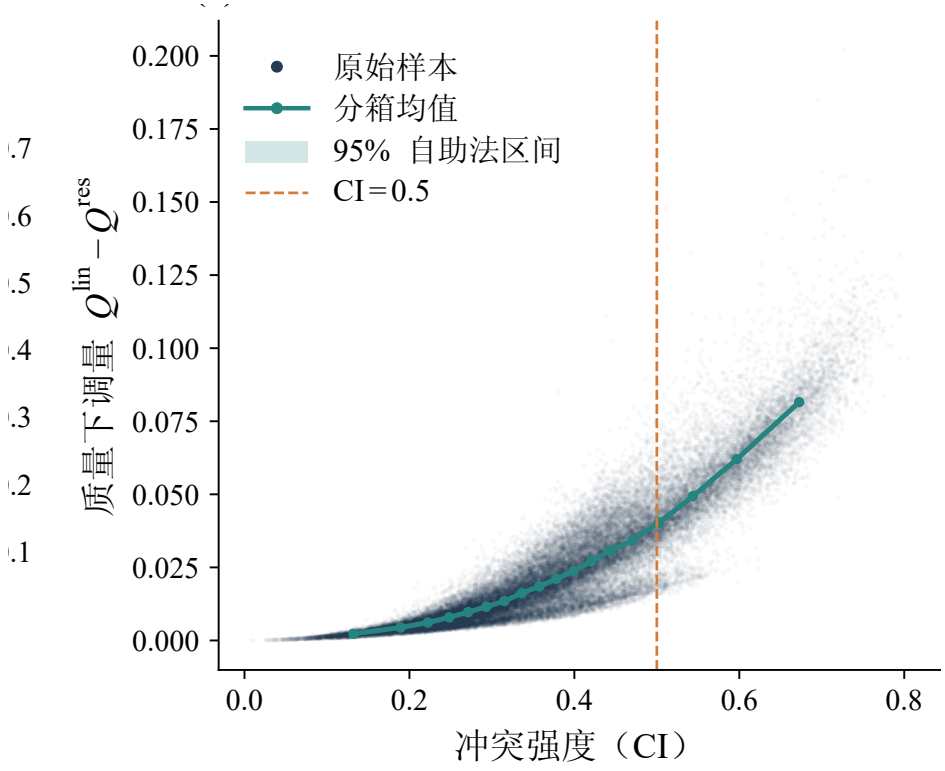



图 4.2　冲突强度与质量下调量。散点为 A1 样本，实线为分箱均值，阴影为图内标注的 95% 自助法区间。

扩展检验保持 A1 的归一化参数及权重不变。为比较域内冲突结构，高低尾部切点另由 A1 中对应领域子集估计并冻结，按式(4.4)分别用于该子集与扩展集非重叠余集；样本级 CI $\geq 0.5$ 阈值不变。表4.3 显示两个域的冲突水平近似稳定。冲突倍率矩阵的秩相关在 github 很高，在 arxiv 仍较高但 Top-20 冲突对重合度较低，因此复现程度并不相同。

表 4.3　非重叠扩展余集的域内冲突复核

| 域 | A1 域内数 | 余集数 | 矩阵 Spearman | Jaccard@20 | A1 冲突率 | 余集冲突率 |
|---|---|---|---|---|---|---|
| arxiv | 1 419 | 16 104 | 0.8700 | 0.5385 | 11.84% | 11.98% |
| github | 10 000 | 193 752 | 0.9974 | 0.9048 | 6.92% | 6.80% |

在 A1 的最低、最高质量五分位中，非 ASCII 字符占比分别为 5.88%、0.41%，营销词命中率分别为 0.93%、0.43%；URL 密度分别为每千字符 0.333、0.091，但其与 $Q^{\text{res}}$ 的样本级 Spearman 仅为 0.051。前两项支持评分方向；URL 密度提供端点组差异，作为辅助核对指标。这些内容统计量亦非人工标注的质量真值。

## 4.4　由样本质量到领域质量

以文档为抽样单位的领域质量分记为 $Q_d^{\text{doc}} = |\mathcal{D}_d|^{-1} \sum_{i \in \mathcal{D}_d} Q_i^{\text{res}}$；考虑训练语料中长文档贡献更多词元，另报告以词数 $n_i$ 近似加权的语料质量分

$$Q_d^{\text{corpus}} = \frac{\sum_{i \in \mathcal{D}_d} n_i Q_i^{\text{res}}}{\sum_{i \in \mathcal{D}_d} n_i}. \tag{4.8}$$

表4.4 同时报出两种口径。文档均值的 95% 区间由 300 次有放回自助重抽样（Bootstrap）得到。arxiv 与 github 以扩展集去重全量为最终值，其 A1 抽样均值分别为 0.7961、0.5179，与全量值之差均小于 0.001。词数加权用于近似刻画长文档对语料的更高贡献，权重单位是词数；实际训练分词器的 token 权重仍需另行计算。

表 4.4　七个质量域的文档均值与词数加权质量分

| 质量域 | 文档数 | $Q_d^{\text{doc}}$ | 文档均值 95% 区间 | $Q_d^{\text{corpus}}$ |
|---|---|---|---|---|
| arxiv | 17 523 | 0.7953 | [0.7948, 0.7958] | 0.7926 |
| book | 171 | 0.6078 | [0.5972, 0.6206] | 0.6198 |
| c4 | 10 000 | 0.5903 | [0.5883, 0.5922] | 0.6468 |
| commoncrawl | 9 640 | 0.6155 | [0.6133, 0.6175] | 0.6471 |
| github | 203 752 | 0.5171 | [0.5167, 0.5175] | 0.5558 |
| stackexchange | 10 000 | 0.6450 | [0.6435, 0.6463] | 0.6680 |
| wikipedia | 10 000 | 0.5248 | [0.5233, 0.5270] | 0.6099 |

## 4.5　17 域配比与损失的定量关系

### 4.5.1　目标、基线模型与结构化曲率模型

令 $\mathbf{p} = (p_1, \ldots, p_{17}) \in \Delta^{16}$，其中 $p_i \geq 0$、$\sum_i p_i = 1$。对每组配比，设 $L_v(\mathbf{p})$ 为验证域 $v$ 的交叉熵损失，主目标为 13 域等权均值 $\bar{L}(\mathbf{p}) = 13^{-1} \sum_{v=1}^{13} L_v(\mathbf{p})$。17 个训练域均保留为

输入份额；其中四个域没有同名验证损失，故输出仍为 13 维。小模型配比代理回归的思路与 RegMix 一致 [7]，但以下特征组合、选择规则与风险目标均由本题数据分析确定。

作为可解释基线，设 $z_i = \log(p_i + \varepsilon)$，拟合

$$\widehat{\widehat{L}}_{\log}(\mathbf{p}) = c + \sum_{i=1}^{17} a_i z_i. \tag{4.9}$$

若局部数据效应随份额增加而递减，对数形式可近似描述这种曲率。$a_i$ 是平滑对数份额的局部响应系数；在配比和为 1 的约束下，其含义为沿单纯形转移方向 $g_i(\mathbf{p})$ 的局部效应。沿单纯形中将当前配比的一小部分转移给域 $i$ 的方向，局部效应为

$$g_i(\mathbf{p}) = \nabla \widehat{\widehat{L}}_{\log}(\mathbf{p})^{\mathsf{T}}(\mathbf{e}_i - \mathbf{p}) = \frac{a_i}{p_i + \varepsilon} - \sum_{k=1}^{17} \frac{a_k p_k}{p_k + \varepsilon}. \tag{4.10}$$

因此 $g_i < 0$ 表示在指定基准配比与转移方向下，代理模型预计损失下降。训练配比中，$a_i$ 最负的四个域为 stackexchange $-0.0562$、dm_mathematics $-0.0553$、pile_cc $-0.0483$、ubuntu_irc $-0.0465$。这些系数刻画训练支持域内的局部关联；跨尺度作用幅度还需要带训练 token 数和独立质量观测的同配方实验识别。

为了表达每个域自身的非线性响应，在对数线性基线上加入平方对数项和原份额项。本文将这一平均损失代理称为结构化曲率模型（SCM）：

$$\widehat{\widehat{L}}_{\mathrm{SCM}}(\mathbf{p}) = c + \sum_{i=1}^{17} \left[ a_i \log(p_i + \varepsilon) + b_i \log^2(p_i + \varepsilon) + d_i p_i \right]. \tag{4.11}$$

51 个显式特征用岭回归估计。$\varepsilon \in \{10^{-4}, 10^{-3}, 10^{-2}\}$ 与岭系数 $\lambda_{\text{ridge}} \in \{0.01, 0.1, 1, 10, 100\}$ 仅在 A4/A5 的固定五折上按 Spearman 相关选择，本次选得 $\varepsilon = 10^{-4}$、$\lambda_{\text{ridge}} = 1$。另以线性混料、完整二阶岭回归及梯度提升树（GBM）作对照。完整二阶模型用于描述组合关系，SCM 侧重跨尺度排序的稳定性。

表4.5展示 A4/A5 固定五折上的完整 15 组参数搜索。$\varepsilon = 10^{-4}$、$\lambda_{\text{ridge}} = 1$ 的排序相关为 0.9651，是这一预设网格的最高值。$\varepsilon = 10^{-2}$ 的五组结果均低于 0.949，说明低份额处的平滑常数会影响对数特征的区分度。该表是开发集内部选模依据，固定检验集成绩仍单独见表4.6。

表 4.5　SCM 平滑常数与岭系数的 A4/A5 五折 Spearman

| $\varepsilon \backslash \lambda_{\text{ridge}}$ | 0.01 | 0.1 | 1 | 10 | 100 |
|---|---|---|---|---|---|
| $10^{-4}$ | 0.9638 | 0.9641 | **0.9651** | 0.9638 | 0.9534 |
| $10^{-3}$ | 0.9620 | 0.9616 | 0.9631 | 0.9633 | 0.9563 |
| $10^{-2}$ | 0.9486 | 0.9464 | 0.9464 | 0.9420 | 0.9335 |

式(4.11)的对数项描述低份额区的快速响应，平方对数项允许曲率变化，原份额项修正较高份额区的趋势。图4.3展示四个示例域的局部预测曲线。

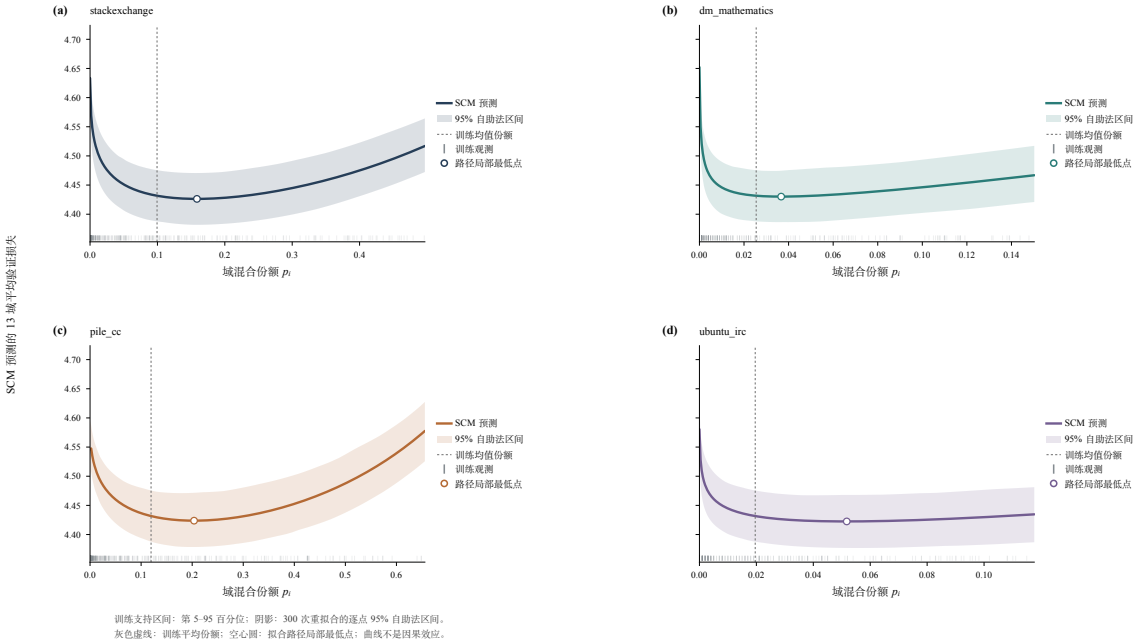



图 4.3　SCM 学到的分域非线性响应。四个示例域的横轴为域混合份额，纵轴为 SCM 预测的 13 域平均损失；阴影为重抽样 95% 区间，虚线标出训练集份额，空心点为拟合曲线的局部低点。

图4.3表明域份额的边际效应随当前份额改变。曲线描述代理模型在训练支持区间内的局部响应，区间外的延伸展示其预测趋势。配比优化仍限定在训练支撑域内。

### 4.5.2　稳定稀疏交互增强

SCM 不显式包含域间交互。我们以 136 个 $z_i z_k$ 为候选项，在 A4/A5 内对 SCM 残差进行 200 次 Bootstrap 与弹性网络（Elastic Net）筛选 [8, 9]，要求入选频率至少 0.7、入选时符号一致率至少 0.8；这一重复抽样筛选借鉴稳定选择思想 [10]。将稳定入选的交互项加入 SCM 所形成的平均损失代理，称为稳定稀疏交互模型（SCI）。训练集只保留 github×stackexchange 一项，两项统计量均为 1.0。A4/A5 开发集的外层五折各自在训练折内重做交互筛选，SCI 的折外 Spearman 为 0.9737，高于 SCM 的 0.9651，因此按开发集门控采用 SCI 作为最终的平均损失代理。这个结果是 A4/A5 内的折外评估；固定检验集结果另见表4.6。交互系数描述预测曲面中的联合变化；在单纯形约束下，交互项的含义依赖被替换的域，故其解释须结合式(4.10)的转移方向。

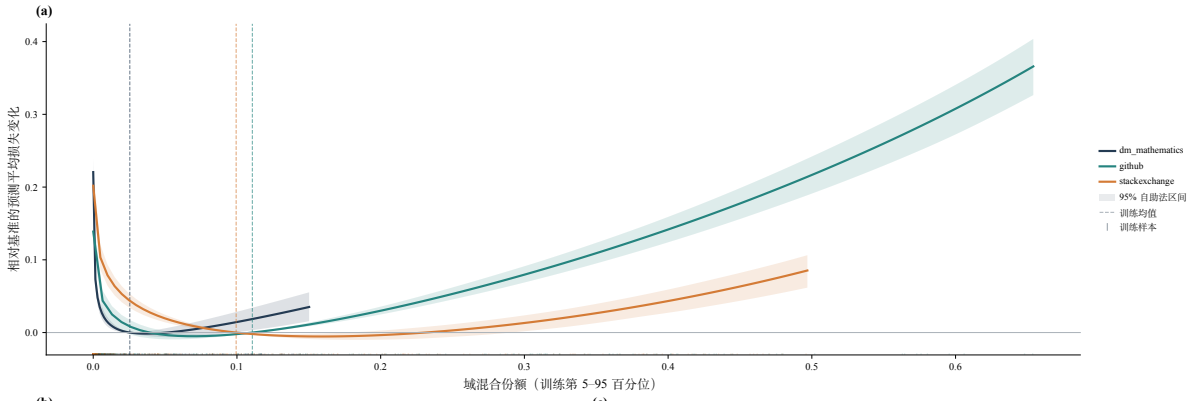



图 4.4　三个示例域相对基准份额的 SCM 预测平均损失变化。实线为代理曲线，阴影为自助重抽样区间；竖线标示训练集份额。

图4.5SCM 在三个固定检验尺度相对对数线性基线的排序增量。1M 与 60M 的配对自助区间位于零右侧；1B 的区间跨过零，说明该尺度的增量方向仍有抽样不确定性。图4.6再展示交互筛选：136 个候选中只有一项稳定入选，内嵌图把 SCI 相对 SCM 的折外和固定检验表现并列。

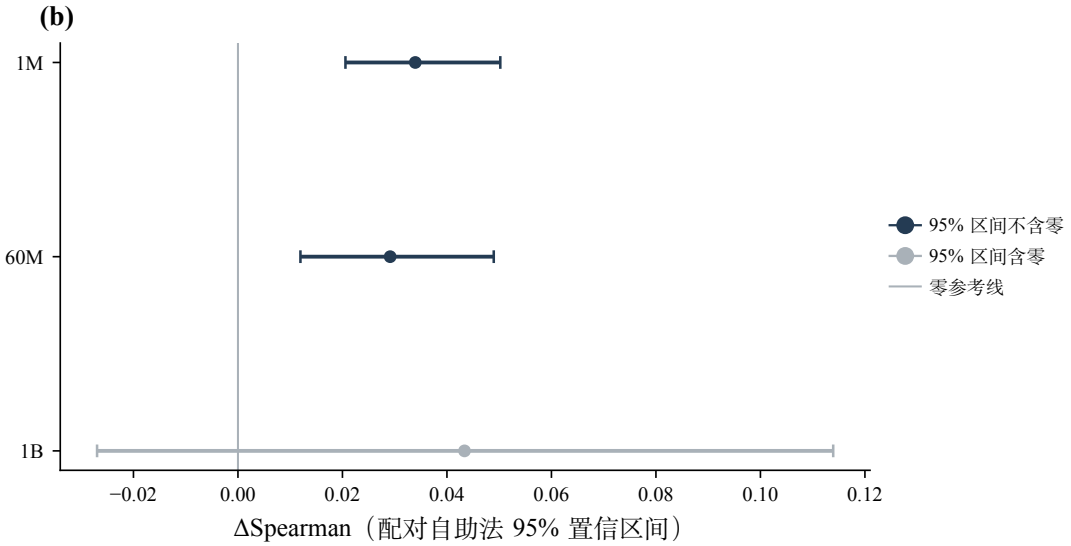



图 4.5　SCM 相对对数线性基线在 1M、60M、1B 固定检验集上的 Spearman 增量。横线为配对 Bootstrap 95% 区间。

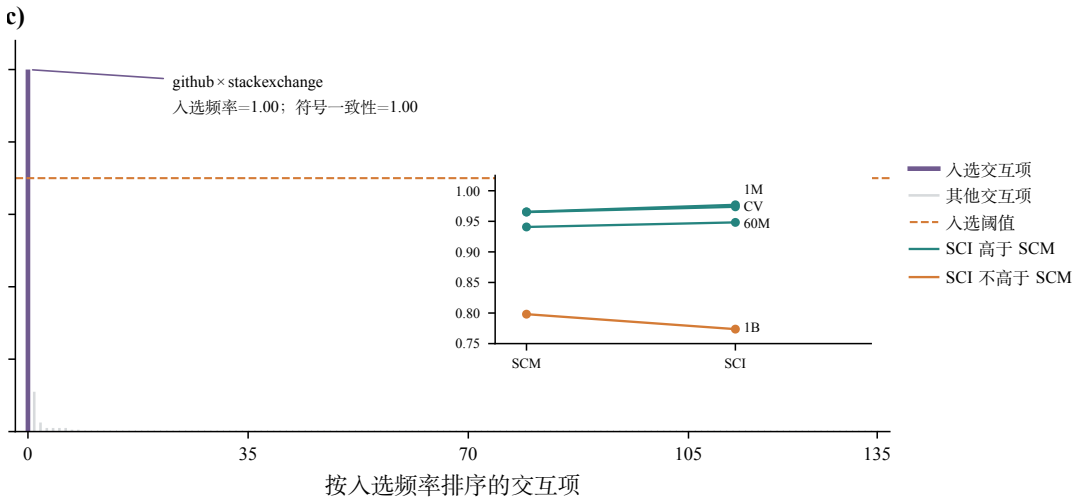



图 4.6　136 个交互候选的稳定选择。仅 github×stackexchange 入选；内嵌图比较 SCI 与 SCM 在开发集和固定检验集上的排序相关。

### 4.5.3　固定检验集上的模型比较

由于 1M 训练损失与更大尺度的损失基线不同，表4.6 以配比排序的 Spearman 相关为主指标。图4.5及表4.6显示，SCM 相对对数线性基线，在 1M、60M、1B 的增量依次为 0.0339、0.0291、0.0434；1B 的配对 Bootstrap 95% 区间为 $[-0.0270, 0.1139]$，跨过零。SCI 在训练折外与 1M 固定检验集上取得最佳排序，在 1B 尺度则由 SCM 更优。

表 4.6　配比模型的平均损失排序能力（Spearman 相关）

| 模型 | A4/A5 五折 | 1M 检验 | 60M 检验 | 1B 检验 |
|---|---|---|---|---|
| 线性混料 | 0.4935 | 0.6245 | 0.5584 | 0.3685 |
| 对数线性 | 0.9432 | 0.9316 | 0.9116 | 0.7548 |
| 完整二阶岭回归 | 0.9688 | 0.9751 | 0.9498 | 0.6039 |
| GBM | 0.9616 | 0.9671 | 0.9301 | 0.7211 |
| SCM | 0.9651 | 0.9655 | 0.9408 | 0.7981 |
| SCI | 0.9737 | 0.9770 | 0.9483 | 0.7737 |

## 4.6　质量映射、配比推荐与外推边界

### 4.6.1　质量分能否改进配比预测

由 $Q^{\mathrm{res}}$ 得到七个质量域的文档均值后，按 A16 给出的对应关系形成配方域质量。若配方域 $i$ 有质量域 $d(i)$，令

$$Q_i = \kappa_i Q_{d(i)} + (1-\kappa_i)\bar{Q}_7, \qquad \bar{Q}_7 = \frac{1}{7}\sum_{d=1}^{7} Q_d = 0.6137. \tag{4.12}$$

有对应关系的六个配方域中，直接对应取 $\kappa_i = 1$，近似对应取 $0.8$；后者按 A16 的对应关系设定，是与配比损失相互独立的操作性收缩系数。其余 11 个域没有可代入式(4.12)的 $d(i)$，直接令 $Q_i = \bar{Q}_7 = 0.6137$。该值取七域均值作为共同先验，用于未直接对应域的质量占位。arxiv 与 github 的 $Q_d$ 使用去重全量均值。

固定域的 $Q_i$ 不随 A4/A5 的配比实验而改变，因此质量作用与领域身份难以分离。配比平均质量 $\bar{Q}(\mathbf{p}) = \sum_i p_i Q_i$ 对训练集平均损失的单变量 $R^2$ 仅为 0.0010；将其加到对数线性代理后，三个检验尺度的排序相关增量只有 0.0005、0.0006、0.0016。为检验质量能否通过改变有效份额改善排序，定义

$$p_i^{\mathrm{eff}}(\eta) = \frac{p_i Q_i^{\eta}}{\sum_{j=1}^{17} p_j Q_j^{\eta}}. \tag{4.13}$$

仅用 A4/A5 五折在 $\eta \in \{0, 0.25, 0.5, 0.75, 1, 1.5, 2\}$ 中选择。图4.7展示选择结果。

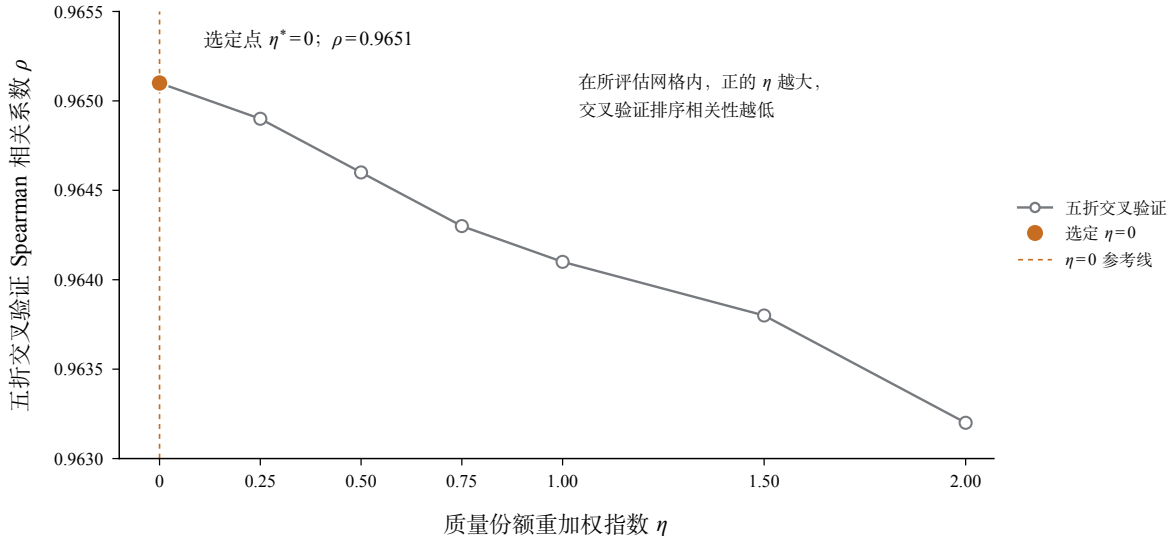



图 4.7　质量重加权指数 $\eta$ 的交叉验证选择。训练集五折 Spearman 在 $\eta = 0$ 时最高，继续增大指数未增加排序能力。

最高 Spearman 为 0.9651，对应 $\eta = 0$，即 $p_i^{\text{eff}} = p_i$。因此本问的损失代理仍使用原始份额 $\mathbf{p}$，同时将 $Q_d$、映射标记及 $Q_i$ 作为独立信息传递给后续问题；这一结果表明静态域质量均值未带来额外的排序增益，与问题二由 $\kappa > 0$ 描述的动态治理效应分属不同机制。为解释训练域变化在不同验证域的响应，另对 13 个验证域拟合对数线性响应系数，并按

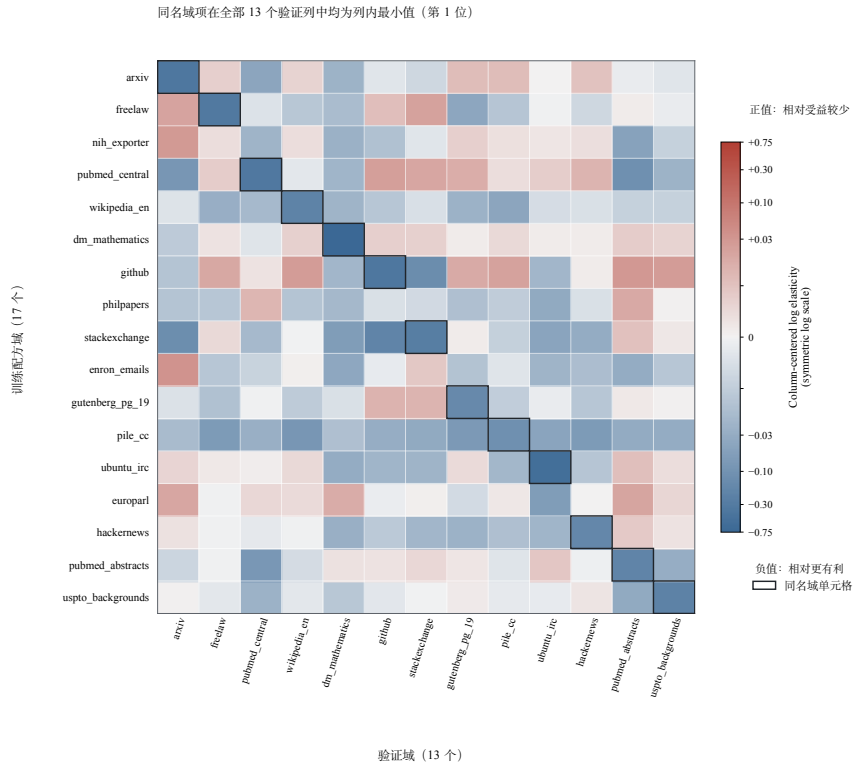



图 4.8　配方域-验证域跨域迁移矩阵。17 个训练域的逐验证域对数响应系数按列中心化；深色边框标出同名域对应项。

验证列中心化，形成 $17 \times 13$ 的迁移矩阵。

图4.8中负值表示相对更有利于降低该验证域损失；同名域在全部 13 个对应验证列中为列内最负响应。该矩阵描述已观测配方的局部关联，不等于跨域迁移的因果效应。

### 4.6.2 均值保持的逐域风险预测

为恢复每个验证域的损失，定义训练残差 $R_{rv} = L_{rv} - \bar{L}_r$，以 SCM 特征对 13 列残差作多输出岭回归。将预测残差逐行中心化，再与 SCI 的平均损失预测相加，构造均值保持的逐域残差多任务模型（MPR-MTL）：

$$\begin{aligned} \widetilde{R}_v(\mathbf{p}) &= \widehat{R}_v(\mathbf{p}) - \frac{1}{13}\sum_{u=1}^{13} \widehat{R}_u(\mathbf{p}), \\ \widehat{L}_v(\mathbf{p}) &= \widehat{\mu}_{\mathrm{SCI}}(\mathbf{p}) + \widetilde{R}_v(\mathbf{p}), \\ \frac{1}{13}\sum_{v=1}^{13} \widehat{L}_v &= \widehat{\mu}_{\mathrm{SCI}}. \end{aligned} \tag{4.14}$$

逐验证域 Spearman 中位数在 1M、60M、1B 三个固定检验集上分别为 0.9685、0.9697、0.9179；60M 和 1B 的 13 个逐域 $R^2$ 则均为负。因此，该模型用于同一尺度内候选配比的逐域相对比较，跨尺度绝对损失另由问题二的条件模型处理。两个均值代理模型在三个固定检验集的候选配比中选中了相同的最低预测损失配比；排序改善已可用于候选筛选，其选方收益留待新配比训练后验证。

为区分“候选排序”与“绝对损失校准”，表4.7将 13 个验证域的固定检验指标按尺度汇总。1M 的 13 个逐域 $R^2$ 均为正；60M 与 1B 的逐域 $R^2$ 均为负，而逐域 Spearman 的中位数仍分别为 0.9697 和 0.9179。由此，均值保持约束保证代数上一致的 13 域平均值，却不会自动消除尺度改变带来的绝对偏移。风险候选的逐域向量适合在同一尺度、相同验证域标准化口径下比较；跨尺度绝对损失由问题二另建规模项。

表 4.7　MPR-MTL 的逐域排序与绝对校准分尺度检验

| 固定检验尺度 | 每域配比数 | Spearman 中位数 | Spearman 范围 | $R^2 > 0$ 域数 |
|---|---|---|---|---|
| 1M | 256 | 0.9685 | $[0.9524, 0.9873]$ | 13 / 13 |
| 60M | 256 | 0.9697 | $[0.9503, 0.9877]$ | 0 / 13 |
| 1B | 64 | 0.9179 | $[0.8315, 0.9730]$ | 0 / 13 |

### 4.6.3 训练配比支撑域内的候选推荐

配比空间有 17 维，直接在整个单纯形上优化容易离开训练数据支撑。为控制外插，将 A4/A5 实测损失最低的 64 个配比及其随机两两凸组合作为候选，候选仍在训练配比凸包内。先以对数模型与 SCM 的预测损失百分位中的较差者为准，得到保守候选 $\mathbf{p}_{\mathrm{safe}}$；再以 MPR-MTL 的 13 域预测损失构造风险目标。设 $Z_v = (\widehat{L}_v - m_v)/s_v$，$m_v$ 为该验证域训练损失的中位数，$s_v$ 为经尺度修正的中位数绝对偏差（MAD）。条件风险价值（CVaR）$\mathrm{CVaR}_{0.8}(Z)$ 在此表示 13 个标准化逐域损失上尾约 20% 的平均值 [11]，则本问使用

$$J(\mathbf{p}) = \frac{1}{13}\sum_{v=1}^{13} Z_v(\mathbf{p}) + 0.25\,\mathrm{CVaR}_{0.8}(Z(\mathbf{p})) + 0.10\,\widehat{\sigma}_{\mathrm{boot}}[\widehat{\mu}(\mathbf{p})]\,. \tag{4.15}$$

式中的 0.25 和 0.10 是候选排序阶段预设的风险偏好系数，其设定独立于固定检验集的估计过程。不确定性项以 120 次训练集 Bootstrap 所得代理预测的标准差估计；在候选集中，取目标函数 $J$ 最小的配比作为风险候选 $\mathbf{p}_{\text{risk}}$。表4.10 列出了供后续问题使用的 17 域份额及质量映射值。SCI 代理预测的平均损失分别为 4.4579（$\mathbf{p}_{\text{risk}}$）和 4.4530（$\mathbf{p}_{\text{safe}}$）。这两个配比尚无新配比训练的实测损失，因此作为后续验证的候选方案。

表4.8进一步拆开风险候选的三个代理口径。$\mathbf{p}_{\text{safe}}$ 的未标准化平均预测损失最低，为 4.4530；$\mathbf{p}_{\text{risk}}$ 的标准化逐域平均值最低，为 $-1.1387$。二者次序不同，源于 13 个验证域各自按训练集的中位数和 MAD 变换；因而不能把标准化均值直接当作原始 Loss。上尾 CVaR 与均值也存在取舍，最终选择还计入式(4.15)的重抽样不确定性。表中“有实测”仅指该配比出现在 1M 训练集，不代表候选的代理列就是新训练结果。

表 4.8　候选配比的逐域风险代理及观测身份

| 配比 | 原始均值代理 | 标准化均值 | $\text{CVaR}_{0.8}$ | 1M 训练实测 |
|---|---|---|---|---|
| $\mathbf{p}_{\text{rob}}$ | 4.4718 | $-1.0768$ | $-0.5945$ | 否 |
| $\mathbf{p}_{\text{safe}}$ | 4.4530 | $-1.0688$ | $-0.6989$ | 否 |
| $\mathbf{p}_{\text{risk}}$ | 4.4579 | $-1.1387$ | $-0.6611$ | 否 |
| 训练集实测最佳配比 | 4.6744 | $-0.8515$ | $-0.0805$ | 是 |

### 4.6.4　尺度外推边界

对完全相同的 256 个配比，1M 与 60M 固定检验集实测损失的排序相关为 0.9658；1B 固定检验集与两者没有相同配比，故不计算直接配对相关。A12–A15 中有 63 个与训练表相同的配比，其 1M 实测损失与 10B、70B 幂律外推平均损失的排序相关分别为 $-0.739$、$-0.814$；10B 与 70B 两张外推表间为 0.990。以 1M 数据训练的 SCM、SCI 对外推表的排序相关也为负。这表明不同外推规则会改变大尺度配比名次，故本文将 10B、70B 的配比结论限定为外推假设下的情形。

表4.9把配比是否相同与损失来源同时列出。1M 与 60M 的 256 个配比逐项匹配，0.9658 的相关系数因而是实测同配方排序证据。1B 与前两组没有相同配比，模型在 1B 固定检验集上的 Spearman 是以该尺度自身的 64 个配比计算的预测排序能力，不能改写成“1M 到 1B 的同配方排序保持”。10B、70B 的三行比较均涉及外推估算损失；两张外推表彼此高度一致，反映的是共同外推口径的内部稳定性。

表 4.9　相同配比下的跨尺度排序比较及损失来源

| 比较对象 | 相同配比数 | Spearman | 右侧损失来源 |
|---|---|---|---|
| 1M 检验 / 60M 检验 | 256 | 0.9658 | 60M 实测 |
| 1M 检验 / 1B 检验 | 0 | — | 无同配方比较 |
| 1M 训练 / 10B 估算 | 63 | $-0.7392$ | 幂律外推 |
| 1M 训练 / 70B 估算 | 63 | $-0.8139$ | 幂律外推 |
| 10B 估算 / 70B 估算 | 63 | 0.9900 | 幂律外推 |

图4.9的上图展示训练配比凸包内候选的标准化预测均值与上尾风险，下图展开 13 个验证域的标准化预测损失。灰点为凸包内生成的候选，彩色标记为三项代表配比；黑色方块对应 A4/A5 实测最优配比在同一代理上的预测坐标。两部分均为代理预测，候选方案仍待新训练检验。

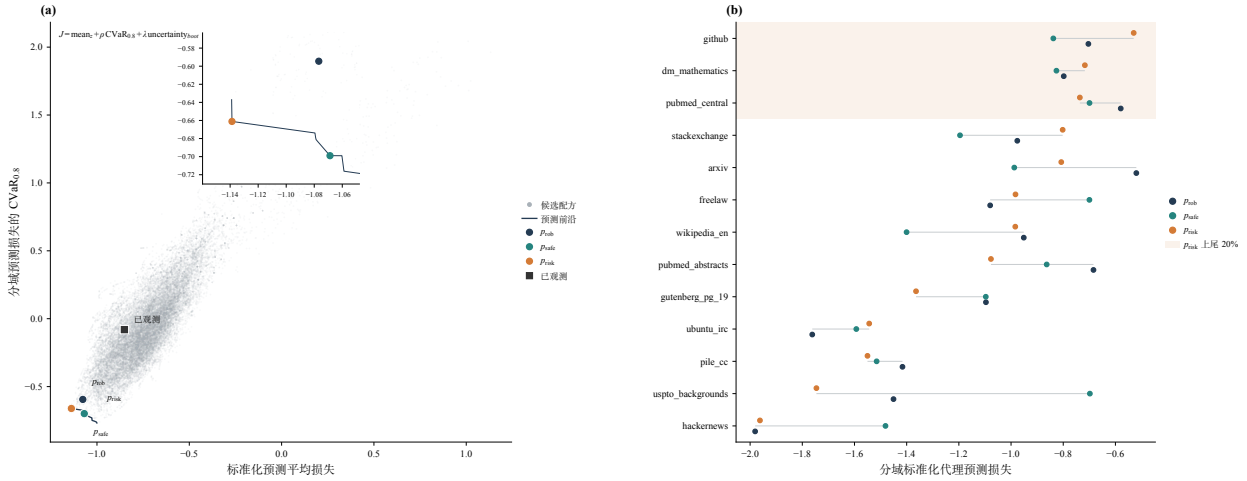



图 4.9　凸包约束下的风险控制推荐。上图目标式的风险系数为 $\rho = 0.25$、不确定性系数为 $\lambda = 0.10$；下图浅色区域标出 $\mathbf{p}_{\text{risk}}$ 的上尾约 20% 验证域。$\mathbf{p}_{\text{rob}}$ 是对照，$\mathbf{p}_{\text{safe}}$ 与 $\mathbf{p}_{\text{risk}}$ 为待验证候选。

表 4.10　风险约束候选配比与配方域质量信息

| 配方域 | $p_i^{\text{risk}}$ | $Q_i$ | 质量信息 |
|---|---|---|---|
| arxiv | 0.0587 | 0.7953 | 直接映射 |
| freelaw | 0.0820 | 0.6137 | 无映射先验 |
| nih_exporter | 0.0007 | 0.6137 | 无映射先验 |
| pubmed_central | 0.0757 | 0.6137 | 无映射先验 |
| wikipedia_en | 0.0355 | 0.5426 | 近似映射 |
| dm_mathematics | 0.0185 | 0.6137 | 无映射先验 |
| github | 0.0229 | 0.5171 | 直接映射 |
| philpapers | 0.0346 | 0.6137 | 无映射先验 |
| stackexchange | 0.0822 | 0.6450 | 直接映射 |
| enron_emails | 0.0003 | 0.6137 | 无映射先验 |
| gutenberg_pg_19 | 0.0397 | 0.6090 | 近似映射 |
| pile_cc | 0.2394 | 0.6151 | 近似映射 |
| ubuntu_irc | 0.0460 | 0.6137 | 无映射先验 |
| europarl | 0.0068 | 0.6137 | 无映射先验 |
| hackernews | 0.0353 | 0.6137 | 无映射先验 |
| pubmed_abstracts | 0.0768 | 0.6137 | 无映射先验 |
| uspto_backgrounds | 0.1450 | 0.6137 | 无映射先验 |

综上，A1–A3 的全量质量信号支持构造具有有限补偿机制的领域质量分，非重叠扩展余集进一步复核了主要冲突结构。基于 A4/A5 建立的 SCM 与 SCI 在 1M、60M 固定检验集上展现出较稳定的配比排序能力；1B 结果则明确了跨尺度应用时需要重点验证的范围，且现有结果尚未支持 SCI 持续优于 SCM。逐域残差模型为验证域层面的风险评估提供了依据。

目前，质量映射已覆盖 17 个配方域中的六个；交叉验证选择保留原始配比，因而无需额外引入质量份额重加权。后续建模可分别使用 $Q_d$、$Q_i$、原始配比及其代理模型，并针对

尚未映射的域、跨尺度绝对损失及待实测的推荐配比，设置相应的验证与不确定性评估环节。图4.9展示风险候选的预测表现，表4.10列出其配比及质量信息。

# 5 问题二的建模与求解

## 5.1 数据口径与建模路线

问题一已经给出样本质量分 $Q^{\text{res}}$、17 域配比代理及风险候选配方。本问的目标是在经典参数量–数据量标度律 [12, 13] 中引入质量和配比，并区分各模块的可识别部分。记 $N$ 为参数个数、$D$ 为训练 token 数，公式中均使用绝对数量。

按证据角色使用附件：B1 的 8 条模型轨迹共 1176 个检查点拟合经典标度律；B2 为半合成族外数据，B3 为插值轨迹，B4 的 57 个跨族点和 B5 的 44 个文献点用于结构迁移检验；B6 的 360 个半合成观测用于选择质量函数，B7 新增 $Q_B \in \{0.5, 0.7\}$ 的 90 个观测作为半合成外层验证；B8 专门用于异常边界敏感性检验。B9 提供大模型真实规模元数据，B10 的损失为估算值，专门用于内部一致性核查。配比项承接问题一的模型和质量映射；A6–A9 的相同配方用于复核跨尺度排序。各配方在两尺度的训练 token 数和独立质量观测尚缺，因此配比尺度指数在本题数据中保留为未识别参数。

## 5.2 规模骨架与跨来源迁移

### 5.2.1 经典标度律估计

以验证集交叉熵为目标，先拟合题设形式

$$L_0(N, D) = E + R(N, D), \qquad R(N, D) = AN^{-\alpha} + BD^{-\beta}. \tag{5.1}$$

其中 $E$ 为渐近损失，$R$ 为可约损失。为保证 $E, A, B > 0$，在对数参数空间对 B1 的预测与观测对数损失使用阈值 $10^{-3}$ 的 Huber 损失，并从 243 组初值搜索。拟合结果为

$$(\widehat{E}, \widehat{A}, \widehat{\alpha}, \widehat{B}, \widehat{\beta}) = (1.6898, 406.3, 0.3400, 409.8, 0.2799). \tag{5.2}$$

B1 内均方根误差（RMSE）为 $1.47 \times 10^{-4}$，决定系数 $R^2 = 0.9999998$。图5.1同时展示观测与预测、残差分布和逐模型留一轨迹误差。B1 内部与式(5.1)高度一致；B2、B4、B5 提供跨模型族的另一级检验。

逐模型留一重估用于核查 B1 内部的参数识别稳定性。八次重估的指数范围及留出轨迹误差为

$$\alpha \in [0.339972, 0.340042], \qquad \beta \in [0.279874, 0.279913],$$
$$\text{RMSE} \in [1.02, 2.13] \times 10^{-4}.$$

这些波动很小，说明 B1 八条轨迹内部识别稳定。由于留出对象仍来自同一 B1 生成体系，跨来源迁移的判断继续依据表5.1所列的 B4、B5 结构检验。

若仅考虑基础训练算力 $C = 6ND$，最优点满足

$$\begin{aligned} \alpha A N^{-\alpha} &= \beta B D^{-\beta}, \\ N^\star &= K_{\text{ND}} (C/6)^{\beta/(\alpha+\beta)}, \\ D^\star &= K_{\text{ND}}^{-1} (C/6)^{\alpha/(\alpha+\beta)}. \end{aligned} \tag{5.3}$$

其中 $K_{\text{ND}} = (\alpha A/\beta B)^{1/(\alpha+\beta)}$。在 $C = 10^{22}$ 次浮点运算（FLOPs）时，经典模型给出 $N^\star = 5.16\text{B}$、$D^\star = 323\text{B}$ token、$L^\star = 2.1386$。图5.2将三个预算的理论最优点叠加到 B1、B4、B5 的规模位置上，并展示 $N^\star \propto C^{0.452}$、$D^\star \propto C^{0.548}$ 的增长趋势。这只是本问的规模参照；问

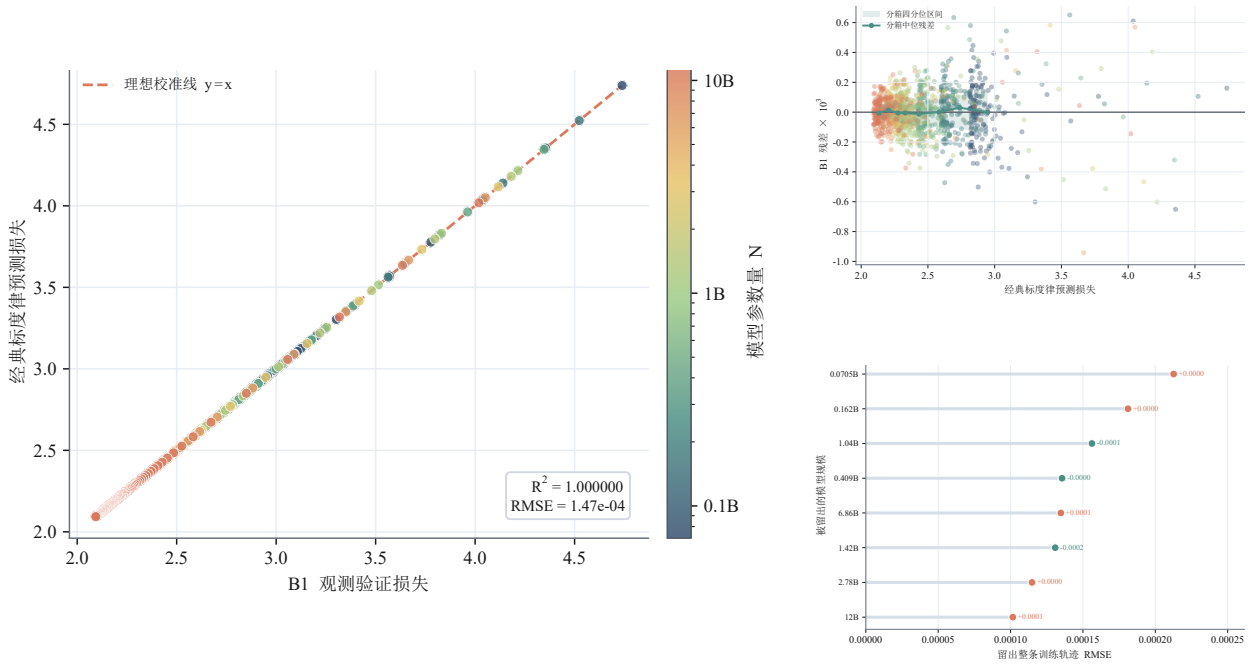



图 5.1　B1 经典标度律的拟合诊断：（a）观测与预测；（b）残差；（c）逐模型留一误差。

题三还须计入质量提升与长上下文的额外成本。

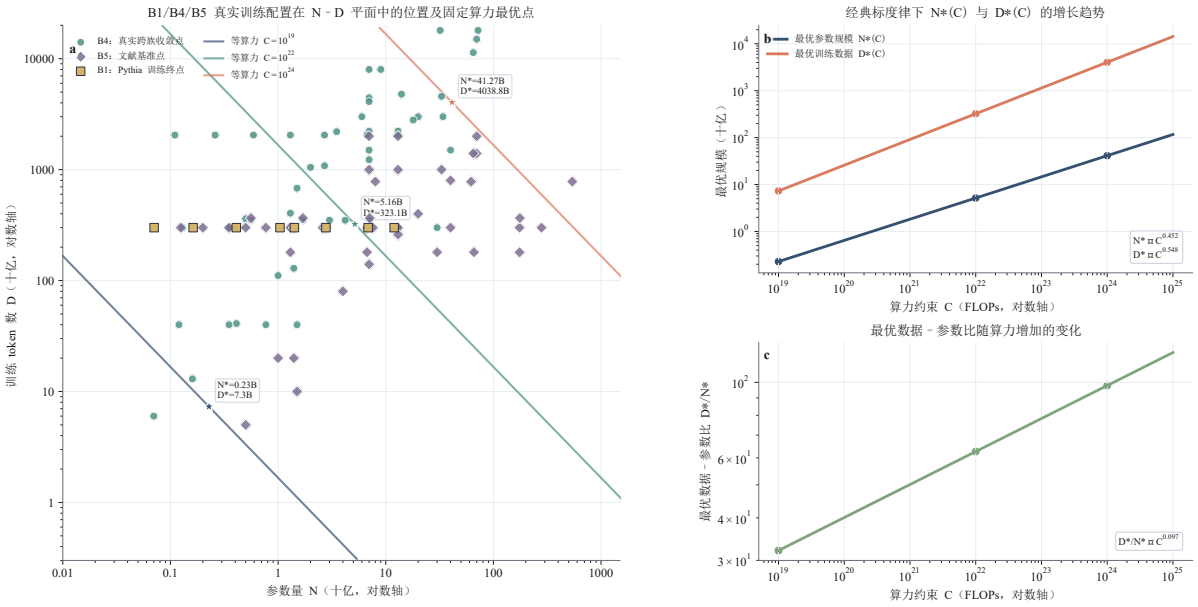



图 5.2　经典标度律下的规模分布与基础训练算力前沿。

### 5.2.2　假设 H1：规模坐标可迁移

不同来源的损失绝对水平受训练和评测设置影响，幂律指数也可随任务及模型条件变化 [14]。本文以来源偏移与尺度乘子将各来源归一到同一尺度。提出可检验的 H1：式(5.1)的 $R(N,D)$ 在来源之间保留稳定的单调规模结构，来源 $f$ 的水平由偏移和正尺度乘子吸收，

$$L_f(N,D) = E_f + s_f R(N,D), \qquad s_f > 0. \tag{5.4}$$

表5.1区分不同数据角色。B2 固定 B1 指数迁移时 $R^2 = 0.9995$；B3 插值点用于轨迹内部的插值核查。B4、B5 在允许来源偏移和乘子后分别达到约 $R^2 = 0.992, 0.940$，对应 Spearman 为 0.983、0.959。图5.3进一步显示，加入来源尺度乘子后两组数据的误差均下降；这支持规模坐标的迁移；各模型族的指数差异由 B4、B5 的分层结果刻画。

表 5.1　规模骨架的分层检验：各行指标对应不同数据角色，不作合并评分

| 数据 | 性质与用途 | 指标 | 结果 |
|---|---|---|---|
| B1 | 主拟合，8 条轨迹 | RMSE | $1.47 \times 10^{-4}$ |
| B2 | 半合成，族外迁移 | $R^2$ / RMSE | 0.9995 / 0.0108 |
| B3 | 插值，轨迹核查 | $R^2$ / RMSE | 0.99996 / 0.0038 |
| B4 | 真实跨族，结构检验 | $R^2$ / Spearman | 0.992 / 0.983 |
| B5 | 文献点，结构检验 | $R^2$ / Spearman | 0.940 / 0.959 |

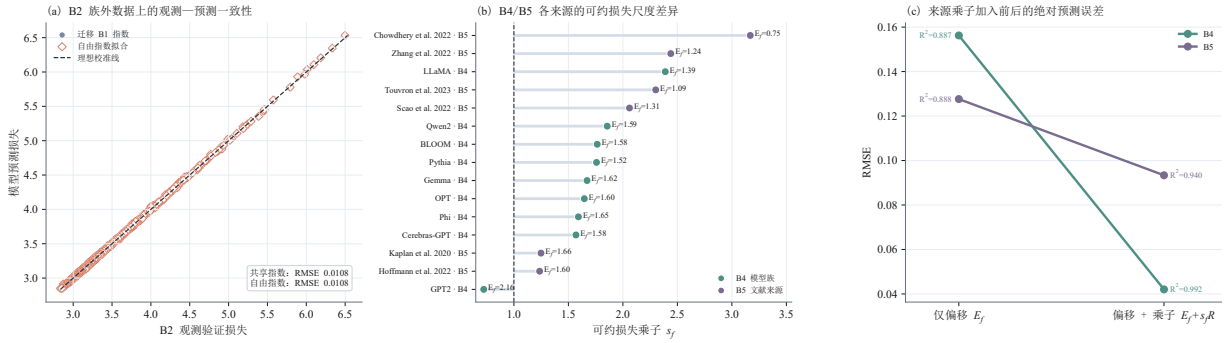



图 5.3　H1 跨来源检验：（a）B2 拟合；（b）B4/B5 来源参数，横轴为 $s_f$、点旁标注为 $E_f$；（c）校准前后误差。

图5.3中的来源偏移 $E_f$ 与可约损失乘子 $s_f$ 在表5.2中分别列示。B4 的 Falcon、Mistral、Yi 分别只有 2、1、2 个规模点，不单独估计 $s_f$，故其乘子列留空。其余来源的 $s_f$ 从 GPT2 的 0.723 到 Chowdhery 等文献点的 3.169，反映损失纵轴口径与任务条件的异质性。来源参数用于检验共享规模坐标的结构形状；不同来源的 $E_f$ 与 $s_f$ 不作为问题三质量或配比效应的替代估计。

表 5.2　B4/B5 来源偏移与可约损失乘子分列估计

| 附件 | 来源 | 规模点数 $n$ | 偏移 $E_f$ | 乘子 $s_f$ |
|---|---|---|---|---|
| B4 | BLOOM | 4 | 1.580 | 1.765 |
| B4 | Cerebras-GPT | 7 | 1.577 | 1.569 |
| B4 | Falcon | 2 | 1.848 | — |
| B4 | GPT2 | 4 | 2.157 | 0.723 |
| B4 | Gemma | 3 | 1.624 | 1.671 |
| B4 | LLaMA | 6 | 1.395 | 2.389 |
| B4 | Mistral | 1 | 1.817 | — |
| B4 | OPT | 7 | 1.602 | 1.646 |
| B4 | Phi | 6 | 1.650 | 1.592 |
| B4 | Pythia | 8 | 1.520 | 1.758 |
| B4 | Qwen2 | 7 | 1.586 | 1.856 |
| B4 | Yi | 2 | 1.718 | — |
| B5 | Chowdhery 等（2022） | 3 | 0.746 | 3.169 |
| B5 | Hoffmann 等（2022） | 16 | 1.600 | 1.236 |
| B5 | Kaplan 等（2020） | 9 | 1.659 | 1.249 |
| B5 | Scao 等（2022） | 4 | 1.310 | 2.060 |
| B5 | Touvron 等（2023） | 7 | 1.095 | 2.301 |
| B5 | Zhang 等（2022） | 5 | 1.242 | 2.439 |

## 5.3　质量与配比的跨附件桥接

### 5.3.1　假设 H3：质量作用于可约损失

在 B6 内比较“只折损有效 token”“附加常数损失”“抬高不可约损失”及作用于整个 $R$ 等六种形式。作用于整个可约损失的形式 $E + R[1 + \kappa(1 - Q_B)^{\gamma}]$ 取得最低赤池信息准则（AIC）值；自由曲率参数为 $\widehat{\gamma} = 0.9935$，按 $(N, D)$ 单元聚类重抽样的 95% 区间为 $[0.9248, 1.0788]$。区间包含 1，故固定最简质量乘子

$$\psi_Q(Q_B) = 1 + \kappa(1 - Q_B), \qquad \widehat{\kappa} = 0.4597. \tag{5.5}$$

$\kappa$ 的聚类 Bootstrap 95% 区间为 $[0.4378, 0.4873]$。形式选择、估计与重抽样均只使用 B6。图5.4展示六种候选形式的相对 AIC，并将 B8 中与 B6 相反的质量方向标为边界敏感性证据；B8 未进入估计。

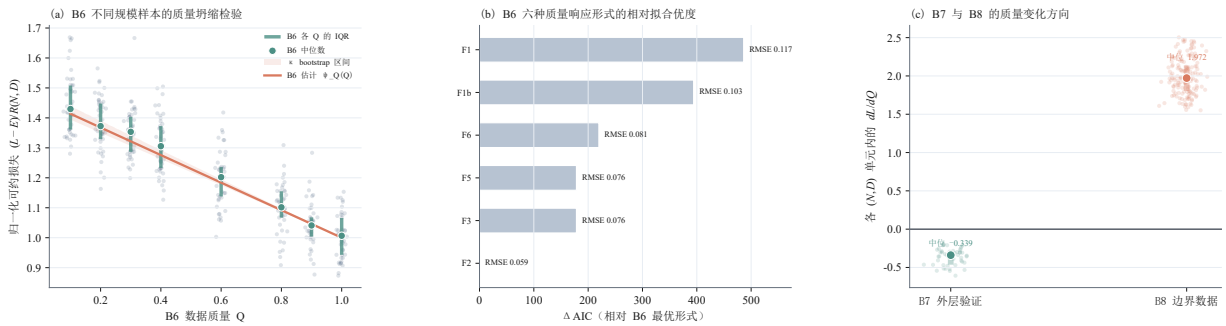



图 5.4　H3 质量项的识别与边界：（a）B6 质量响应；（b）候选形式相对 AIC；（c）B7/B8 方向比较。

表5.3给出 B6 内部拟合的六种候选形式。整个可约损失乘子 F2 的 RMSE 为 0.0594；相

对于它，下一组候选的 ΔAIC 至少为 178.45。该比较用于选择质量项作用位置，不能替代 B7 的新质量等级检验。F2 中自由估计的曲率接近 1，正文最终采用式(5.5)的固定线性质量乘子，并重新估计 $\kappa$。

表 5.3　B6 内部拟合的六种质量作用形式

| 候选形式 | RMSE | ΔAIC |
|---|---|---|
| F2：整个可约损失乘子 | 0.0594 | 0 |
| F3：可约损失附加项 | 0.0761 | 178.45 |
| F5：不可约项乘子 | 0.0761 | 178.45 |
| F6：参数轴与数据轴双有效量 | 0.0806 | 219.75 |
| F1b：指数型有效 token | 0.1029 | 394.19 |
| F1：幂型有效 token | 0.1170 | 486.27 |

在完全隔离的 B7 新质量水平上，式(5.5)的预测 RMSE 为 0.04671、$R^2 = 0.9789$。图5.5分别显示观测与预测及两个新质量等级的残差；因此 H3 在题目提供的半合成质量机制上获得外层检验；真实语料质量干预的因果效应需由实测干预确认。

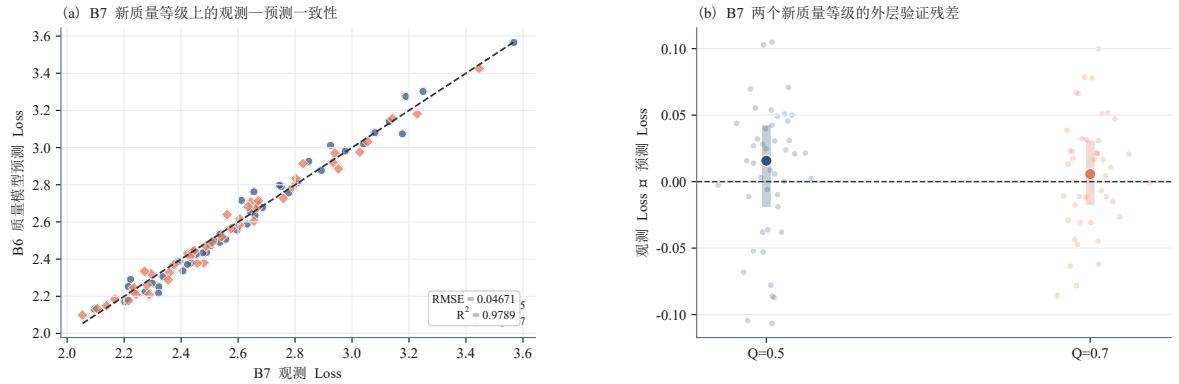



图 5.5　B7 新质量等级的半合成验证：（a）预测与观测；（b）分质量等级残差。

问题一的 $Q_A \equiv Q^{\text{res}}$ 与 B6/B7 的 $Q_B$ 来自两条不同的测量过程。为连接两种坐标，令

$$Q_B = T(Q_A; c_Q) = \text{clip}\{1 - c_Q(1 - Q_A),\, 0,\, 1\}. \tag{5.6}$$

中心情景取 $c_Q = 1$，另以 0.75、1.25 做敏感性分析。现有附件缺少共同标定实验，故 $c_Q$ 保留为情景参数；$Q_A = 1$ 对应 $Q_B = 1$ 是坐标锚点约定。问题一风险配方的映射均值为 $Q_{0,A}(\mathbf{p}_{\text{risk}}) = 0.6223$，其中 11 个无直接对应质量域采用共同先验，因此该均值含先验成分。B6 所识别的 $\psi_Q^{\text{abs}}(Q_B) = 1 + \kappa(1 - Q_B)$ 只描述该半合成质量坐标内的绝对响应。进入跨附件综合模型时，以每个配比自身的质量起点归一化：

$$Q_{0,A}(\mathbf{p}) = \sum_i p_i Q_i, \qquad \psi_Q^{\text{rel}}(Q_A, \mathbf{p}; c_Q) = \frac{\psi_Q^{\text{abs}}[T(Q_A; c_Q)]}{\psi_Q^{\text{abs}}[T(Q_{0,A}(\mathbf{p}); c_Q)]}. \tag{5.7}$$

当 $Q_A = Q_{0,A}(\mathbf{p})$ 时，此因子恒为 1；这样把配比结构桥中的基线差异与追加质量治理分开。归一化是建模约定，尚无联合干预实验单独检验。

### 5.3.2 假设 H2：配比排序迁移及幅度识别边界

沿用问题一的可解析对数结构桥

$$L_{\text{mix}}(\mathbf{p}) = c_0 + \sum_{i=1}^{17} a_i \log(p_i + \varepsilon),$$
$$\psi_{p,0}(\mathbf{p}) = \frac{L_{\text{mix}}(\mathbf{p})}{L_{\text{mix}}(\mathbf{p}_{\text{ref}})}. \tag{5.8}$$

这里 $\varepsilon = 0.001$，$\mathbf{p}_{\text{ref}}$ 专门用于使 $\psi_{p,0}(\mathbf{p}_{\text{ref}}) = 1$；问题一的风险候选 $\mathbf{p}_{\text{risk}}$ 尚无新配方的实测损失。H2a 检验排序结构：A6–A9 有 256 个 1M 与 60M 完全相同的配方，其平均损失 Spearman 为 0.9658，Pearson 为 0.9671。1B 与前两档没有相同配方，因此不参加同配方尺度检验。

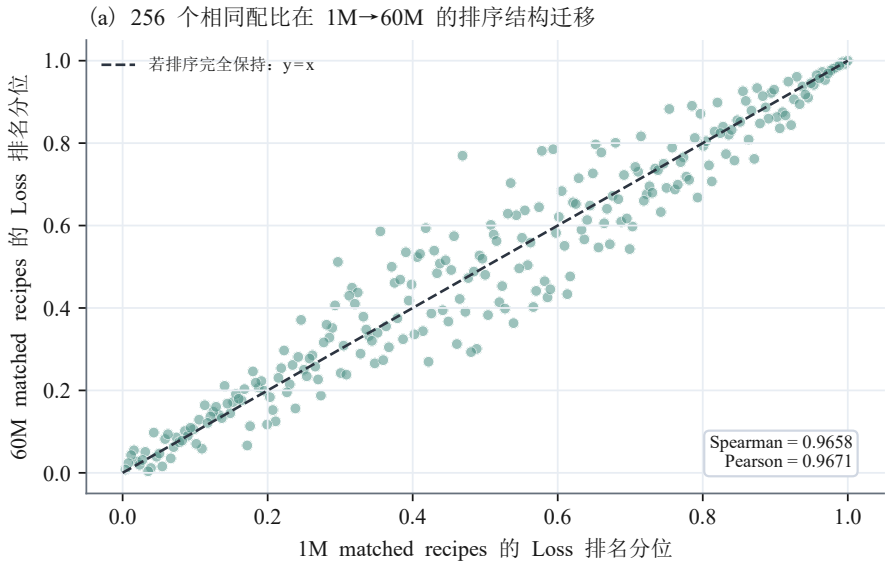



图 5.6　相同配方在 1M 与 60M 尺度下的平均损失秩位。

原始平均损失在两个尺度之间的中心化配对斜率为 0.7623，$R^2 = 0.9353$。这一斜率同时包含参数量、训练 token 数、可能的质量差异以及配比效应，属于混合诊断量；配比响应幅度比需按下述条件单独识别。若要单独识别幅度指数，至少需要每个配方和尺度的 $D_{s,i}$ 与独立测得的 $Q_{A,s,i}$，先构造

$$y_{s,i}^{\text{mix}} = \frac{L_{s,i} - E}{R(N_s, D_{s,i})\, \psi_Q^{\text{abs}}[T(Q_{A,s,i}; c_Q)]} - 1, \qquad z_i = \psi_{p,0}(\mathbf{p}_i) - 1, \tag{5.9}$$

再分别估计 $y^{\text{mix}}$ 对 $z_i$ 的两尺度响应斜率 $b_{1\text{M}}, b_{60\text{M}}$；仅当两者可识别且为正时，定义 $s_{60} = b_{60\text{M}}/b_{1\text{M}}$ 和 $\gamma_p = -\log s_{60}/\log 60$。当前 A6–A9 缺少上述完整元数据。配方加权质量 $\sum_i p_i Q_i$ 由配比构造，本文将其作为配比属性；独立质量观测需另行测量。新版计算接口明确记录 gamma_p_identified=false，$s_{60}$ 与 $\gamma_p$ 及其区间均留空；原始斜率 0.7623 专门用于混合效应诊断。

为计算条件情景，定义

$$\psi_p(\mathbf{p}; N) = 1 + g(N; \gamma_p, \mathcal{S})[\psi_{p,0}(\mathbf{p}) - 1]. \tag{5.10}$$

主情景取无衰减 $g \equiv 1$，相当于结构零假设 $\gamma_p = 0$；$\gamma_p = 0.05, 0.10$ 搭配持续幂律 $g = (N/10^6)^{-\gamma_p}$ 或在 60M 后冻结的形式，仅为人为敏感性设定。当前数据支持同配方损失排序近似保持；幅度随规模变化的形式由预设情景覆盖，后续需独立识别。

## 5.4 广义标度律及资源替代

### 5.4.1 模块化模型与识别边界

附件中没有同时独立改变 $N, D, Q_A, \mathbf{p}$ 的联合实验，特别是缺少 $Q_A \times \mathbf{p}$ 的干预。为得到可计算模型，采用乘法可分离的跨附件闭合假设：

$$\begin{aligned} L &= E + R(N, D)\, \Phi(N, Q_A, \mathbf{p}), \\ \Phi(N, Q_A, \mathbf{p}) &= \psi_Q^{\text{rel}}(Q_A, \mathbf{p}; c_Q)\, \psi_p(\mathbf{p}; N). \end{aligned} \tag{5.11}$$

本文将式(5.11)记为 SAED（本文自定义的模块化广义标度律代号）。$E, A, B, \alpha, \beta$ 来自 B1，$\kappa$ 来自 B6 并由 B7 的新质量等级检验；$\psi_{p,0}$ 来自问题一，H2a 支持 1M–60M 的同配方排序近似保持。$c_Q$、可分离性及配比尺度函数的具体形式仍是跨附件假设，$\gamma_p$ 未被当前数据识别。取 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 且 $Q_A = Q_{0,A}(\mathbf{p}_{\text{ref}})$ 时，模型退化为经典律；$Q_A = 1$ 并不是本模型的自动基线。B7 为质量模块提供单独的外层检验；完整四维模型的联合预测精度仍需联合实验评估。

### 5.4.2 边际效用、弹性与等效资源

记 $\Phi = \psi_Q^{\text{rel}} \psi_p$。对固定配比、质量桥未截断的内部点，三个单变量边际效应为

$$\begin{aligned} \frac{\partial L}{\partial N} &= -\alpha A N^{-\alpha-1} \Phi + R\Phi\, \frac{\partial \log \psi_p}{\partial N}, \\ \frac{\partial L}{\partial D} &= -\frac{\beta B D^{-\beta}}{D} \Phi, \\ \frac{\partial L}{\partial Q_A} &= -\frac{\kappa c_Q R \psi_p}{1 + \kappa\{1 - T[Q_{0,A}(\mathbf{p}); c_Q]\}}. \end{aligned} \tag{5.12}$$

持续幂律情景下，$\partial_N \log \psi_p = -\gamma_p g(N)[\psi_{p,0}(\mathbf{p}) - 1]/(N\psi_p)$；无衰减主情景该项为零，60M 后冻结情景在冻结区间亦为零。若坐标桥被截断，$Q_A$ 的局部导数取零。定义损失弹性 $\epsilon_x = (x/L)\partial L/\partial x$。在 $\mathbf{p}_{\text{risk}}$、$Q_A = Q_{0,A} = 0.6223$ 和 Pythia-1B[15] 的 $N = 1.04$B、$D = 300$B 参考点，无衰减情景给出 $(\epsilon_N, \epsilon_D, \epsilon_Q) = (-0.0532, -0.0315, -0.0656)$。三项弹性比较的是该点各变量的条件损失响应；投入成本不同，资源决策还需由问题三的预算模型求解。

为帮助解释质量和配比的合成作用，沿两个单独的规模轴分别定义

$$N_{\text{eq}}^{(N)} = N\Phi^{-1/\alpha}, \qquad D_{\text{eq}}^{(D)} = D\Phi^{-1/\beta}. \tag{5.13}$$

这两个等效量沿参数轴和数据轴分别换算可约损失项，用于比较条件模型中的单轴替代关系。实际资源组合由联合预算约束另行确定。

图5.7展示不同桥接情景如何把问题一质量坐标映射为数据轴等效倍率；三条曲线的差异来自预设 $c_Q$，并非三组独立质量实验。图5.8在四个参考规模点上分开报告参数轴与数据轴的等效量。这两个轴向换算各自保持相应单轴可约损失项，因而不能把两个比率相乘作为联合算力收益。

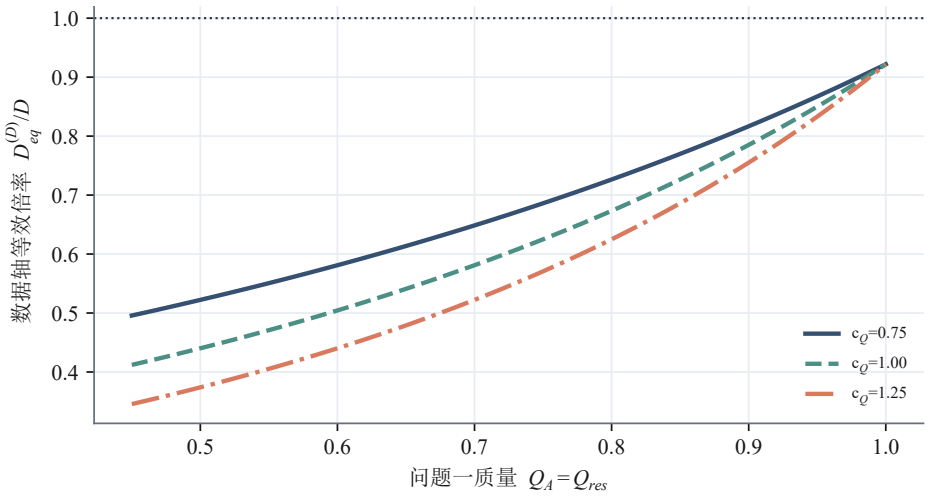



图 5.7　问题一质量坐标到数据轴等效倍率的条件映射。$c_Q = 0.75, 1, 1.25$ 为桥接情景，横轴质量分来自问题一。

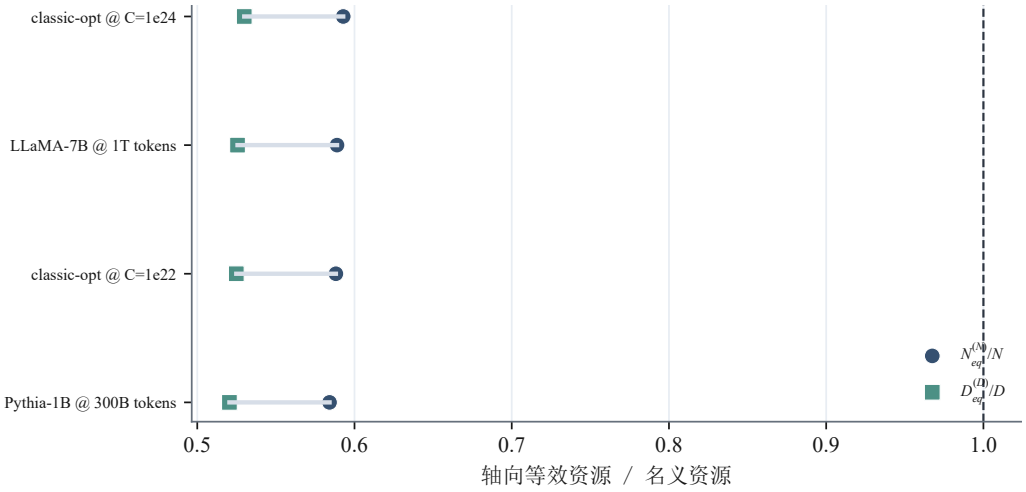



图 5.8　四个参考配置的参数轴与数据轴等效资源比。两类标记对应式(5.13)的独立单轴换算，虚线为名义资源比 1。

图5.9把 $N, D, Q_A$ 的局部损失弹性放在相同损失尺度上比较，显示在参考点附近质量坐标的局部影响可以与规模轴影响同量级，但这仍未计入治理成本。图5.10进一步把质量提高 0.1 时的高质量参数倍率，与低质量模型追平时的反向倍率并列。两组数值各自解不同的等损失方程，分别回答“提高质量后可用多少参数”和“降低质量后需补多少参数”。

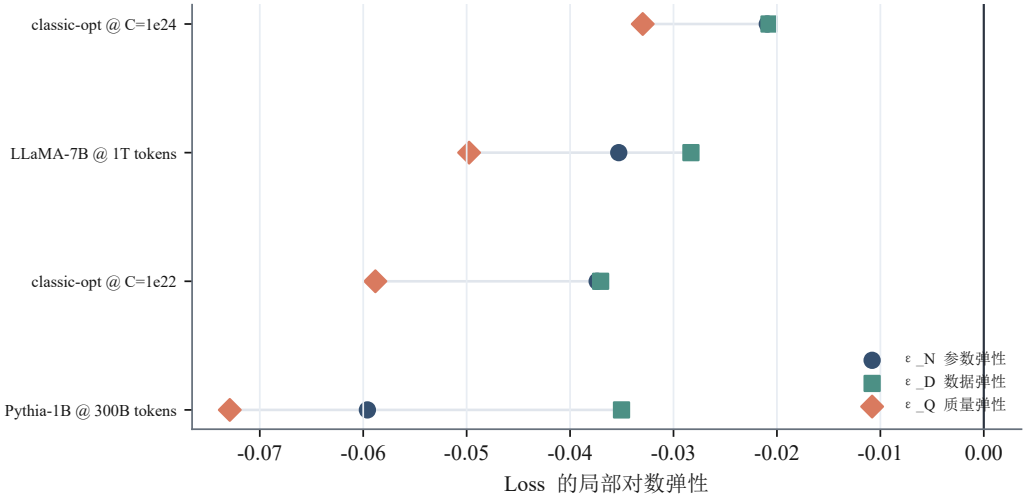



图 5.9　四个参考配置中参数量、训练 token 数和质量的局部相对损失弹性。各点的 $N, D, Q_A$ 不同，弹性仅描述各自参考点附近的模型响应。

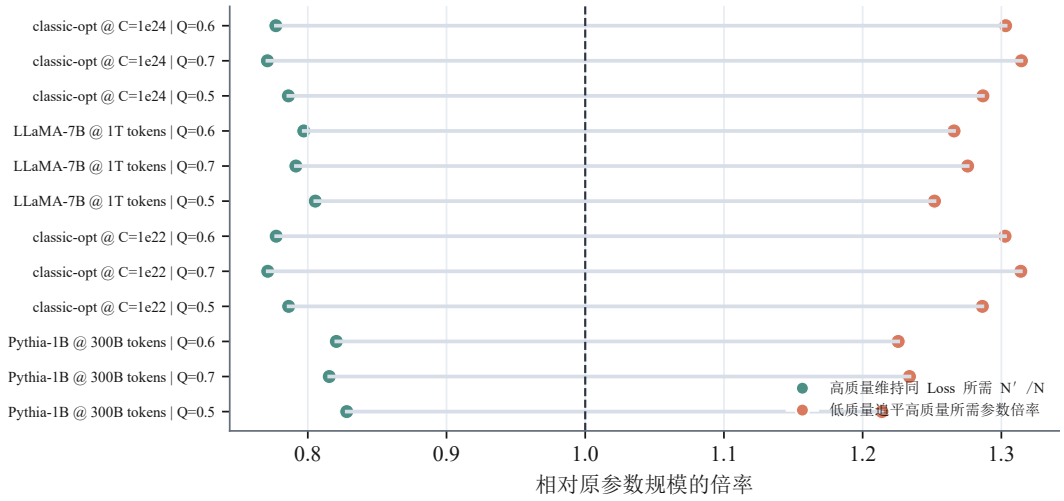



图 5.10　质量提高 0.1 的参数替代倍率及低质量模型的反向补偿倍率。点为不同参考配置下的模型内等损失解，不代表实际训练的算力节省。

### 5.4.3　领域再分配与质量–参数替代

17 域配比位于 $\sum_i p_i = 1$ 的单纯形，增加某一域份额必然减少其余域份额。从域 $k$ 向域 $i$ 转移微小份额 $\delta$。新版结果矩阵采用随配比移动的质量起点 $Q_A(\delta) = Q_{0,A}[\mathbf{p} + \delta(\mathbf{e}_i - \mathbf{e}_k)]$；沿此路径 $\psi_Q^{\mathrm{rel}} \equiv 1$，因此局部方向导数为

$$\begin{aligned}\Delta_{i\leftarrow k} &= \frac{\mathrm{d}L[N, D, Q_A(\delta), \mathbf{p} + \delta(\mathbf{e}_i - \mathbf{e}_k)]}{\mathrm{d}\delta}\bigg|_{\delta=0} \\ &= \frac{R(N,D)g(N;\gamma_p,\mathcal{S})}{L_{\mathrm{mix}}(\mathbf{p}_{\mathrm{ref}})}\left[\frac{a_i}{p_i+\varepsilon} - \frac{a_k}{p_k+\varepsilon}\right].\end{aligned} \tag{5.14}$$

$\Delta_{i\leftarrow k} < 0$ 表示沿所定义路径的模型预测损失下降。方向矩阵在均匀配比附近计算。式(5.14)给出移动质量起点的局部效应，不对应固定 $Q_A$ 下的总配比效应。

问题一的 SCI 稳定入选交互来自 github 与 stackexchange 两个域。该代理曲率刻画预测曲面的局部结构，跨域因果互补或替代仍需配对干预实验识别。

固定 $D, \mathbf{p}$，把质量从 $Q_A$ 提高到 $Q'_A > Q_A$，令 $F(N') = L(N', D, Q'_A, \mathbf{p}) - L(N, D, Q_A, \mathbf{p})$。在主情景 $\gamma_p = 0$、$\psi_{p,0}(\mathbf{p}) \geq 1$ 及正的质量系数下，目标随 $N'$ 单调下降，其 $N' \to \infty$ 极限为

$$L_\infty = E + BD^{-\beta}\psi_Q^{\mathrm{rel}}(Q'_A, \mathbf{p}; c_Q)\psi_{p,0}(\mathbf{p}). \tag{5.15}$$

若原始损失严格高于 $L_\infty$，则存在唯一有限的同损失参数解。持续衰减情景在 $\gamma_p > 0$ 时改取极限配比乘子 1；60M 后冻结情景则取冻结值，各情景须分别核对单调性。以 Pythia-1B、$D = 300$B、风险配比为例，$Q_A : 0.5 \to 0.6$ 时维持原损失的高质量参数倍率为 0.8269；反向让低质量模型追平原高质量模型需 1.2158 倍参数。这是两个目标方程，不能直接互取倒数，也不是实测节省的训练算力。

### 5.5 验证、算力前沿与外推边界

表5.4区分已识别数值、建模假设与数据尚不足以识别的参数。B7 的 RMSE 衡量半合成质量预测误差，同配方 Spearman 衡量配比排序，本文分别报告两种任务的指标。H2b 的幅度参数及其区间留空；原始损失斜率作为混合诊断量报告。

表 5.4　SAED 各模块的参数、证据与识别边界

| 模块 | 估计或检验结果 | 证据边界 |
|---|---|---|
| 经典骨架 | $\alpha = 0.3400,\ \beta = 0.2799$ | B1 内拟合 |
| 质量乘子 | $\kappa = 0.4597$，区间 $[0.4378, 0.4873]$ | B6 半合成聚类重抽样 |
| 新质量验证 | RMSE $= 0.04671$，$R^2 = 0.9789$ | B7 新 $Q_B$，半合成 |
| 配比排序 | Spearman $= 0.9658$ | 1M–60M 同配方 |
| 配比幅度 | $s_{60}$、$\gamma_p$ 未识别 | 缺 $D_{s,i}$ 与独立 $Q_{A,s,i}$ |
| 原始 Loss 斜率 | 0.7623（仅诊断） | 混合规模与质量差异 |
| 跨附件桥 | $c_Q = 1$；$0.75, 1.25$ 敏感性 | 设定，未独立标定 |

在固定配比下，以 $C = 6ND$ 代入式(5.11)并进行一维数值优化。对于给定 $\mathbf{p}$，$\psi_Q^{\mathrm{rel}}$ 是与 $N, D$ 无关的正乘子，因此改变 $Q_A$ 只改变最优预测损失，不单独改变 $N^\star : D^\star$。主情景 $\gamma_p = 0$ 时 $\psi_p$ 同样与规模无关，最优分配比与经典律相同。在 $C = 10^{22}$ FLOPs、风险配比与自身基线质量 $Q_A = Q_{0,A} = 0.6223$ 下，得到 $N^\star = 5.159$B、$D^\star = 323.1$B、$L^\star = 2.1552$；人为取持续幂律 $\gamma_p = 0.05$ 则给出 5.223B、319.1B、2.1494。两行差异是尺度设定的模型响应，不是从数据测得的衰减效应。在基线质量点 $\psi_Q^{\mathrm{rel}} = 1$，单独改变 $\kappa, c_Q$ 对此点的 $N, D, L$ 无影响，偏离基线时则仍有影响。此处只讨论基础训练算力前沿，不代替问题三的完整成本优化。

大规模外推采用分层敏感性分析。B4 按模型族、B5 按文献来源重抽样指数，在回代 B1 时以 $E, A, B \geq 0$ 重新标定；本次来源重估中心指数约为 $\alpha = 0.283, \beta = 0.252$，其抽样分位范围分别约为 $[0.199, 0.293]$、$[0.165, 0.281]$。B6 的 $\kappa$ 有数据驱动的重抽样范围，而 $c_Q \in \{0.75, 1, 1.25\}$、$\gamma_p \in \{0, 0.05, 0.10\}$ 及持续衰减或 60M 后冻结形式是人为设定。混合抽样得到的 P05/P50/P95 和情景包络构成条件敏感性带，其中既有数据重抽样，也有人为设置的桥接和尺度情景；其统计覆盖率及百亿参数尺度上的预测精度仍待独立实验检验。B10 的估算 Loss 与经典律 RMSE 为 0.0011、Spearman 为 1.000，专门核查其内部生成口径的一致性。

图5.11把经典骨架与 SAED 的中心预测和条件敏感性带放到同一参数轴。参数超过百

亿后，两条中心曲线保持接近，但两组带宽明显扩大。这一带宽混合了跨族指数重抽样与桥接情景，表达的是输入设定改变后的模型响应范围。图5.12则隔离配比尺度设定对 $N^\star, D^\star$ 分配的影响；在展示的预算区间内，两条相对变化曲线幅度较小，名义资源配置仍由规模骨架主导。

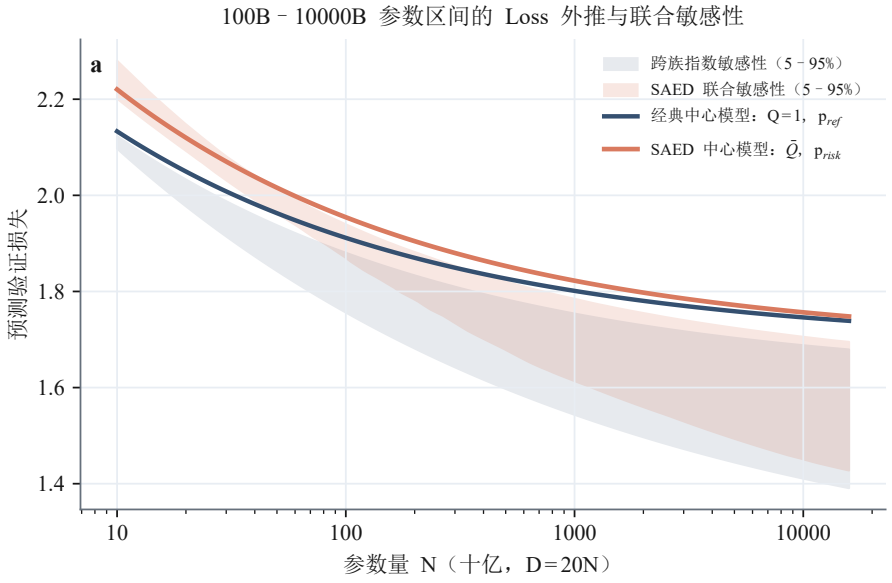



图 5.11　百亿参数以上经典骨架与 SAED 的预测损失中心曲线和条件敏感性带。阴影为混合重抽样及人工桥接情景的 5–95% 分位，不解释为独立实测置信区间。

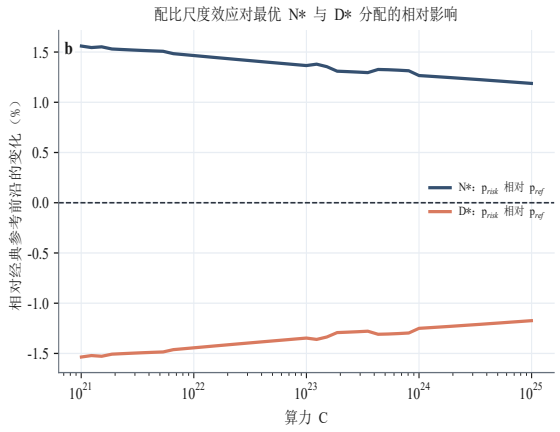



图 5.12　配比尺度设定对最优参数量 $N^\star$ 和训练 token 数 $D^\star$ 的相对影响。比较对象为图中标注的参考配比，曲线是条件模型计算结果。

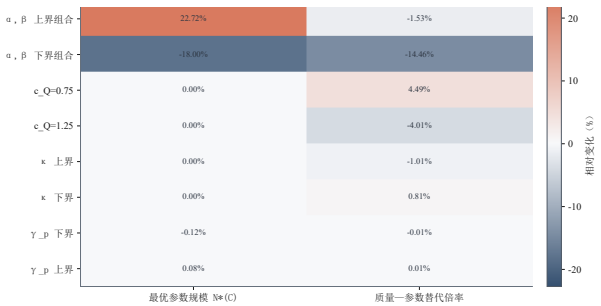



图 5.13　$C = 10^{22}$ FLOPs 下关键输入扰动对最优参数量与质量—参数替代倍率的相对影响。指数端点来自跨族重抽样；桥接系数与配比尺度指数为预设情景。

在 $Q_A = Q_{0,A}(\mathbf{p})$ 的基线预测点，$\psi_Q^{\mathrm{rel}} = 1$ 使 $\kappa, c_Q$ 的影响代数抵消；这体现了相对质量因子的基线归一化性质。质量提高 0.1 时的替代倍率仍随 $\kappa, c_Q$ 改变。问题一 A12–A15 的 10B、70B 损失也是幂律外推值；63 个相同训练配比上，它们与 1M 实测损失的排序相关分别为 $-0.739$、$-0.814$，说明外推规则间可能给出不同的配比排序，但不能据此认定任何规则已被新训练验证。

图5.13逐项改变当前模型的关键输入，检验最优 $N^\star$ 与质量—参数替代倍率。$C = 10^{22}$ FLOPs 时，跨族指数上界与下界组合使 $N^\star$ 分别变化 $+22.72\%$ 和 $-18.00\%$；在配比自身的质量基线，改变 $c_Q$ 或 $\kappa$ 对 $N^\star$ 的变化为零，这正是相对质量归一化的代数结果。离开基线进行质量替代时，$c_Q = 0.75$ 与 $1.25$ 对替代倍率分别带来 $+4.49\%$ 与 $-4.01\%$ 的变化。因此，资源前沿与质量替代的主要不确定性来源并不相同，后续优化需保留指数和桥接参数的情景身份。

因此问题三只接收：B1 经典参数、B6/B7 质量证据、相对质量基线、问题一配比结构与风险配比、H2a 的匹配排序、以及 gamma_p_identified=false 标志。问题三的名义配比尺度形式应取无衰减；正指数仅用作结构敏感性。新的大尺度同配方训练及独立质量测量，才可能进一步检验幅度迁移和四维组合模型。

# 6 问题三的建模与求解

## 6.1 输入口径与有限候选配比

本问在总算力预算 $C$ 和给定上下文长度 $L_{\text{ctx}}$ 下，比较问题一正式导出的有限配比候选，并分别优化参数量 $N$、训练 token 数 $D$ 和追加治理后的质量 $Q_A$。问题二的 SAED 名义参数为 $(E, A, \alpha, B, \beta) = (1.68984, 406.298, 0.339987, 409.784, 0.279893)$，$\kappa = 0.459661$。这些参数直接进入条件预测，不根据本问最优配置反向重估。公式中 $N, D$ 使用绝对数量，表格才换算为十亿（B）。

问题二的识别核查给出 gamma_p_identified=false。名义配比项因此采用无衰减结构零假设 $\psi_p(\mathbf{p}, N) = \psi_{p,0}(\mathbf{p})$。$\gamma_p = 0.05, 0.10$ 及持续幂律、60M 后冻结形式为预设的敏感性情景。表6.1列出实际进入选择的三个配比及用于结构归一化的参考点。$\mathbf{p}_{\text{measured}}$ 的“实测”身份只来自问题一的 1M 训练配比，其目标规模损失仍须模型外推。两个新推荐配比也没有目标规模新训练观测。

表 6.1　问题三的配比候选与证据身份

| 配比 | 来源身份 | $Q_{0,A}(\mathbf{p})$ | $\psi_{p,0}(\mathbf{p})$ | 进入选择 |
|---|---|---|---|---|
| $\mathbf{p}_{\text{risk}}$ | 风险控制代理推荐 | 0.622345 | 1.03702 | 是 |
| $\mathbf{p}_{\text{safe}}$ | 训练配比凸包内代理推荐 | 0.617122 | 1.02144 | 是 |
| $\mathbf{p}_{\text{measured}}$ | 1M 训练集实测最佳 | 0.605803 | 1.06696 | 是 |
| $\mathbf{p}_{\text{ref}}$ | 结构归一化理论参考 | 0.618067 | 1.00000 | 否 |

于是 $\mathcal{P}_{\text{exec}} = \{\mathbf{p}_{\text{risk}}, \mathbf{p}_{\text{safe}}, \mathbf{p}_{\text{measured}}\}$。这里“可执行”表示配比向量、来源身份及问题一接口经过一致性检查。目标尺度训练效果仍待实测。$\mathbf{p}_{\text{ref}}$ 专门用作结构归一化参考，不参加最优方案选择。

附件 C7 的 45 个模型给出可行上下文长度 $\{2048, 4096, 8192, 32768, 131072\}$。默认 4096。

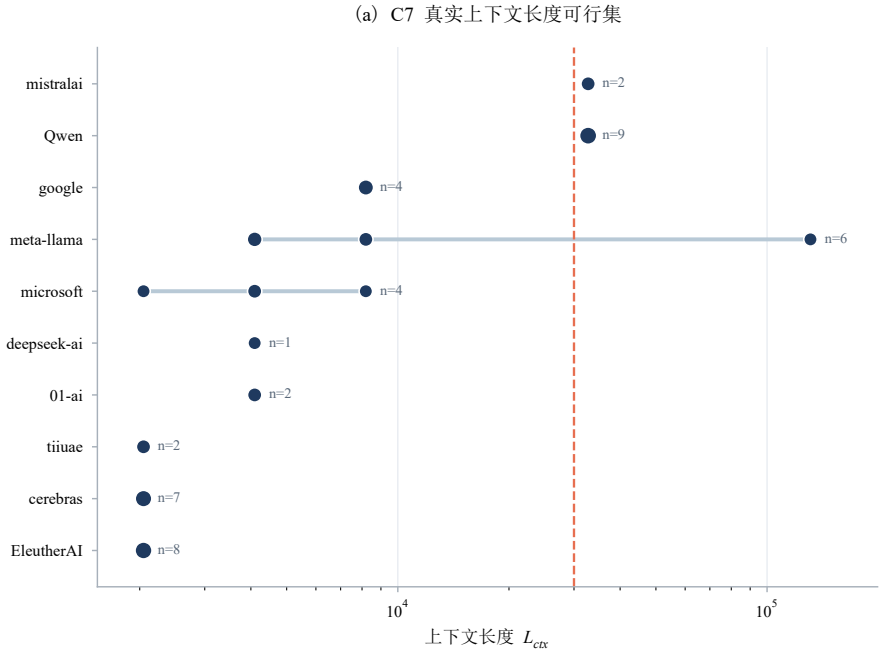



图 6.1　附件 C7 各模型族的上下文长度观测范围与计算成本阈值。

按本问设定的注意力成本系数 $\eta_{\text{att}} = 2 \times 10^{-4}$，

$$\frac{C_{\text{attn}}}{C_{\text{train}}} = \frac{\eta_{\text{att}} L_{\text{ctx}}}{6}, \qquad L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta_{\text{att}}} = 30000. \tag{6.1}$$

30000 标记两类开销相等的诊断线，C7 的可行长度仍取前述五个观测值。$\eta_{\text{att}}$ 与问题一的质量份额重加权指数 $\eta$ 含义不同。

## 6.2　相对质量治理与资源优化

问题一的质量分构成每个配比的治理起点 $Q_{0,A}(\mathbf{p}) = \sum_i p_i Q_i$。其中 11 个配方域没有直接对应的质量域，$Q_i$ 使用共同先验回退，故 $Q_{0,A}$ 是操作性起点而非 17 个域全部实测的质量。问题二的 B6/B7 则估计在其半合成质量坐标内改变质量时的响应。为避免把配比自身的基线质量差异重复解释为治理收益，定义

$$\begin{aligned} T(Q_A; c_Q) &= \text{clip}[1 - c_Q(1 - Q_A), 0, 1], \\ \psi_Q^{\text{abs}}(Q_A) &= 1 + \kappa\{1 - T(Q_A; c_Q)\}, \\ \widetilde{\psi}_Q(Q_A; \mathbf{p}) &= \frac{\psi_Q^{\text{abs}}(Q_A)}{\psi_Q^{\text{abs}}[Q_{0,A}(\mathbf{p})]}, \\ \widetilde{\psi}_Q[Q_{0,A}(\mathbf{p}); \mathbf{p}] &= 1. \end{aligned} \tag{6.2}$$

名义设 $c_Q = 1$，$0.75, 1.25$ 仅为桥接情景。式(6.2)与问题二的相对质量口径一致。质量中性等于 1 是代数与代码的一致性检查，不是联合训练实验对该桥接假设的验证。

题目给出基础训练与质量成本。本问另以 $\eta_{\text{att}} N D L_{\text{ctx}}$ 表示长文本注意力成本。对三种成本函数

$$g_{\exp}(Q) = 10^7 e^{6Q}, \qquad g_{\text{pow}}(Q) = 5 \times 10^9 Q^4, \qquad g_{\log}(Q) = 2 \times 10^9 \log(1 + 10Q), \tag{6.3}$$

只计追加治理成本 $\Delta g = g(Q_A) - g[Q_{0,A}(\mathbf{p})] \geq 0$，从而得到有限候选优化问题

$$\begin{aligned} \min_{\mathbf{p},N,D,Q_A} \quad & L = E + (AN^{-\alpha} + BD^{-\beta})\widetilde{\psi}_Q(Q_A;\mathbf{p})\psi_p(\mathbf{p},N), \\ \text{s.t.} \quad & \mathbf{p} \in \mathcal{P}_{\text{exec}}, \quad N, D > 0, \quad Q_{0,A}(\mathbf{p}) \leq Q_A \leq 1, \\ & D[(6 + \eta_{\text{att}} L_{\text{ctx}})N + \Delta g] \leq C. \end{aligned} \tag{6.4}$$

三个配比分别求得条件数值解，再以预测损失选取最优候选。优化范围是 $\mathcal{P}_{\text{exec}}$ 与给定资源约束。$\mathbf{p}_{\text{ref}}$ 另行计算作为模型内归一化参考，其与所选损失的差值用于量化当前代理模型下的参考差距。

### 6.3 数值求解与体制判据

固定 $Q_A, \mathbf{p}$ 时，增加 $D$ 降低模型损失，最优解用满预算。令 $c_N = 6 + \eta_{\text{att}} L_{\text{ctx}}$、$H = c_N N + \Delta g$，则 $D = C/H$。对固定质量的 $N$ 方向，在有限 $\log N$ 搜索网格上寻找导数变号的驻点，并比较边界。对质量方向同时比较两端点与扫描发现的内部驻点。若 $\psi_p$ 随 $N$ 变化，内部一阶条件为

$$0 = \psi_p \left[ -\alpha A N^{-\alpha} + \beta B D^{-\beta} \frac{c_N N}{H} \right] + N R(N,D) \frac{\partial \psi_p}{\partial N}. \tag{6.5}$$

名义无衰减情景中最后一项为零。质量方向的收益成本比定义为

$$\rho_Q = \frac{-\widetilde{\psi}'_Q(Q_A) R(N,D) H}{\widetilde{\psi}_Q(Q_A)\, \beta B D^{-\beta} g'(Q_A)}. \tag{6.6}$$

用 R0、R1、R2 分别表示 $Q_A = Q_{0,A}$、$Q_{0,A} < Q_A < 1$、$Q_A = 1$。数值证书核查候选解的预算残差和一阶条件。搜索与比较覆盖已发现的驻点及边界。连续资源空间的解析全局最优性需要额外证明。

连续预算扫描遇到状态变化时进一步二分并尝试求解 KKT 边界或局部分支损失等值根。只有通过指定条件根和数值最优包络检查的点称为“分支交叉”。仅由状态二分给出的位置仍记为“数值状态边界”，不推断具体转移机制。

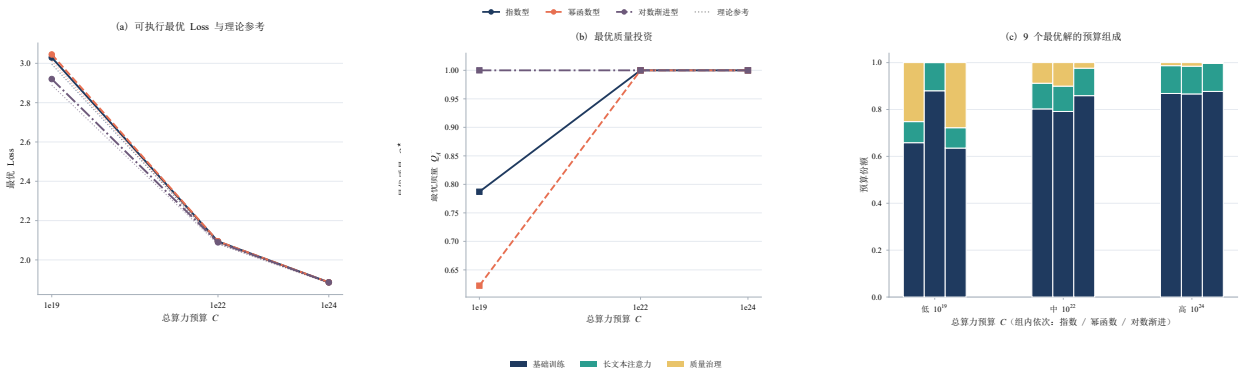
### 6.4 三档预算的名义配置

默认 $L_{\text{ctx}} = 4096$，预算取 $10^{19}, 10^{22}, 10^{24}$ FLOPs。表6.2报告九个条件数值解。九行均选 $\mathbf{p}_{\text{safe}}$。该结论对应三候选、名义无衰减和所设成本函数的模型预测。目标尺度的新配比训练尚待实施。

图6.2a至图6.2c把表6.2的九个数值解拆成损失、质量和预算组成三个视角。三种成本下，预算从 $10^{19}$ 增至 $10^{24}$ FLOPs，最优预测损失均随之下降；高预算端的三条曲线逐渐靠近。这说明在当前名义模型中，成本函数主要改变低预算质量治理的进入时机，而高预算结果共同接近设定的质量上界。图中的理论参考配比只提供结构归一化比较，不属于可执行候选。

表 6.2　三种质量成本下的有限候选名义配置（$L_{\text{ctx}} = 4096$；$N, D$ 单位为十亿）

| 成本 | $C$ | $N$ (B) | $D$ (B) | $Q_A^\star$ | 预测 $L^\star$ | 状态 | $s_Q$ (%) |
|---|---|---|---|---|---|---|---|
| 指数型 | $10^{19}$ | 0.303 | 3.596 | 0.786 | 3.02336 | R1 | 25.60 |
| 指数型 | $10^{22}$ | 5.428 | 246.051 | 1.000 | 2.09355 | R2 | 8.93 |
| 指数型 | $10^{24}$ | 39.558 | 3657.850 | 1.000 | 1.88628 | R2 | 1.33 |
| 幂函数型 | $10^{19}$ | 0.215 | 6.814 | 0.617 | 3.03977 | R0 | 0.00 |
| 幂函数型 | $10^{22}$ | 5.517 | 238.669 | 1.000 | 2.09457 | R2 | 10.20 |
| 幂函数型 | $10^{24}$ | 39.665 | 3639.560 | 1.000 | 1.88636 | R2 | 1.56 |
| 对数渐进型 | $10^{19}$ | 0.317 | 3.314 | 1.000 | 2.91453 | R2 | 28.36 |
| 对数渐进型 | $10^{22}$ | 5.011 | 285.501 | 1.000 | 2.08891 | R2 | 2.44 |
| 对数渐进型 | $10^{24}$ | 39.094 | 3739.060 | 1.000 | 1.88597 | R2 | 0.32 |




(a) 可执行最优预测损失　　(b) 最优质量水平　　(c) 算力预算组成

图 6.2　三档预算下的模型结果与算力分配。(a) 三档预算下的可执行最优预测损失，实线对应指数型、幂函数型及对数渐进型质量成本；点线为理论参考配比的模型内结果。(b) 三档预算下的最优质量水平，指数型在低预算取得内部解，幂函数型从基线质量起步，对数渐进型在低预算即达到质量上界；中高预算三者均达到 $Q_A^\star = 1$。(c) 九个名义最优解的算力预算组成，每档预算内从左到右为指数型、幂函数型、对数渐进型质量成本；深色为基础训练，绿色为长文本注意力，黄色为质量治理。

指数型成本下，低预算配置的训练、注意力与质量治理预算份额分别为 65.46%、8.94%、25.60%。到 $10^{24}$ FLOPs 时变为 86.82%、11.85%、1.33%。高预算时 $Q_A^\star = 1$ 表示模型求解达到设定的质量上界。现实语料可达质量需由具体治理实验衡量。$10^{24}$ 的九行中三行均标为远距离外推。较低预算的 “interpolation” 标签也只核对 B1 的 $N, D, 6ND$ 边际范围，不证明质量、配比与规模的联合支撑。指数型三档与不可执行参考配比的预测损失差分别约为 0.02769、0.00833、0.00405。

## 6.5　连续预算、状态转移与上下文响应

图6.3与图6.4把三档离散预算扩展为连续预算路径。质量轨迹中的平台与上升段对应 R0、R1、R2 的不同活跃约束；$D^\star/N^\star$ 在转移窗口附近出现折点，表明质量治理与训练规模的联合调整会改变资源比例。损失曲线随预算递减，可执行方案与理论参考的差距随预算增大而收窄。这里的参考线仍是模型内比较对象，不能替代未训练新配比的观测。

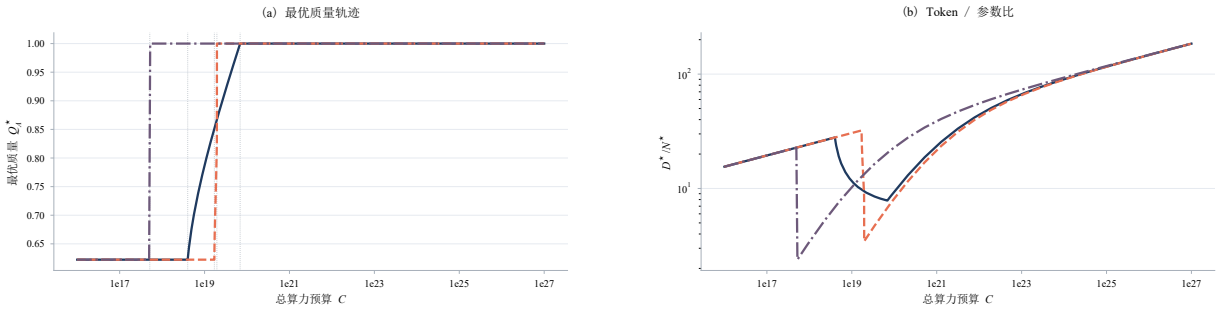



图 6.3　连续预算下的最优质量轨迹与训练 token 数 / 参数量比。三条曲线分别对应指数型、幂函数型、对数渐进型质量成本；折点与质量体制的活跃约束变化相对应。

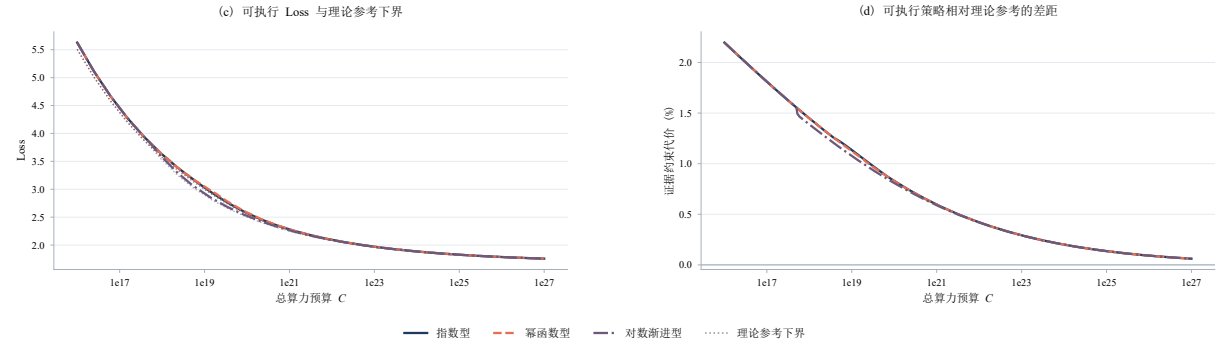



图 6.4　连续预算下的可执行预测损失与理论参考下界，以及两者的模型内相对差距。虚线参考曲线不参加有限候选决策。

在 $C \in [10^{16}, 10^{27}]$ 扫描并自适应加密，状态签名由配比身份和 R0/R1/R2 共同组成。新版转移表只报告 $\mathbf{p}_{\text{safe}}$ 的质量体制变化，未观察到配比切换。有限网格不能排除很窄的未发现区间。表6.3同时给出位置和机制核查状态，避免把状态二分位置误写成精确 KKT 根。

表 6.3　名义配置下的质量状态转移及机制证据（$L_{\text{ctx}} = 4096$）

| 成本 | 状态变化 | 转移预算 $C$ | 机制核查 |
|---|---|---|---|
| 指数型 | $R0 \to R1$ | $3.86826 \times 10^{18}$ | 状态二分，连续边界未证实 |
| 指数型 | $R1 \to R2$ | $7.03630 \times 10^{19}$ | 状态二分，机制未证实 |
| 幂函数型 | $R0 \to R1$ | $1.66239 \times 10^{19}$ | 状态二分，连续边界未证实 |
| 幂函数型 | $R1 \to R2$ | $1.96784 \times 10^{19}$ | 分支等值根及数值包络检查 |
| 对数渐进型 | $R0 \to R2$ | $5.24973 \times 10^{17}$ | 端点分支等值根及数值包络检查 |

幂函数型 R1→R2 的两分支损失差约为 $2.74 \times 10^{-12}$、质量水平相差约 0.1585。对数渐进型 R0→R2 的质量跳跃约为 0.3829。这两处支持模型内分支切换，仍不是解析证明。指数型 R1→R2 的端点 $\rho_Q(1)$ 虽接近 1，但其分支差值核查缺失，不能据此把该位置写成已确认的 KKT 连续边界。相位图按 R0/R1/R2 着色时展示的是质量体制。各预算–上下文网格点的配比身份需另由主动集签名核查。

图6.5把表6.3中的转移预算放到同一对数轴上。指数型和幂函数型都经过部分质量投资窗口，前者的 R1 窗口更宽；对数渐进型从 R0 直接进入 R2。图6.5进一步固定指数型成

本，同时改变预算与上下文长度，显示体制边界随注意力成本移动。颜色表示最优质量状态，而非在图上直接证明连续边界的解析机制；转移点的数值证据仍以表6.3为准。

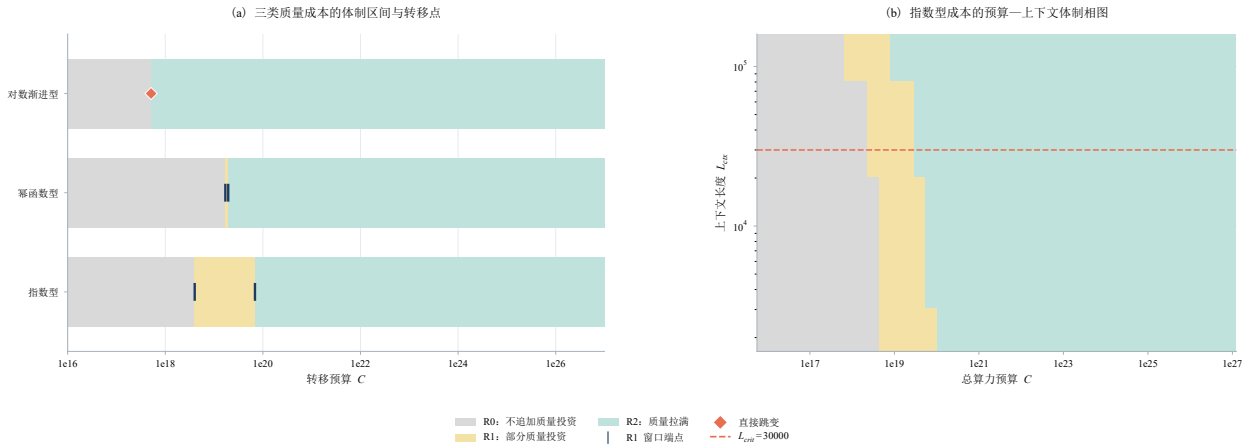



图 6.5　三类质量成本的 R0、R1、R2 体制区间与数值转移点，以及指数型质量成本下的预算—上下文质量体制相图。深色短线表示部分质量投资窗口端点，菱形表示对数渐进型的端点跳变；虚线为 $L_{\text{ctx}}^{\text{crit}} = 30000$ 的开销诊断线；颜色对应 R0、R1、R2。

上下文长度经 $6 + \eta_{\text{att}} L_{\text{ctx}}$ 改变单位 $ND$ 的计算成本，当前模型中不直接改变质量收益函数。代码对 C7 的五个实际长度及诊断点 30000 重新求解。指数型成本、$C = 10^{19}$ 时，六个长度均选 $\mathbf{p}_{\text{safe}}$ 且为 R1。从 2048 增至 131072，$Q_A^\star$ 从 0.776233 升至 0.993493，预测 Loss 从 3.01270 升至 3.30013。$C = 10^{22}$ 的六行均选该配比且为 R2。质量上升来自给定总预算内的资源重新分配，刻画长上下文成本对配置结构的间接影响。

记 $\varepsilon_N = \mathrm{d}\ln N^\star / \mathrm{d}\ln C$、$\varepsilon_D = \mathrm{d}\ln D^\star / \mathrm{d}\ln C$、$\varepsilon_Q = \mathrm{d}Q_A^\star / \mathrm{d}\ln C$。体制或配比切换处导数可能不连续，局部数值差分不宜直接解释为稳定弹性。分支机制的核查状态见表6.3。高预算处的响应属于条件外推。

图6.6把 C7 观测到的五种上下文长度与诊断点 30000 放在同一条件模型中。固定预算时，延长上下文会提高注意力开销并推高最优预测损失。低预算下，治理质量从 0.776233 增至 0.993493，表明模型在更昂贵的上下文设置中重新分配了质量与训练资源；这一变化是优化模型的条件响应。图6.7给出相应的资源弹性和预算份额。尖峰集中在质量体制变换附近，应按分支切换解释，不将其当作平滑曲线的稳定局部弹性。

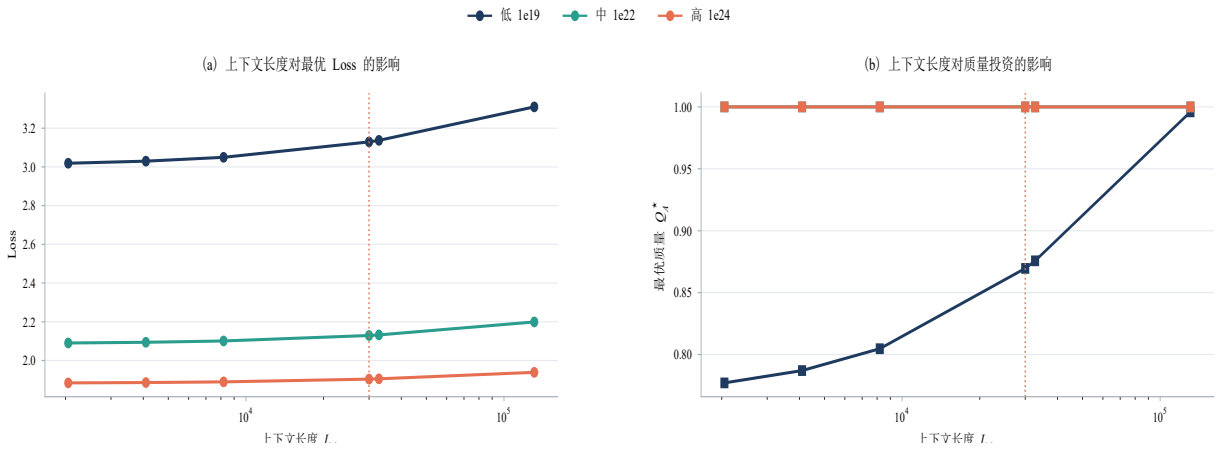



图 6.6　上下文长度对最优预测损失和治理质量的条件影响。三条曲线分别对应 $10^{19}$、$10^{22}$、$10^{24}$ FLOPs，虚线标识 $L_{\text{ctx}} = 30000$ 的开销诊断点。

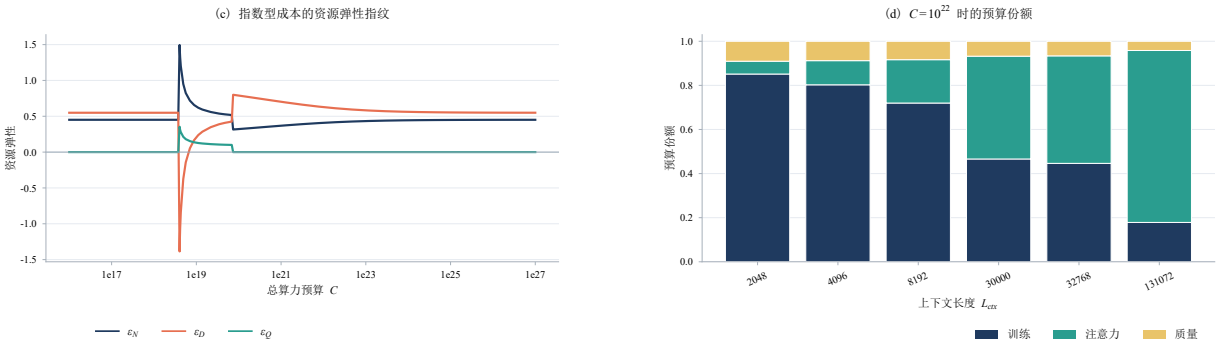



图 6.7　指数型质量成本下的资源弹性与 $10^{22}$ FLOPs 时的预算份额。弹性曲线按预算求局部数值差分，折点附近须结合体制转移判读。

## 6.6　条件不确定性、遗憾与等效算力

本节只固定其名义值，联合改变 $\kappa$ 的 B6 区间端点 $0.4378, 0.4873$、人为质量桥 $c_Q = 0.75, 1.25$，以及五种配比尺度设定：无衰减 $\gamma_p = 0$、持续幂律 $\gamma_p = 0.05, 0.10$、60M 后冻结 $\gamma_p = 0.05, 0.10$。$2 \times 2 \times 5 = 20$ 个角点加一个名义设定，共形成 21 个无概率权重的压力测试情景。其作用是检查设定扰动下的决策稳定性。

对每个情景 $s$，在三个可执行配比内计算数值最优 $L_s^\star$。有限候选决策集由各情景数值解和名义解组成。归一化遗憾定义为

$$r_s(x) = \frac{L_s(x) - L_s^\star}{\max(L_s^\star - E_s, 10^{-12})}, \qquad x_{\mathrm{rob}} = \arg\min_{x \in \mathcal{X}_{\mathrm{cand}}} \max_s r_s(x). \tag{6.7}$$

这里的 minimax 仅针对有限候选集。表6.4给出指数型成本下三档预算的名义解与最小最大遗憾解。两列解均选 $\mathbf{p}_{\mathrm{safe}}$。高预算的微小遗憾只反映当前 21 情景和有限决策集的接近程度，不表示跨模型族规模外推已获验证。

以不追加质量治理 $Q_A = Q_{0,A}(\mathbf{p})$ 为反事实，并允许在同一三配比集合内选择，定义达到治理模型预测损失所需的等效预算倍数 $M(C) = C_{\mathrm{eq}}/C$。三种质量成本下的倍率列于表6.4。这些倍率描述模型内质量治理相对于追加算力的条件替代关系，实际训练加速仍需同预算实验检验。

表 6.4　21 情景下的最坏遗憾与模型内等效算力倍数（遗憾列采用指数型质量成本）

| 预算 $C$ (FLOPs) | 名义解遗憾 | 稳健解遗憾 | $M_{\mathrm{exp}}$ | $M_{\mathrm{pow}}$ | $M_{\mathrm{log}}$ |
|---|---|---|---|---|---|
| $10^{19}$ | 0.008580 | 0.008580 | 1.08290 | 1.00000 | 1.88557 |
| $10^{22}$ | $4.05 \times 10^{-6}$ | $2.37 \times 10^{-6}$ | 2.59988 | 2.55769 | 2.80330 |
| $10^{24}$ | $2.84 \times 10^{-6}$ | $2.03 \times 10^{-6}$ | 2.83635 | 2.82962 | 2.86569 |

图6.8展示 $10^{22}$ FLOPs 下名义解在各联合情景中的归一化遗憾。情景标签显式列出质量响应端点、配比尺度设定与桥接系数，便于追溯最不利情景的来源。图6.8将三档预算的最坏遗憾并列。低预算的风险高于中高预算；在有限候选集内，稳健解对中高预算的改进虽可计算，但量级很小，因而不将曲线重合解释为所有未考虑扰动下的稳健性。

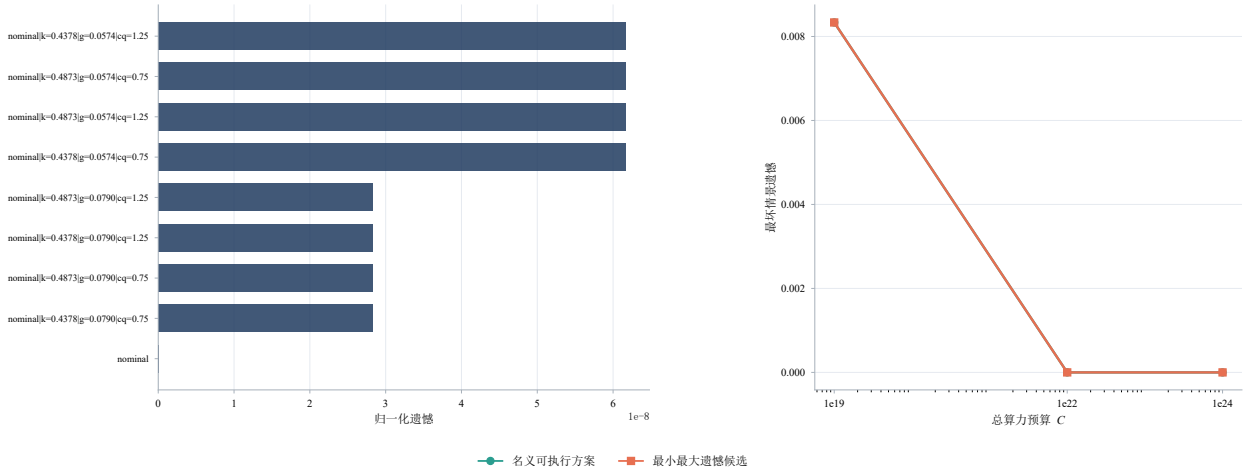



图 6.8　$10^{22}$ FLOPs 下名义可执行方案在联合参数情景中的归一化遗憾，以及三档预算下名义解与最小最大遗憾候选的最坏情景遗憾。

综上，三类成本下的九个名义配置均选择训练配比凸包内的 $\mathbf{p}_{\text{safe}}$。连续预算分析进一步给出 R0/R1/R2 的状态路径，并区分已核验分支交叉与数值状态边界。传递给能力预测模型的是注明配比身份、无衰减名义假设、成本函数和上下文长度的条件损失情景。其适用范围为三个候选配比及当前代理模型。$\gamma_p$ 未被识别，$10^{24}$ FLOPs 解属于远距离外推，完整标度律参数联合变化留待后续评估。

# 7　问题四的建模与求解

## 7.1　能力指标、样本口径与时间轴

本问以附件 C1 的六维等权综合分 Average 表示能力 $S \in (0, 100)$。六维分别为 IFEval、BBH、MATH Lvl 5、GPQA、MUSR 和 MMLU-PRO，评测框架及部分原始基准的公开来源见文献 [16–19]。为处理得分上界，在回归中使用 $y = \text{logit}(S/100)$，预测后再用 $S = 100\sigma(y)$ 返回原分数尺度，其中 $\sigma(z) = 1/(1 + e^{-z})$，$\text{logit}(u) = \ln[u/(1 - u)]$。数值计算将 $S/100$ 截至 $[10^{-3}, 1 - 10^{-3}]$。数据清理要求参数量为正、综合分与提交日期可用，且附件类型可归入预训练基础模型或对话 / 微调模型。C1 原有 4576 条，符合条件者 4552 条。

“开放模型”在附件中没有完全统一的法律定义。本文主口径采用 C1 许可证白名单，保留许可证字段明确落入研究复现可用类别的记录，剔除 other、unknown 与缺失。比较口径为全部 4552 条有效排行榜记录，未逐条核实其权重是否可下载。主口径共 2498 条，其中预训练基础模型 241 条、对话 / 微调模型 2257 条。与 Epoch 权重字段可对照的 442 条中，424 条标为开放权重。在这些开放权重条目里，只有 60.1% 进入本文许可证白名单，说明两个筛选口径并不等价。白名单还包含限制商业使用的许可，因此下文的“开放”是研究复现操作口径，不等同于严格的开放源代码定义。图7.1展示筛选对样本构成和可观察最高分的影响：柱形为不同模型类型的记录占比，散点为各许可证组的最高分。

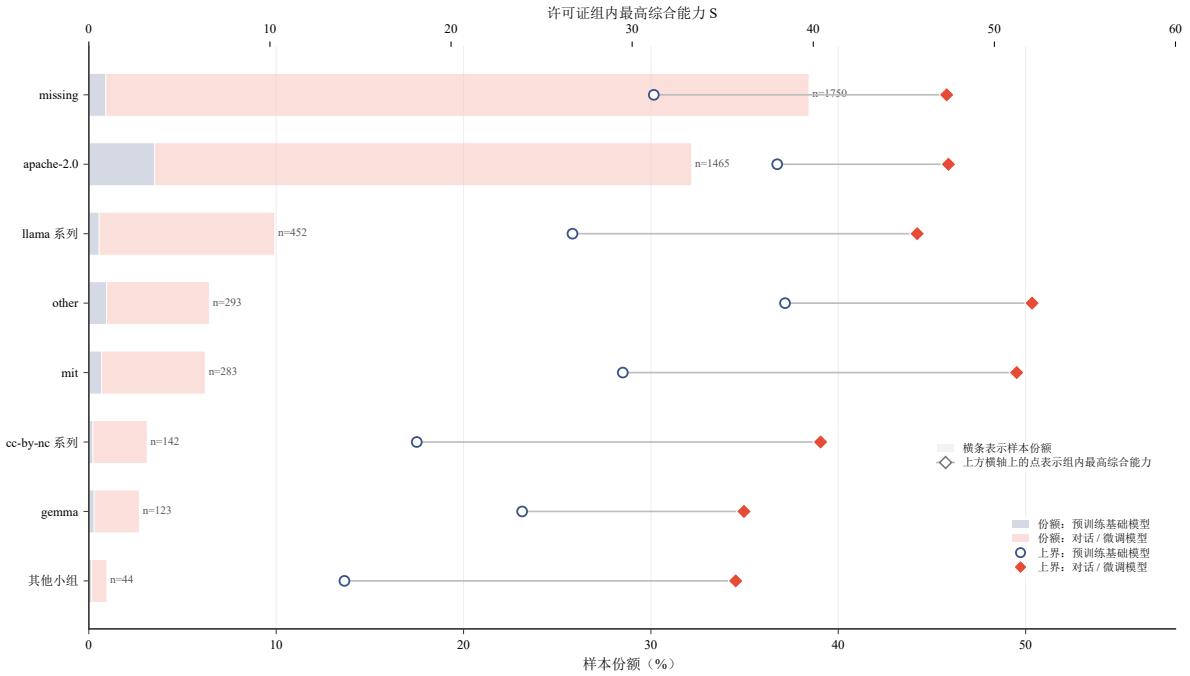



图 7.1　C1 各许可证组的模型记录占比与最高综合分。

能力记录按排行榜提交日期排序，技术年代使用 C2 / C4 的发布日期，C8 评测日期专门用于逐任务数据核对。446 个可匹配模型的“提交减发布”间隔中位数为 104 天、四分位区间为 36–172 天，所以本文对模型发布与能力被观测分别使用两条时间轴。以 2024 年 6 月首批提交的最高分作记录起点，严格口径下截至 2025 年 3 月，预训练基础模型前沿为 38.01 分，对话 / 微调模型为 51.23 分。图7.2将累计记录与月度提交量并列，避免把提交密度变化误认成稳定的技术进步速度。首月为集中提交的初始批次，后续台阶才对应记录刷新。

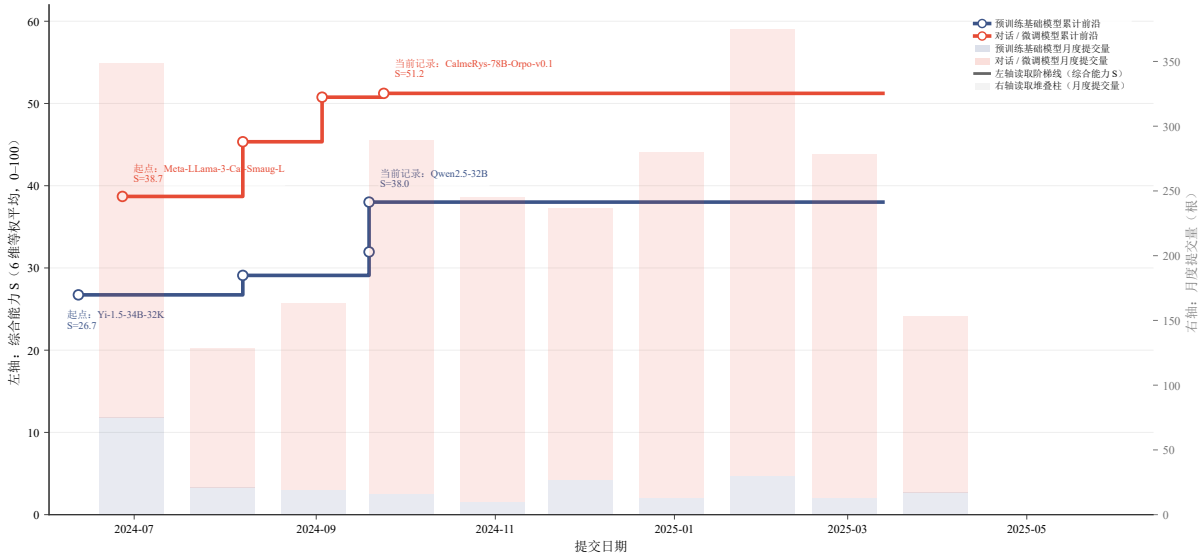



图 7.2　严格许可证口径下的累计最高综合分与月度提交量。

## 7.2 C8 逐任务重建与能力增长的异质性

C1 汇总分可能掩盖任务间差异。附件 C8 提供 39 个叶子任务：BBH 24 个、GPQA 3 个、MATH 7 个、MUSR 3 个、IFEval 与 MMLU-PRO 各 1 个。对任务 $j$ 的原分数 $a_{ij}$，以全部有效模型该任务分布的第 2 百分位 $b_j$ 为经验低分基线，定义

$$\widetilde{a}_{ij} = \mathrm{clip}\left(\frac{a_{ij} - b_j}{1 - b_j}, 0, 1\right), \quad S_i^{\mathrm{C8}} = \frac{100}{6} \sum_{f=1}^{6} \frac{\sum_{j \in \mathcal{J}_f} n_j^{\mathrm{eff}} \widetilde{a}_{ij}}{\sum_{j \in \mathcal{J}_f} n_j^{\mathrm{eff}}}. \tag{7.1}$$

其中，$\mathcal{J}_f$ 为第 $f$ 个 benchmark 家族的任务集，$n_j^{\mathrm{eff}}$ 由 C8 配置给出。家族内按有效样本量加权，六家族再等权。$b_j$ 是数据分位数，不是已知的理论随机猜测概率。C8 与 C1 可匹配 1886 个模型。重建分与 C1 综合分的 Pearson 相关系数为 0.9891、Spearman 相关系数为 0.9916。故汇总分用于主分析具有较高的排序一致性，但任务结构仍须单独检验。

在严格口径的 C8 匹配记录上，以 2024 年 6–9 月为早期、2024 年 12 月及以后为晚期，分别取每项任务归一化得分最高的 5 个模型的均值，再在任务家族内等权平均。图7.3中 MATH 家族的前沿增益为 0.1324，GPQA 为 0.0359，MUSR 为 0.0124，MMLU-PRO 与 IFEval 分别为 0.0066、0.0033，BBH 为 $-0.0006$。早晚期是不同日期窗口的描述性比较，任务家族的增益差异显示综合分变化伴随明显的分项异质性。

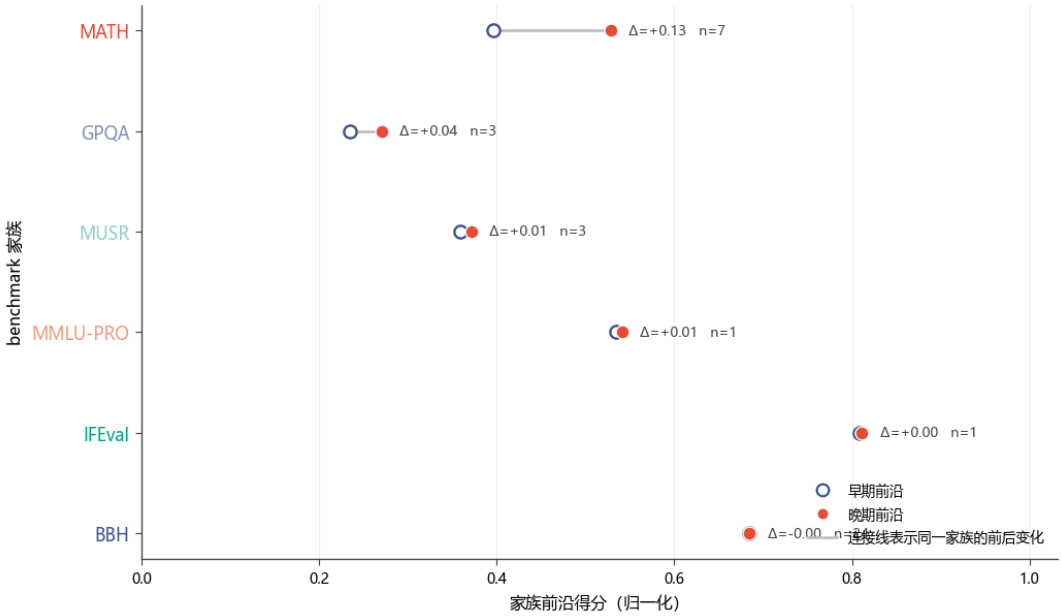



图 7.3 C8 六个基准家族早晚期逐任务 Top-5 均分及变化。

## 7.3 训练算力主口径下的规模与非规模贡献

### 7.3.1 参数量诊断与等能力线

为与常见的参数标度分析对照，先在 C1 严格口径内分别拟合 $q = 0.9$ 条件分位前沿 [20]

$$Q_{0.9}(y_i \mid N_i, \tau_i) = \theta_0 + \theta_1 \ln N_i + \theta_2 (\ln N_i)^2 + \gamma_N \tau_i. \tag{7.2}$$

预训练基础模型的 $\gamma_N = 0.0231$/月，Bootstrap 95% 区间为 $[0.0038, 0.0515]$。对话 / 微调模型为 0.0637/月，区间为 $[0.0562, 0.0718]$。在参考规模附近，等能力线所需参数量随月份减少，预训练 3B 参考点的参数需求半衰期约 12.8 个月，对话 / 微调 8B 参考点约 4.7 个月。等价参数倍数依赖参考规模和模型形式，图7.4及表7.1共同展示这一诊断。下一段的主贡

献分解以实测训练 FLOPs 为口径。

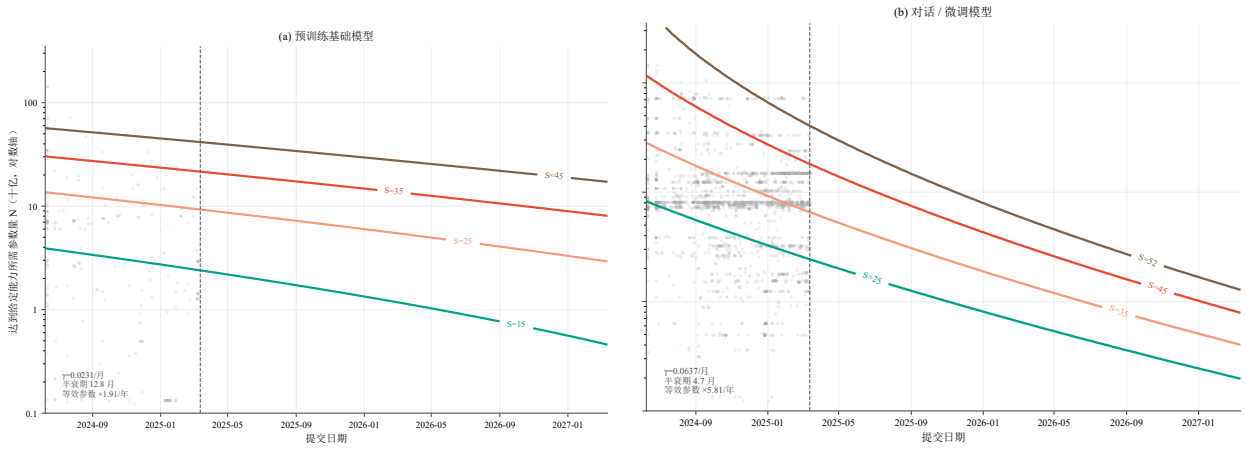



图 7.4　参数量等能力线（$q = 0.9$）：左图为预训练基础模型，右图为对话 / 微调模型。灰点为观测模型，彩色线对应不同固定综合分，虚线为样本截止时间；纵轴为所需参数量（十亿，对数轴）。

表7.1将等能力线的局部变化换算为参数需求半衰期。相同模型形式下，半衰期随参考参数量改变：预训练基础模型在 1B 和 8B 处分别为 9.93 和 15.55 个月，对话 / 微调模型分别为 6.33 和 4.73 个月。它是严格许可证样本内拟合曲面的条件换算，不能直接作为单一技术因素的进步速度。

表 7.1　等能力线在不同参考参数量处的条件换算

| 类型 | 参考参数量 | 局部参数斜率 | 半衰期（月） | 年等价参数倍数 |
|---|---|---|---|---|
| 预训练基础模型 | 1B | 0.3304 | 9.93 | 2.31 |
| 预训练基础模型 | 8B | 0.5176 | 15.55 | 1.71 |
| 对话 / 微调模型 | 1B | 0.5812 | 6.33 | 3.72 |
| 对话 / 微调模型 | 8B | 0.4346 | 4.73 | 5.80 |

进一步对每个任务估计

$$\operatorname{logit}(\widetilde{a}_{ij}) = \beta_{0j} + \beta_j \ln N_i + \gamma_j \tau_i + \delta_j I_i^{\text{chat}} + \epsilon_{ij}, \tag{7.3}$$

其中 $\tau_i$ 是以 2024 年 6 月为原点的提交月份，$I_i^{\text{chat}}$ 来自 C1 类型字段。对模型记录做 100 次 Bootstrap 重采样。$\beta_j > 0$ 与 $\gamma_j > 0$ 各自的重抽样比例均达到 0.90 时，将该任务标为“双驱动”。仅一项满足时分别标为规模或时间驱动，其余标为混合 / 不确定。

图7.5显示任务点在两种关联上的分布，气泡大小对应任务有效样本量。颜色区分任务家族，黑边表示至少一个系数的正向重抽样比例达到 0.90，浅色点表示两项均未达到该阈值。此处的“时间关联”汇总训练数据、架构、对齐等随时间共同变化的因素，具体贡献有待独立对照识别。

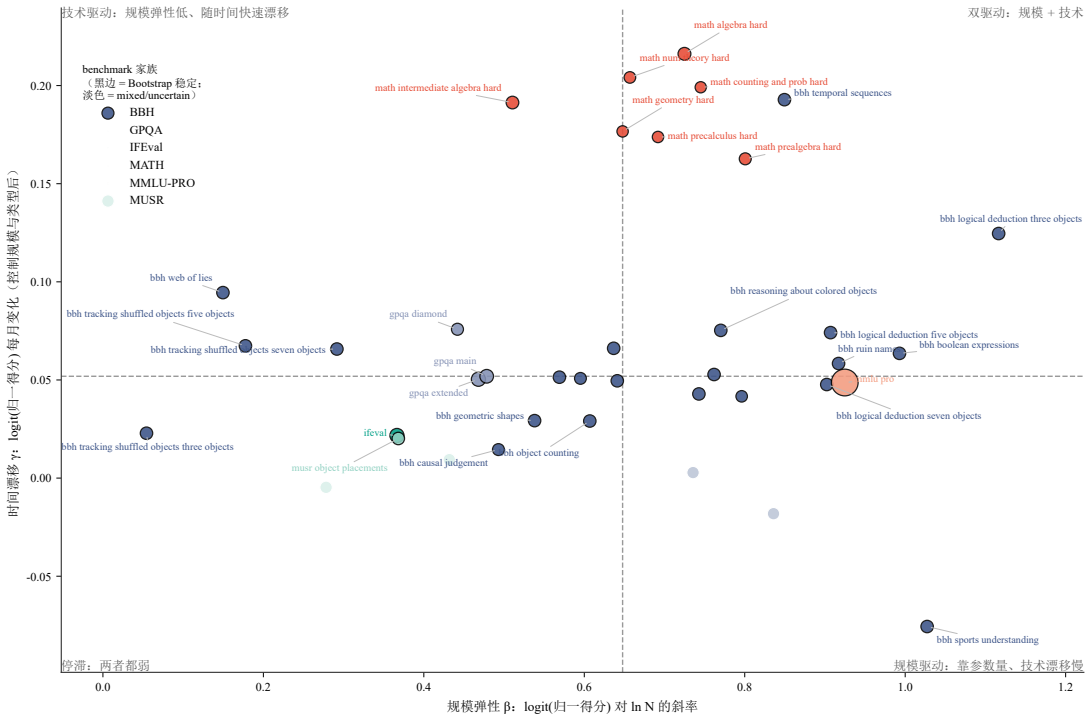



图 7.5　C8 逐任务参数量与提交时间系数（logit 尺度）。

为检验时间系数是否完全由参数量区间的迁移造成，表7.2固定参数量区间，比较严格许可证口径下最早三个月（$\tau < 3$）与观测末端三个月（$\tau \geq \tau_{\max} - 3$）各自得分最高五条记录的均值。对话 / 微调模型在 10–30B 区间的差值为 11.01 分，预训练基础模型同区间为 5.45 分；预训练 30–200B 区间的末期没有记录，因此不计算差值。固定参数区间后仍能观察到较大变化，支持将时间项作为独立的描述性预测变量；两端模型样本不同，表中差值同时承载架构、训练数据和提交选择变化。

表 7.2　固定参数量区间内首末三个月的 Top-5 综合分比较

| 类型 | 参数量区间 | 首期均分 | 末期均分 | 差值 | 两期样本数 |
|---|---|---|---|---|---|
| 预训练 | 0.5–3B | 11.93 | 15.37 | 3.45 | 5 / 5 |
| 预训练 | 3–10B | 20.98 | 21.54 | 0.56 | 5 / 5 |
| 预训练 | 10–30B | 22.41 | 27.86 | 5.45 | 5 / 5 |
| 预训练 | 30–200B | 26.24 | — | — | 5 / 0 |
| 对话 / 微调 | 0.5–3B | 15.19 | 23.25 | 8.06 | 5 / 5 |
| 对话 / 微调 | 3–10B | 31.42 | 38.57 | 7.16 | 5 / 5 |
| 对话 / 微调 | 10–30B | 33.40 | 44.40 | 11.01 | 5 / 5 |
| 对话 / 微调 | 30–200B | 44.38 | 47.11 | 2.73 | 5 / 5 |

### 7.3.2　训练 FLOPs 前沿与 Shapley 分解

贡献分解以 C4 的实测训练算力 $C_i$ 为规模变量。将 C1 与 C4 按模型名称唯一匹配，得到 83 条记录，其中预训练 60 条、对话 / 微调 23 条。令 $\widetilde{\ln C}$ 为匹配样本的 $\ln C$ 中位数，$t_i^{\text{pub}}$ 为距 2024 年 6 月的发布月份，拟合训练算力前沿（Compute-Q90）与延迟诊断模

型（DATF-Q90）：

$$
\begin{aligned}
Q^{\mathrm{C}}_{0.9}(y_i) &= \beta_0 + \beta_C(\ln C_i - \widetilde{\ln C}) + \gamma_C t_i^{\mathrm{pub}} + \delta I_i^{\mathrm{chat}},\\
Q^{\mathrm{D}}_{0.9}(y_i) &= \beta_0^{\mathrm{D}} + \beta_C^{\mathrm{D}}(\ln C_i - \widetilde{\ln C}) + \gamma_C^{\mathrm{D}} t_i^{\mathrm{pub}}\\
&\quad + \rho d_i + \delta^{\mathrm{D}} I_i^{\mathrm{chat}},\\
d_i &= t_i^{\mathrm{sub}} - t_i^{\mathrm{pub}}.
\end{aligned}
\tag{7.4}
$$

Compute-Q90 得到 $\beta_C = 0.1286$、$\gamma_C = 0.0325$/月，分位伪 $R^2 = 0.4326$。DATF 的相应值为 $0.1431$、$0.0607$/月，并有 $\rho = 0.0297$/月、伪 $R^2 = 0.4599$。$\rho$ 只表明提交延迟携带统计信息，不证明发布后扩散具有因果效应。两个时间系数的差异也表明技术年代的估计依赖时间轴定义。下文把 $\gamma_C$ 称为非规模时间漂移，其中可能同时包含算法、数据工程、对齐、评测和样本选择变化。

令 $f(C,t,g) = 100\sigma[\widehat{\beta}_0 + \widehat{\beta}_C(\ln C - \widetilde{\ln C}) + \widehat{\gamma}_C t + \widehat{\delta} I_g^{\mathrm{chat}}]$。以 2021–2023 年为早期、2024–2025 年为晚期，分别取匹配组内训练算力与发布时间的中位数 $(C_0, t_0)$、$(C_1, t_1)$。对于实际观测的 $q = 0.9$ 综合分变化 $\Delta S_{\mathrm{obs}}$，使用两因素 Shapley 平均路径：

$$
\begin{aligned}
\Delta S_C &= \tfrac{1}{2}\{f(C_1,t_0) - f(C_0,t_0) + f(C_1,t_1) - f(C_0,t_1)\},\\
\Delta S_t &= \tfrac{1}{2}\{f(C_0,t_1) - f(C_0,t_0) + f(C_1,t_1) - f(C_1,t_0)\},\\
\Delta S_u &= \Delta S_{\mathrm{obs}} - \Delta S_C - \Delta S_t.
\end{aligned}
\tag{7.5}
$$

表 7.3　2021–2023 与 2024–2025 年间的能力前沿变化分解（分；括号内为占实际变化的比例）

| 类型 | 早期 $q_{.9}$ | 晚期 $q_{.9}$ | 算力扩张 | 时间漂移 | 未解释 |
|---|---|---|---|---|---|
| 预训练基础模型 | 13.67 | 32.19 | 4.65 (25.12%) | 7.31 (39.48%) | 6.56 (35.40%) |
| 对话 / 微调模型 | 21.94 | 31.56 | 3.56 (37.04%) | 4.16 (43.29%) | 1.89 (19.67%) |

表7.3直接用实际变化作分母，保留未解释项且不把三项占比裁剪为正值。预训练组中，训练算力扩张解释 4.65 分（25.12%），非规模时间漂移为 7.31 分（39.48%），如实保留 6.56 分（35.40%）未解释项。对话 / 微调组对应为 3.56、4.16、1.89 分。图7.6的前一面板来自 C1–C4 匹配样本，后一面板按 C1 参数量分组作 Top-5 前沿的描述性核查。参数量以外的变化由时间项汇总，其具体技术来源有待另行识别。

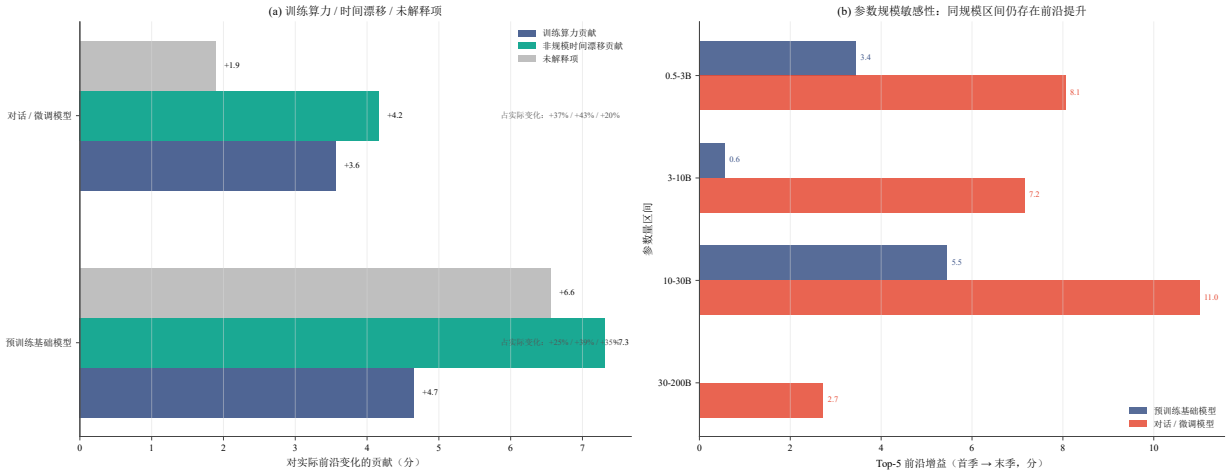



图 7.6　训练算力、时间漂移及未解释项的能力贡献与分参数区间 Top-5 前沿变化。

## 7.4　算力增长的变化点与条件情景

附件 C3 的 2019–2025 年年度记录覆盖更长时期，其中部分条目采用估算口径。本文将其作为历史背景单独呈现，前沿回归以 C1 为准。图7.7显示 C3 的历史小样本、年度分布与累计记录。2024 年记录为 52.08 分，2025 年未在该表内刷新。该数值与 C1 严格许可证口径的 51.23 分出自不同筛选与时间序列，两者分别报告。

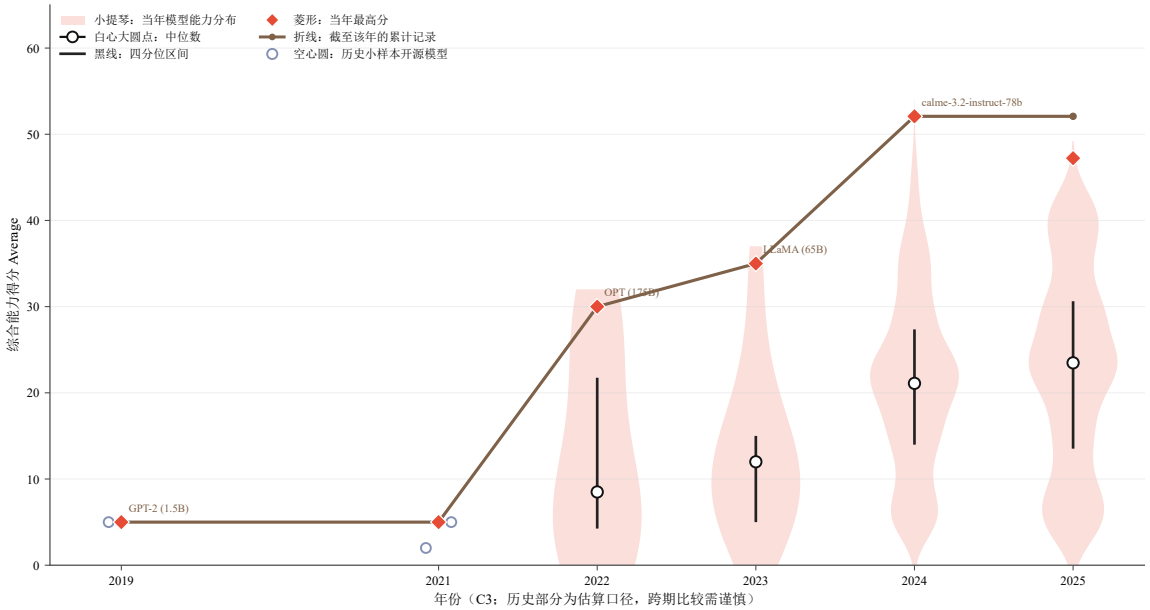



图 7.7　C3 在 2019–2025 年的能力分布、年度最高分与累计记录。

对 C4 标为开放权重的语言模型，在 $\log_{10} C$ 上以 $q = 0.9$ 分位折线搜索变化点，要求分段两侧各至少 25 条，并最小化两段 pinball 损失。记 $\rho_q(e) = e[q - \mathbf{1}(e < 0)]$，变化点由

$$t_c^* = \arg\min_{t_c} \left\{ \sum_{t_i < t_c} \rho_{.9}(e_i^{\text{pre}}) + \sum_{t_i \geq t_c} \rho_{.9}(e_i^{\text{post}}) \right\} \tag{7.6}$$

确定，其中 $e_i^{\text{pre}}$、$e_i^{\text{post}}$ 是各分段 $\log_{10} C$ 对发布时间线性分位回归的残差。所有拟合记录

均截至 2025 年 3 月 13 日，其后 94 条 C4 开放权重语言模型记录作为事后核对样本。变化点为 2024.50 年。变化点前 $n = 311$，前沿算力年倍数估计为 3.01，Bootstrap 95% 区间 $[2.37, 3.58]$。后段 $n = 90$，估计为 0.13，区间 $[0.02, 8.47]$。后段点估计低于 1，而区间跨越 1，表示近期趋势尚不确定。

以变化点后的点估计设置年算力倍数 $G$ 的三种条件情景：延续为 0.13，对数增长率减半为 $\sqrt{0.13} \approx 0.36$，停滞为 1。这里“放缓”指对数增长率的绝对幅度减半，在 $G < 1$ 时对应更缓的算力下降，而“停滞”是算力不变。表7.4区分截至预测日的历史拟合与后续条件情景。对应的能力预测结果见表7.6。

表 7.4　训练算力变化点及条件情景（拟合记录截至 2025 年 3 月 13 日）

| 类型 | 阶段或情景 | 样本量 | 年算力倍数 $G$ | Bootstrap 95% 区间 |
|---|---|---|---|---|
| 历史拟合 | 变化点前 | 311 | 3.01 | $[2.37, 3.58]$ |
| 历史拟合 | 变化点后 | 90 | 0.13 | $[0.02, 8.47]$ |
| 条件情景 | 延续 | — | 0.13 | — |
| 条件情景 | 放缓 | — | $\sqrt{0.13} \approx 0.36$ | — |
| 条件情景 | 停滞 | — | 1 | — |

### 7.5　损失–能力桥接及问题三的增量接口

问题三优化的是验证集交叉熵 $L^\star(C)$，而 C1 能力分来自不同评测。先在有可比损失和综合分的 C5 模型上校准异方差自适应 Logistic 桥：

$$S = 100\sigma\{a + b(L_0 - L) + cI^{\text{chat}}\}, \qquad L_0 = 2.5. \tag{7.7}$$

参数 $a, b, c$ 由 C5 拟合。样本权重为可比性等级的先验权重乘以等级内残差方差倒数，并迭代更新。C5 含 43 个校准模型。按模型名称从 C6 中剔除 C5 已有者，对其新增的 32 个模型固定使用 C5 参数作外层验证，得到 RMSE 8.97 分、MAE 7.33 分、偏差 +1.39 分（观测减预测）。这里的“外层”按模型身份划分：C6 新增模型未参加 C5 校准。验证仍在同一附件体系内进行。验证后才用 C6 全量重估，得到

$$\widehat{S} = 100\sigma\{-2.610 + 1.727(2.5 - L) + 0.880I^{\text{chat}}\}. \tag{7.8}$$

全量拟合的 $R^2 = 0.479$。高可比与中可比两组残差标准差分别为 2.35、8.62 分。C5 到 C6 全量重估的三个系数变动分别为 $0.0317, -0.0247, 0.0496$。图7.8同时给出 C5 校准点、C6 新增验证点及重估桥，阴影为全量重估参数的 Bootstrap 波动。图中的拟合曲线与上述新增样本外层误差分别报告。

附件 A、B 与 C 的损失测量来自不同实验。本文将问题三给出的算力变化所致损失增量接入式(7.8)，并以 C1 截点实测前沿 $F_0$ 锚定：

$$\Delta L^\star = L^\star(C_0) - L^\star(C_1), \qquad S_1^L = 100\sigma\left[\text{logit}(F_0/100) + \widehat{b}\,\Delta L^\star\right]. \tag{7.9}$$

其中 $C_0 = 7.8 \times 10^{24}$ FLOPs 为截至预测日可见的榜单模型算力锚，$C_1 = C_0 G^{h/12}$ 是 $h$ 个月后的情景算力。问题三指数型质量成本曲线只使用其标记为非远距离外推的预算点 $[10^{19}, 10^{22}]$ FLOPs 作连续化：在该范围内按 $\log C$ 插值，范围上方用这些点拟合 $L^\star(C) = E + KC^{-\eta}$ 作条件延拓。锚点本身已高于该范围。在各目标时距的情景抽样中，79%–100% 的

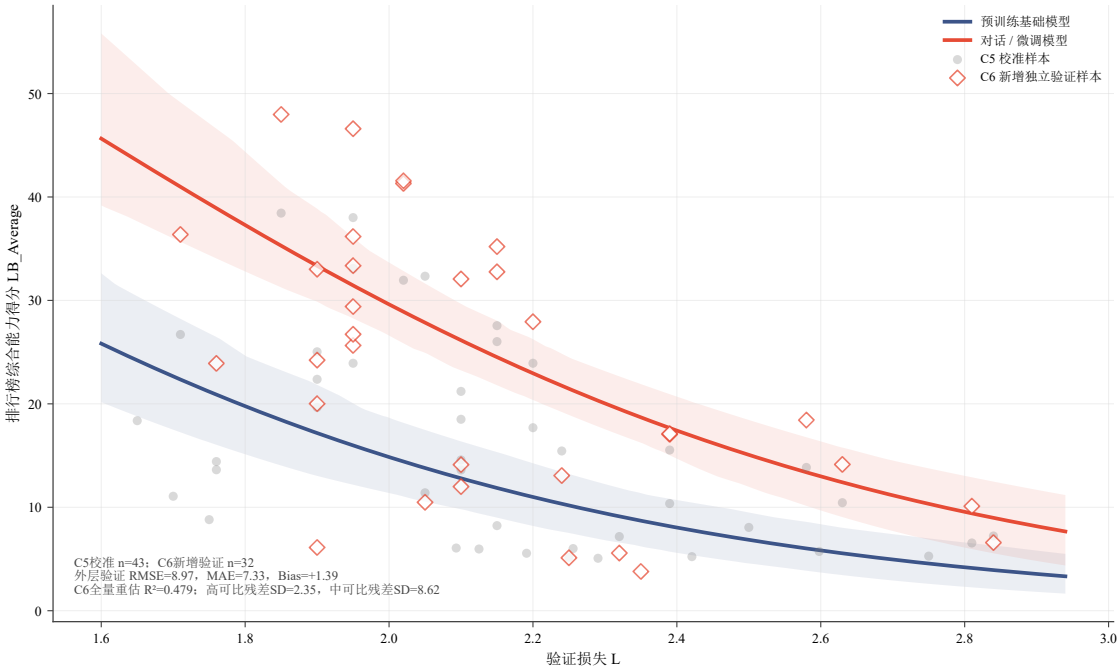



图 7.8　损失–能力 Logistic 桥的 C5 校准、C6 外层检验与全量重估。

目标预算落在该范围之外，因此式(7.9)用于跨问题条件核对。新版“延续”情景的 $G = 0.13$ 使预训练组 12、24 个月的 $\Delta L^{\star}$ 分别约为 $-0.06, -0.13$。未加累计前沿约束的桥接分数分别为 35.78、33.04 分，低于实测 $F_0 = 38.01$。最终累计前沿模型的相应中位数为 40.73、43.47 分。两通道差额列为模型间待解释项。累计前沿施加不下降约束，桥接分数的下降不会改变已观测前沿。

## 7.6　12 与 24 个月能力前沿的情景预测

预测对象是按提交日期累计的严格口径记录 $F_t = \max_{i:t_i^{\mathrm{sub}} \le t} S_i$。候选有经验到达率前沿模型（EARF）、式(7.4)的 Compute-Q90、含延迟项的 DATF-Q90，以及前三者预测的非负且权重和为 1 的组合。EARF 以累计提交数 $M_t$ 和月份 $t$ 拟合 $\mathrm{logit}(F_t/100) = a + b\ln(1+M_t) + ct$。训练算力模型则以当前真实 $F_0$ 锚定，把 $\widehat{\beta}_C(h/12)\ln G + \widehat{\gamma}_C h$ 加到当前 logit 分数上。任何候选均按累计前沿的定义设下界 $F_0$。

模型选择采用滚动预测原点：每折只用原点以前的 C1 与 C4 信息拟合，并要求预测窗口内实际有新提交。代码尝试 3、6、9 个月窗口。两类模型均只有 *3* 个月 *3* 折达到共同折数要求，6、9 个月均为 0 折。表7.5只比较这 3 个折外（out-of-fold，OOF）目标，并增列“保持当前前沿不变”的 Persistence 基线。预训练组在复杂候选中以 Compute-Q90 的 MAE 3.0943 分最小。对话 / 微调组以 EARF 的 MAE 0 最小。两组 Persistence 的 MAE 也均为 0，且全部有效折都没有前沿刷新。因此本次候选选择仅用于定义后续条件情景，未形成优于持续性基线的预测能力证据。

非负组合权重也由这批 OOF 目标拟合，其同批误差是候选间比较值，不作为独立外层误差。当前 6、9 个月缺少有效折，12、24 个月的结果在下文按长期情景外推单独报告。

以 2025 年 3 月的 $F_0$ 为起点，在三种算力情景下外推 12 和 24 个月。表7.6给出条件中位数与期限扩张经验区间，图7.10显示连续轨迹。区间先对前沿模型参数及变化点后算力增长率作 Bootstrap / 情景采样，再将实际有效的 3 个月 OOF 绝对残差按 $\sqrt{h/3}$ 扩张。由于这些折没有前沿刷新，还用历史正向前沿跃迁的中位幅度设置经验半径下限，并将区间下限截于当前实测 $F_0$。此构造是长期情景敏感性范围，其 12、24 个月覆盖率尚无直接回

表 7.5　3 个月滚动回测的 OOF MAE（分；两类模型各 3 折，均无前沿刷新）

| 类型 | EARF | Compute-Q90 | DATF-Q90 | 非负组合 | Persistence | 候选中选择 |
|---|---|---|---|---|---|---|
| 预训练基础模型 | 18.4342 | 3.0943 | 5.0350 | 3.0943 | 0 | Compute-Q90 |
| 对话 / 微调模型 | 0 | 3.2250 | 5.1479 | 0 | 0 | EARF |

测。

延续情景的 12、24 个月中位数，预训练组为 40.73、43.47 分，对话 / 微调组均为 51.23 分。后者所选 EARF 与算力情景无直接联动。预训练组在停滞情景下的中位数升至 47.28、56.74 分，是 Compute-Q90 中时间项继续外推的模型输出。延续情景 $G = 0.13$ 时算力项反向抵消部分时间项。该排序由当前点估计与模型形式共同决定，变化点后年倍数的宽区间使三种情景都需同时报告。

## 7.7　口径敏感性与结论边界

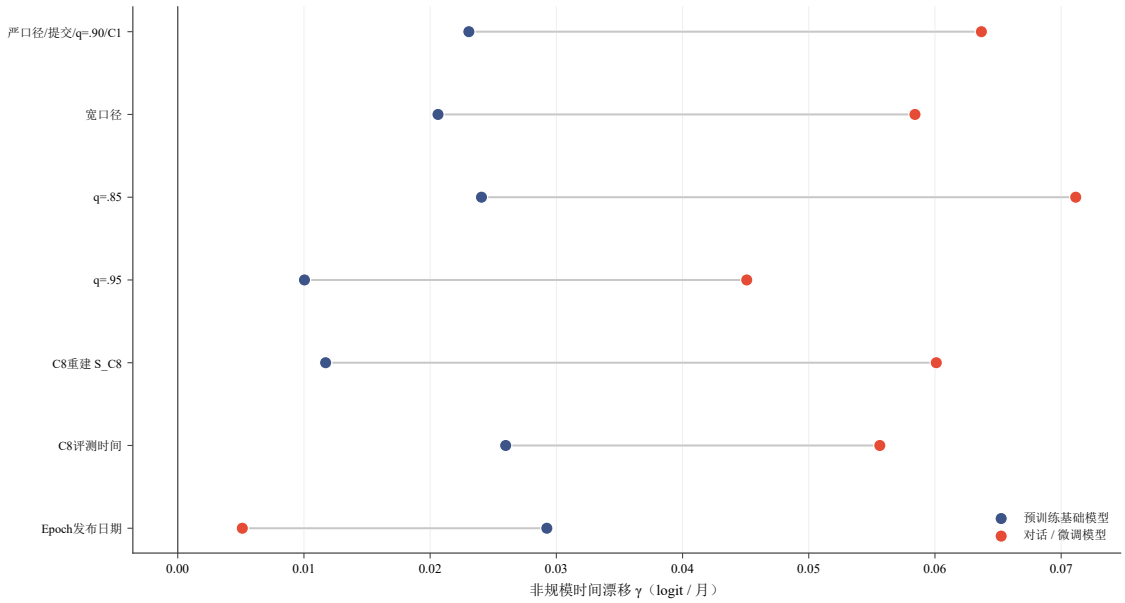



图 7.9　不同口径下参数量前沿时间系数的敏感性。

图7.9比较许可证筛选、分位水平、C8 重建得分和时间轴。图中横向跨度表示不同识别口径的敏感性，不是单一系数的置信区间。预训练模型在严格 / 宽口径下的月时间系数分别为 0.0231 / 0.0206。对话 / 微调模型分别为 0.0637 / 0.0584。对话 / 微调组若改用 Epoch 发布日期，系数降到 0.0051/月，且可匹配样本仅 207 条，提示时间轴选择与样本组成会显著改变“非规模漂移”的数值。$q = 0.95$ 或 C8 重建分也改变估计，因此参数需求半衰期和算力等效倍数只可作为给定口径下的模型解释量。

表 7.6　两类模型前沿的条件预测（以 2025 年 3 月实测前沿为锚；区间为期限扩张经验区间）

| 类型 | 算力情景 | 12 月中位数 | 12 月经验区间 | 24 月中位数 | 24 月经验区间 |
|---|---|---|---|---|---|
| 预训练 | 延续（$G = 0.13$） | 40.73 | $[38.01, 63.19]$ | 43.47 | $[38.01, 81.64]$ |
| 预训练 | 放缓（$G = 0.36$） | 44.10 | $[38.01, 63.22]$ | 50.58 | $[38.01, 81.43]$ |
| 预训练 | 停滞（$G = 1$） | 47.28 | $[38.01, 64.62]$ | 56.74 | $[38.01, 83.89]$ |
| 对话 / 微调 | 延续（$G = 0.13$） | 51.23 | $[51.23, 63.77]$ | 51.23 | $[51.23, 68.96]$ |
| 对话 / 微调 | 放缓（$G = 0.36$） | 51.23 | $[51.23, 63.77]$ | 51.23 | $[51.23, 68.96]$ |
| 对话 / 微调 | 停滞（$G = 1$） | 51.23 | $[51.23, 63.77]$ | 51.23 | $[51.23, 68.96]$ |

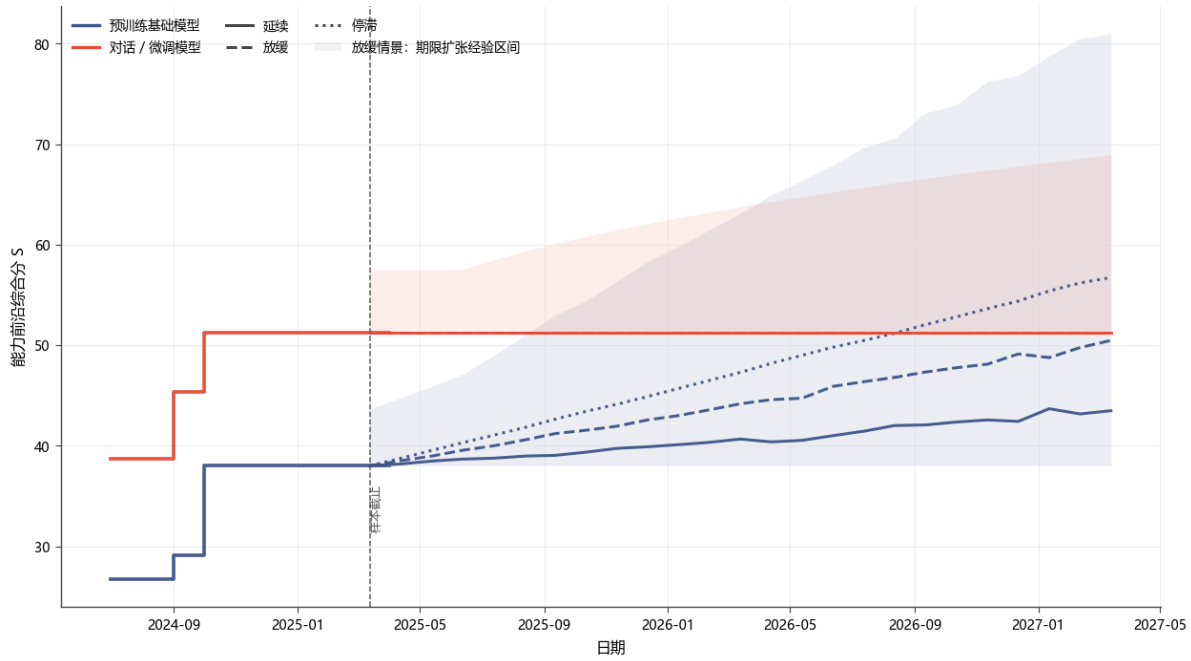



图 7.10　2025 年 3 月起两类模型的能力前沿条件轨迹与经验带。

综上，C1–C4 匹配样本中的前沿变化可以在模型内分成训练算力扩张、非规模时间漂移和未解释项。C8 显示任务家族的增长具有异质性。C5 到 C6 的新增模型检验为损失–能力桥提供了可核对的留出误差。算力增长参数只使用预测截止日以前的 C4 记录。12、24 个月数值对应条件情景，其误差带由每类仅 3 个、且均无前沿刷新的 3 个月 OOF 折与历史跃迁幅度扩张而来。同一批滚动回测折上的模型选择也没有胜过 Persistence 基线。因而长期结果适合进行情景对照，其实际预测精度仍需后续前沿刷新记录检验。

# 8　模型评价与适用边界

## 8.1　模型的主要成果

**质量评价与配比筛选。**问题一用严格互斥尾部和独立性参照筛出 80 对强冲突候选，再由四维有限补偿聚合得到七域质量分。扩展集使用与 A1 不重叠的余集复核冲突结构，配比代理则将开发集折外评估与固定检验集分开报告。SCM、SCI 和逐域残差模型分别承担局部曲率、稀疏交互与风险比较任务。推荐配比保持在训练配比凸包内。

**可追溯的跨附件模型。**问题二把经典规模项、半合成质量项和问题一配比项写成模块

化广义标度律。B1 识别规模参数，B6 估计质量响应，B7 在新质量水平检验该模块。A6–A9 提供同配方排序迁移证据。相对质量因子以各配比自身起点归一化，使追加治理与配比结构的作用在模型中各有位置。配比作用幅度的尺度指数按识别结果留空，问题三以无衰减名义情景和预设敏感性情景继续求解。

**有限候选下的资源决策。**问题三对三个可执行配比、三类质量成本和三档预算分别求解，并在名义设定下九次选出 $\mathbf{p}_{\text{safe}}$。预算连续扫描将经等值根与数值包络核查的切换同数值状态边界分列。21 个预设情景补充检查候选决策对桥参数及尺度形式的敏感性。问题四进一步将前沿变化分成训练算力、非规模时间漂移和未解释项，预训练组分别占实际变化的 25.12%、39.48%、35.40%。

### 8.2 结果的适用范围

**质量与配比。**问题一的强冲突对属于预设筛选规则，逐对统计量未进行多重比较校正。跨维度和跨评分器类型的描述性差异在 0.05 水平下均无显著组间证据。17 个配方域中，11 个域的质量坐标使用共同先验。词数加权近似语料中的文档贡献，实际分词器 token 权重需要另行计算。推荐的新配比及 A12–A15 的大尺度表分别属于代理预测和幂律估计，目标规模实测效果需由新训练核验。

**标度律与质量桥。**B6/B7 支持题目提供的半合成质量机制。真实语料质量干预、跨附件质量坐标桥 $c_Q$ 以及四维组合模型的联合精度需要新的联测实验。A6–A9 的 1M–60M 同配方样本支持排序迁移，但缺少逐配方训练 token 数和独立质量观测，因此 $\gamma_p$ 未识别。大尺度 P05/P50/P95 为数据重抽样与人为桥接情景共同构成的条件敏感性带，其覆盖率需要独立检验。

**优化与能力外推。**问题三的最优性是在三个可执行配比、给定成本函数与代理损失下数值比较所得。数值一阶条件核查支持已发现解的局部求解，连续资源空间的解析全局最优性仍需额外证明。部分状态转移仅由二分定位，$10^{24}$ FLOPs 解属于远距离外推。问题四的损失–能力桥由 C5 校准、C6 新增模型检验。问题三可直接支撑的非远距离预算止于 $10^{22}$ FLOPs，而问题四的算力锚点为 $7.8 \times 10^{24}$ FLOPs，跨问增量只作条件核对。算力变化点及情景参数使用 2025 年 3 月 13 日以前可见的 C4 记录。12、24 个月结果是条件预测，经验区间由 3 个月回测残差和历史正向跃迁幅度扩张。全部有效回测折均未刷新前沿，候选模型没有优于 Persistence 基线的证据。提交日期与发布日期、许可证筛选及任务汇总口径均在正文单独标明。

### 8.3 推广方向

严格互斥尾部与独立性参照可用于其他多指标文本评价。分模块识别与相对质量基线适合多来源实验的条件组合。若进一步取得同配方跨尺度训练、独立质量测量和联合干预数据，可直接检验配比幅度律与四维预测精度。资源优化可扩展到更多实测配比和经过校准的质量成本函数。能力前沿预测需要覆盖真实刷新事件的滚动回测，才能检验相对于持续性基线的增益。

## 参考文献


[1] Guilherme Penedo，et al.，The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale，https://papers.nips.cc/paper_files/paper/2024/hash/370df50ccfdf8bde18f8f9c2d9151bda-Abstract-Datasets_and_Benchmarks_Track.html，2026-09-26。

[2] Benjamin Warner，et al.，Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference，https://aclanthology.org/2025.acl-long.127/，2026-09-26。

[3] Alexander Wettig，Aatmik Gupta，Saumya Malik，Danqi Chen，QuRating: Selecting High-Quality Data for Training Language Models，Proceedings of Machine Learning Research，235：52915–52971，2024。

[4] Sang Michael Xie，Shibani Santurkar，Tengyu Ma，Percy Liang，Data Selection for Language Models via Importance Resampling，https://proceedings.neurips.cc/paper_files/paper/2023/hash/6b9aa8f418bde2840d5f4ab7a02f663b-Abstract-Conference.html，2026-09-26。

[5] Jack W. Rae，et al.，Scaling Language Models: Methods, Analysis & Insights from Training Gopher，https://arxiv.org/abs/2112.11446，2026-09-26。

[6] Danae Diakoulaki，George Mavrotas，Lefteris Papayannakis，Determining Objective Weights in Multiple Criteria Problems: The CRITIC Method，Computers & Operations Research，22(7)：763–770，1995。

[7] Qian Liu，Xiaosen Zheng，Niklas Muennighoff，et al.，RegMix: Data Mixture as Regression for Language Model Pre-training，https://proceedings.iclr.cc/paper_files/paper/2025/hash/5f67d864aae6115374fed7beddd119e0-Abstract-Conference.html，2026-09-26。

[8] Bradley Efron，Bootstrap Methods: Another Look at the Jackknife，The Annals of Statistics，7(1)：1–26，1979。

[9] Hui Zou，Trevor Hastie，Regularization and Variable Selection via the Elastic Net，Journal of the Royal Statistical Society: Series B，67(2)：301–320，2005。

[10] Nicolai Meinshausen，Peter Bühlmann，Stability Selection，Journal of the Royal Statistical Society: Series B，72(4)：417–473，2010。

[11] R. Tyrrell Rockafellar，Stanislav Uryasev，Optimization of Conditional Value-at-Risk，The Journal of Risk，2(3)：21–41，2000。

[12] Jared Kaplan，Sam McCandlish，Tom Henighan，et al.，Scaling Laws for Neural Language Models，https://arxiv.org/abs/2001.08361，2026-09-26。

[13] Jordan Hoffmann，Sebastian Borgeaud，Arthur Mensch，et al.，An Empirical Analysis of Compute-Optimal Large Language Model Training，https://papers.nips.cc/paper_files/paper/2022/hash/c1e2faff6f588870935f114ebe04a3e5-Abstract-Conference.html，2026-09-26。

[14] Yasaman Bahri，Ethan Dyer，Jared Kaplan，Jaehoon Lee，Utkarsh Sharma，Explaining Neural Scaling Laws，Proceedings of the National Academy of Sciences，121(27)：e2311878121，2024。

[15] Stella Biderman，Hailey Schoelkopf，Quentin Gregory Anthony，et al.，Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling，Proceedings of Machine Learning Research，202：2397–2430，2023。

[16] Clémentine Fourrier，Nathan Habib，Alina Lozovskaya，Konrad Szafer，Thomas Wolf，Open-LLM Performances Are Plateauing, Let's Make the Leaderboard Steep Again，https://huggingface.co/spaces/open-llm-leaderboard/blog，2026-09-26。

[17] Jeffrey Zhou，Tianjian Lu，Swaroop Mishra，et al.，Instruction-Following Evaluation for Large Language Models，https://arxiv.org/abs/2311.07911，2026-09-26。

[18] David Rein，Betty Li Hou，Asa Cooper Stickland，et al.，GPQA: A Graduate-Level Google-Proof Q&A Benchmark，https://arxiv.org/abs/2311.12022，2026-09-26。

[19] Yubo Wang，Xueguang Ma，Ge Zhang，et al.，MMLU-Pro: A More

Robust and Challenging Multi-Task Language Understanding Benchmark，https://papers.nips.cc/paper_files/paper/2024/hash/ad236edc564f3e3156e1b2feafb99a24-Abstract-Datasets_and_Benchmarks_Track.html，2026-09-26。

[20] Roger Koenker，Gilbert Bassett，Regression Quantiles，Econometrica，46(1)：33–50，1978。

# 附录 A　图表目录

## 插图


4.1 线性质量分 $Q^{\text{lin}}$ 与有限补偿评分 $Q^{\text{res}}$ 的样本关系。颜色表示冲突强度，虚线表示两种评分相等。 . . . . . 10
4.2 冲突强度与质量下调量。散点为 A1 样本，实线为分箱均值，阴影为图内标注的 95% 自助法区间。 . . . . . 10
4.3 SCM 学到的分域非线性响应。四个示例域的横轴为域混合份额，纵轴为 SCM 预测的 13 域平均损失；阴影为重抽样 95% 区间，虚线标出训练集份额，空心点为拟合曲线的局部低点。 . . . . . 13
4.4 三个示例域相对基准份额的 SCM 预测平均损失变化。实线为代理曲线，阴影为自助重抽样区间；竖线标示训练集份额。 . . . . . 13
4.5 SCM 相对对数线性基线在 1M、60M、1B 固定检验集上的 Spearman 增量。横线为配对 Bootstrap 95% 区间。 . . . . . 14
4.6 136 个交互候选的稳定选择。仅 github×stackexchange 入选；内嵌图比较 SCI 与 SCM 在开发集和固定检验集上的排序相关。 . . . . . 14
4.7 质量重加权指数 $\eta$ 的交叉验证选择。训练集五折 Spearman 在 $\eta = 0$ 时最高，继续增大指数未增加排序能力。 . . . . . 16
4.8 配方域-验证域跨域迁移矩阵。17 个训练域的逐验证域对数响应系数按列中心化；深色边框标出同名域对应项。 . . . . . 16
4.9 凸包约束下的风险控制推荐。上图目标式的风险系数为 $\rho = 0.25$、不确定性系数为 $\lambda = 0.10$；下图浅色区域标出 $\mathbf{p}_{\text{risk}}$ 的上尾约 20% 验证域。$\mathbf{p}_{\text{rob}}$ 是对照，$\mathbf{p}_{\text{safe}}$ 与 $\mathbf{p}_{\text{risk}}$ 为待验证候选。 . . . . . 19
5.1 B1 经典标度律的拟合诊断：（a）观测与预测；（b）残差；（c）逐模型留一误差。 . . . . . 21
5.2 经典标度律下的规模分布与基础训练算力前沿。 . . . . . 21
5.3 H1 跨来源检验：（a）B2 拟合；（b）B4/B5 来源参数，横轴为 $s_f$、点旁标注为 $E_f$；（c）校准前后误差。 . . . . . 22
5.4 H3 质量项的识别与边界：（a）B6 质量响应；（b）候选形式相对 AIC；（c）B7/B8 方向比较。 . . . . . 23
5.5 B7 新质量等级的半合成验证：（a）预测与观测；（b）分质量等级残差。 . . 24
5.6 相同配方在 1M 与 60M 尺度下的平均损失秩位。 . . . . . 25
5.7 问题一质量坐标到数据轴等效倍率的条件映射。$c_Q = 0.75, 1, 1.25$ 为桥接情景，横轴质量分来自问题一。 . . . . . 27
5.8 四个参考配置的参数轴与数据轴等效资源比。两类标记对应式(5.13)的独立单轴换算，虚线为名义资源比 1。 . . . . . 27
5.9 四个参考配置中参数量、训练 token 数和质量的局部相对损失弹性。各点的 $N, D, Q_A$ 不同，弹性仅描述各自参考点附近的模型响应。 . . . . . 28
5.10 质量提高 0.1 的参数替代倍率及低质量模型的反向补偿倍率。点为不同参考配置下的模型内等损失解，不代表实际训练的算力节省。 . . . . . 28
5.11 百亿参数以上经典骨架与 SAED 的预测损失中心曲线和条件敏感性带。阴影为混合重抽样及人工桥接情景的 5–95% 分位，不解释为独立实测置信区间。 . . . . . 30
5.12 配比尺度设定对最优参数量 $N^\star$ 和训练 token 数 $D^\star$ 的相对影响。比较对象为图中标注的参考配比，曲线是条件模型计算结果。 . . . . . 30
5.13 $C = 10^{22}$ FLOPs 下关键输入扰动对最优参数量与质量—参数替代倍率的相对影响。指数端点来自跨族重抽样；桥接系数与配比尺度指数为预设情景。 30

6.1 附件 C7 各模型族的上下文长度观测范围与计算成本阈值。 . . . . . 32
6.2 三档预算下的模型结果与算力分配。(a) 三档预算下的可执行最优预测损失，实线对应指数型、幂函数型及对数渐进型质量成本；点线为理论参考配比的模型内结果。(b) 三档预算下的最优质量水平，指数型在低预算取得内部解，幂函数型从基线质量起步，对数渐进型在低预算即达到质量上界；中高预算三者均达到 $Q_A^\star = 1$。(c) 九个名义最优解的算力预算组成，每档预算内从左到右为指数型、幂函数型、对数渐进型质量成本；深色为基础训练，绿色为长文本注意力，黄色为质量治理。 . . . . . 34
6.3 连续预算下的最优质量轨迹与训练 token 数 / 参数量比。三条曲线分别对应指数型、幂函数型、对数渐进型质量成本；折点与质量体制的活跃约束变化相对应。 . . . . . 35
6.4 连续预算下的可执行预测损失与理论参考下界，以及两者的模型内相对差距。虚线参考曲线不参加有限候选决策。 . . . . . 35
6.5 三类质量成本的 R0、R1、R2 体制区间与数值转移点，以及指数型质量成本下的预算—上下文质量体制相图。深色短线表示部分质量投资窗口端点，菱形表示对数渐进型的端点跳变；虚线为 $L_{\text{ctx}}^{\text{crit}} = 30000$ 的开销诊断线；颜色对应 R0、R1、R2。 . . . . . 36
6.6 上下文长度对最优预测损失和治理质量的条件影响。三条曲线分别对应 $10^{19}$、$10^{22}$、$10^{24}$ FLOPs，虚线标识 $L_{\text{ctx}} = 30000$ 的开销诊断点。 . . . . . 36
6.7 指数型质量成本下的资源弹性与 $10^{22}$ FLOPs 时的预算份额。弹性曲线按预算求局部数值差分，折点附近须结合体制转移判读。 . . . . . 37
6.8 $10^{22}$ FLOPs 下名义可执行方案在联合参数情景中的归一化遗憾，以及三档预算下名义解与最小最大遗憾候选的最坏情景遗憾。 . . . . . 38
7.1 C1 各许可证组的模型记录占比与最高综合分。 . . . . . 39
7.2 严格许可证口径下的累计最高综合分与月度提交量。 . . . . . 39
7.3 C8 六个基准家族早晚期逐任务 Top-5 均分及变化。 . . . . . 40
7.4 参数量等能力线（$q = 0.9$）：左图为预训练基础模型，右图为对话 / 微调模型。灰点为观测模型，彩色线对应不同固定综合分，虚线为样本截止时间；纵轴为所需参数量（十亿，对数轴）。 . . . . . 41
7.5 C8 逐任务参数量与提交时间系数（logit 尺度）。 . . . . . 42
7.6 训练算力、时间漂移及未解释项的能力贡献与分参数区间 Top-5 前沿变化。 44
7.7 C3 在 2019–2025 年的能力分布、年度最高分与累计记录。 . . . . . 44
7.8 损失–能力 Logistic 桥的 C5 校准、C6 外层检验与全量重估。 . . . . . 46
7.9 不同口径下参数量前沿时间系数的敏感性。 . . . . . 47
7.10 2025 年 3 月起两类模型的能力前沿条件轨迹与经验带。 . . . . . 48

## 表格

3.1 符号说明表 . . . . . 6
4.1 A1 组合权重最高的六项质量指标 . . . . . 8
4.2 A1 中冲突倍率最高的五组可识别指标对 . . . . . 9
4.3 非重叠扩展余集的域内冲突复核 . . . . . 11
4.4 七个质量域的文档均值与词数加权质量分 . . . . . 11
4.5 SCM 平滑常数与岭系数的 A4/A5 五折 Spearman . . . . . 12
4.6 配比模型的平均损失排序能力（Spearman 相关） . . . . . 15
4.7 MPR-MTL 的逐域排序与绝对校准分尺度检验 . . . . . 17
4.8 候选配比的逐域风险代理及观测身份 . . . . . 18

4.9 相同配比下的跨尺度排序比较及损失来源 . . . . . 18
4.10 风险约束候选配比与配方域质量信息 . . . . . 19
5.1 规模骨架的分层检验：各行指标对应不同数据角色，不作合并评分 . . . . . 22
5.2 B4/B5 来源偏移与可约损失乘子分列估计 . . . . . 23
5.3 B6 内部拟合的六种质量作用形式 . . . . . 24
5.4 SAED 各模块的参数、证据与识别边界 . . . . . 29
6.1 问题三的配比候选与证据身份 . . . . . 31
6.2 三种质量成本下的有限候选名义配置（$L_{\text{ctx}} = 4096$；$N, D$ 单位为十亿） . . 34
6.3 名义配置下的质量状态转移及机制证据（$L_{\text{ctx}} = 4096$） . . . . . 35
6.4 21 情景下的最坏遗憾与模型内等效算力倍数（遗憾列采用指数型质量成本） 37
7.1 等能力线在不同参考参数量处的条件换算 . . . . . 41
7.2 固定参数量区间内首末三个月的 Top-5 综合分比较 . . . . . 42
7.3 2021–2023 与 2024–2025 年间的能力前沿变化分解（分；括号内为占实际变化的比例） . . . . . 43
7.4 训练算力变化点及条件情景（拟合记录截至 2025 年 3 月 13 日） . . . . . 45
7.5 3 个月滚动回测的 OOF MAE（分；两类模型各 3 折，均无前沿刷新） . . . 47
7.6 两类模型前沿的条件预测（以 2025 年 3 月实测前沿为锚；区间为期限扩张经验区间） . . . . . 48
B.1 四问的主要数据角色与结果身份 . . . . . 55
B.2 A1 上 22 项指标的方向、维度与权重 . . . . . 55
B.3 六个有对应质量域的配方质量映射 . . . . . 56
B.4 跨问题使用的参数数值与取得方式 . . . . . 57

# 附录 B　数据角色与补充结果

## B.1　训练、检验与情景数据的分工

四问的数据来自附件 A、B、C 中不同的观测和构造过程。表B.1把主要参数的估计数据与后续检验分开列出；折外预测、固定检验集和半合成新质量等级对应不同证据层级，跨附件组合则需另加识别假设。表中未把幂律外推表当作新模型训练的实测结果。

表 B.1　四问的主要数据角色与结果身份

| 问题 | 模型拟合与选择 | 检验或情景输入 | 结果身份 |
|---|---|---|---|
| 一 | A1 确定质量预处理与权重；A4/A5 拟合配比代理并作五折选择 | A2/A3 作非重叠扩展复核；A6–A9 作固定检验；A12–A15 是给定的幂律外推表 | 质量为指标构造分；新推荐配比为代理预测 |
| 二 | B1 估计规模骨架；B6 选择并估计质量乘子 | B2–B5 核查规模迁移；B7 用新质量等级检验；A6–A9 的同配方记录核查排序 | B7 属半合成外层检验；配比幅度指数未识别 |
| 三 | 接收问题一、二的既定模型及三个可执行候选，按给定预算数值求解 | C7 上下文长度及 21 个无概率权重的参数情景用于敏感性分析 | 最优配置与等效算力均为模型内条件预测 |
| 四 | C1–C4 截点以前的匹配记录估计能力与算力关系；C5 校准损失–能力桥 | C6 新增模型作桥接检验；C8 核对任务分项；滚动原点产生 3 个月 OOF | 12、24 个月结果为带经验区间的条件情景 |

## B.2　22 项质量指标的方向与权重

表B.2列出问题一在 A1 上冻结的指标方向及三套权重，名称保持附件字段拼写；D1–D4 依次为语义价值、语言表达、信息结构和干净度。正向、负向及区间型指标经正文所述映射后，均按“值越大质量越高”解释。数值取自队伍计算表 `indicator_weights.csv`，仅为排版四舍五入，程序计算使用未舍入值。

表 B.2　A1 上 22 项指标的方向、维度与权重

| 指标字段 | 维度 | 方向 | 熵权 | CRITIC | 组合权重 |
|---|---|---|---|---|---|
| fineweb_edu | D1 | 正向 | 0.06744 | 0.04181 | 0.05576 |
| fluency_en | D2 | 正向 | 0.05989 | 0.06190 | 0.06394 |
| modernbert_cleanliness | D4 | 正向 | 0.06881 | 0.05454 | 0.06433 |
| modernbert_readability | D2 | 正向 | 0.05659 | 0.05305 | 0.05754 |
| modernbert_reasoning | D1 | 正向 | 0.12069 | 0.05124 | 0.08259 |
| modernbert_professionalism | D1 | 正向 | 0.17912 | 0.09520 | 0.13713 |
| dsir_books | D1 | 正向 | 0.01995 | 0.03320 | 0.02703 |
| dsir_wiki | D1 | 正向 | 0.01988 | 0.03326 | 0.02700 |
| dsir_math | D1 | 正向 | 0.01901 | 0.03208 | 0.02593 |
| qurater | D1 | 正向 | 0.06024 | 0.03931 | 0.05110 |
| rps_doc_unigram_entropy | D3 | 正向 | 0.03829 | 0.03808 | 0.04010 |

续表 B.2　A1 上 22 项指标的方向、维度与权重

| 指标字段 | 维度 | 方向 | 熵权 | CRITIC | 组合权重 |
|---|---|---|---|---|---|
| rps_doc_frac_unique_words | D3 | 正向 | 0.05034 | 0.06111 | 0.05824 |
| rps_lines_ending_with_terminal_punctution_mark | D2 | 正向 | 0.08867 | 0.06675 | 0.08079 |
| ad_en | D4 | 负向 | 0.01898 | 0.05343 | 0.03344 |
| rps_doc_frac_no_alph_words | D4 | 负向 | 0.01540 | 0.03736 | 0.02519 |
| rps_doc_frac_chars_top_2gram | D4 | 负向 | 0.01744 | 0.04009 | 0.02777 |
| rps_doc_frac_chars_top_3gram | D4 | 负向 | 0.01549 | 0.04070 | 0.02636 |
| rps_lines_uppercase_letter_fraction | D4 | 负向 | 0.06116 | 0.06611 | 0.06677 |
| rps_lines_numerical_chars_fraction | D4 | 负向 | 0.01466 | 0.04430 | 0.02676 |
| rps_doc_word_count | D3 | 区间 | 0.00200 | 0.01592 | 0.00593 |
| rps_doc_num_sentences | D3 | 区间 | 0.00387 | 0.02443 | 0.01021 |
| rps_doc_mean_word_length | D2 | 区间 | 0.00208 | 0.01616 | 0.00609 |

### B.3　质量域到配方域的映射

问题一的七域汇总值见表4.4。在 17 个配方域中，三个域直接映射、三个域按 A16 对应关系近似映射，其余 11 个采用共同先验值 0.613690。表B.3列出六个有对应质量域的结果，计算表为 `selected_quality_domain_mapping.csv`。近似映射系数为 0.8；表中 $Q_i$ 是实际进入式(4.13)与问题二质量基线的数值，不等同于独立测得的训练效果。

表 B.3　六个有对应质量域的配方质量映射

| 配方域 | 对应质量域 | 映射方式 | 映射系数 | $Q_i$ |
|---|---|---|---|---|
| arxiv | arxiv | 直接 | 1.0 | 0.7953 |
| github | github | 直接 | 1.0 | 0.5171 |
| stackexchange | stackexchange | 直接 | 1.0 | 0.6450 |
| wikipedia_en | wikipedia | 近似 | 0.8 | 0.5426 |
| gutenberg_pg_19 | book | 近似 | 0.8 | 0.6090 |
| pile_cc | commoncrawl | 近似 | 0.8 | 0.6151 |

### B.4　标度律参数与识别状态

表B.4补充正文表5.4未全部展开的 B1 参数。$E, A, \alpha, B, \beta$ 来自 B1 经典损失骨架拟合；$\kappa$ 只在 B6 的半合成质量机制内估计。$c_Q$ 与 $\gamma_p$ 的正值是情景输入，不与前述估计参数混列为同一类观测证据。

表 B.4　跨问题使用的参数数值与取得方式

| 参数 | 使用数值 | 取得数据 | 用途与状态 |
|---|---|---|---|
| $E$ | 1.689842 | B1 | 经典损失渐近项，拟合值 |
| $A$ | 406.297691 | B1 | 参数量项系数，拟合值 |
| $\alpha$ | 0.339987 | B1 | 参数量指数，拟合值 |
| $B$ | 409.784320 | B1 | 训练数据项系数，拟合值 |
| $\beta$ | 0.279893 | B1 | 数据量指数，拟合值 |
| $\kappa$ | 0.459661 | B6 | 半合成质量乘子；聚类重抽样区间 $[0.437820, 0.487343]$ |
| $c_Q$ | 1 | 跨附件桥接约定 | 中心情景；0.75、1.25 用于敏感性分析 |
| $\gamma_p$ | 0 | 结构零假设 | 名义无衰减；0.05、0.10 为人为敏感性情景，数据未识别幅度指数 |

# 附录 C　计算顺序与结果复核

以下顺序用于核对正文各表图的输入与输出身份，不把条件预测解释为新训练实测。各统计量、目标函数和约束以正文公式为准。

1. 在 A1 上确定 22 项指标的预处理、四维组合权重、冲突尾部阈值与缺失值填补参数；冻结后计算 A2/A3 非重叠余集和七域质量表。表B.2给出冻结权重，表4.4给出汇总分。
2. 在 A4/A5 内进行配比模型的五折选择和交互稳定筛选；固定检验集的秩相关单独列于表4.6。把推荐配比标记为代理预测，并把 A12–A15 的 10B、70B 表标记为幂律外推。
3. 在 B1 估计规模骨架，在 B6 选择质量形式并估计 $\kappa$，再用未参与选择的 B7 新质量等级计算 RMSE 和 $R^2$。同配方 1M–60M 记录检验排序；由于缺少逐配方的训练 token 数及独立质量观测，令 `gamma_p_identified=false`，问题三名义情景采用 $\gamma_p = 0$。
4. 对三个可执行配比及三种质量成本函数求解问题三的有限候选优化；预算与质量状态的数值结果分别见表6.2、表6.3。21 个扰动情景是无概率权重的压力测试，表6.4中的遗憾和等效算力倍率均为模型内条件量。
5. 问题四按预测截点锁定 C1–C4 的可见信息。C5 校准损失–能力桥，C6 新增模型给出模型身份未参加校准的检验；滚动原点 OOF 仅评估具备新提交记录的 3 个月窗口。12、24 个月预测以截点实测前沿锚定，并单列长期情景适用边界。

## C.1　AI 工具使用说明

本队使用 ChatGPT 辅助资料线索整理、参考文献信息核对、依据队员提供的模型与结果起草和修订论文文字、修改部分绘图脚本，以及检查 LaTeX 排版与图文对应关系。附件数据、模型方案和数值结果由参赛队提供；论文中的公式、引文、表图数值及最终 PDF 由队员核验后提交。AI 输出不作为模型结论或文献证据。

# 附录 D　关键计算代码

以下代码摘自四问的最终计算 notebook；所调用的参数、数据表和辅助函数由对应 notebook 初始化。

## D.1　问题一：指标赋权与质量冲突消解

```
def entropy_weight(X):
    X = np.asarray(X, float) + 1e-12; n = X.shape[0]
    P = X / X.sum(axis=0)
    e = -(P * np.log(P)).sum(axis=0) / np.log(n)
    d = 1 - e
    return d / d.sum()

def critic_weight(X):
    X = np.asarray(X, float)
    sd = X.std(axis=0, ddof=1)
    Rm = np.corrcoef(X, rowvar=False)
    C = sd * (1 - Rm).sum(axis=1)
    return C / C.sum()

def power_mean(S, p, Wd=W_DIM_VEC):
    Sv = np.clip(np.asarray(S, float), EPS, 1.0)
    Wd = np.asarray(Wd, float) / np.sum(Wd)
    if abs(p) < 1e-9:
        return np.exp((Wd * np.log(Sv)).sum(axis=1))
    return ((Wd * Sv ** p).sum(axis=1)) ** (1.0 / p)
```

## D.2　问题二：经典标度律与质量乘子

```
def L_classic(N, D, th):
```

```
    return (th['E'] + th['A'] * np.asarray(N, float) ** (-th['alpha'])
            + th['B'] * np.asarray(D, float) ** (-th['beta']))

def psi_Q_abs(q, kappa=None):
    k = KAPPA if kappa is None else float(kappa)
    return 1.0 + k * (1.0 - np.asarray(q, float))

def psi_Q_rel(q, q0, kappa=None):
    return psi_Q_abs(q, kappa) / psi_Q_abs(q0, kappa)
```

## D.3 问题三：广义损失与稳健决策

```
def L_gen(N, D, QA, Q0_A, th=None, kappa=None,
          psi_p0=1.0, gamma=None, c_q=None, scale_form=None):
    th = TH if th is None else th
    pp = psi_p_at_N(N, psi_p0,
                    GAMMA_P if gamma is None else gamma, scale_form)
    qrel = psi_Q_rel(QA, Q0_A, kappa, c_q)
    return th['E'] + R_fun(N, D, th) * qrel * pp

def robust_minimax_regret(C, L, cost):
    scen_opt = []
    for sc in SCENARIOS:
        z = solve_executable(C, L, cost, th=sc['th'],
                             kappa=sc['kappa'], gamma=sc['gamma'],
                             c_q=sc['c_q'], scale_form=sc['scale_form'],
                             nscan=71)
        z['scenario_origin'] = sc['name']
        scen_opt.append(z)
    nominal = solve_executable(C, L, cost)
    candidates = scen_opt + [dict(nominal,
                                  scenario_origin='nominal_solution')]
    scenario_opt_loss = {
        sc['name']: next(z['loss'] for z in scen_opt
                         if z['scenario_origin'] == sc['name'])
        for sc in SCENARIOS
    }
    rows = []
    for j, x in enumerate(candidates):
        regrets = []
        for sc in SCENARIOS:
            ls = eval_decision(x, sc)
            lstar = scenario_opt_loss[sc['name']]
            denom = max(lstar - sc['th']['E'], 1e-12)
            regrets.append((ls - lstar) / denom)
        rows.append({'idx': j, 'max_regret': max(regrets),
                     'mean_regret': float(np.mean(regrets))})
    best = min(rows, key=lambda r: (r['max_regret'], r['mean_regret']))
    x = candidates[best['idx']].copy()
    x.update({'max_regret': best['max_regret'],
              'mean_regret': best['mean_regret'],
              'uncertainty_scope': UNCERTAINTY_SCOPE})
    return x, scen_opt
```

## D.4 问题四：损失–能力桥接与月度前沿

```
def fit_bridge_adaptive(d, pooled_prior=5.0, n_iter=4):
    w = d['w_prior'].values.astype(float).copy()
    th = fit_bridge_weighted(d, w)
    for _ in range(n_iter):
        rr = d['LB_Average'].values - bridge(
            th, d['Val_Loss'], d['chat'])
        pv = float(np.mean(rr ** 2))
```

```
        inv = np.zeros(len(d), float)
        for tier in d['tier'].unique():
            mask = d['tier'].values == tier
            v = (np.sum(rr[mask] ** 2) + pooled_prior * pv) / (
                mask.sum() + pooled_prior)
            inv[mask] = 1 / max(v, 1e-6)
        w = d['w_prior'].values * inv
        w = w / max(w.max(), 1e-12)
        th = fit_bridge_weighted(d, w, th)
    return th, w

def monthly_frontier(df, end_date=None):
    d = df.copy()
    if end_date is not None:
        d = d[d['date_sub'] <= pd.Timestamp(end_date)]
    d = d.sort_values('date_sub')
    p = d['date_sub'].dt.to_period('M')
    grp = d.groupby(p).agg(month_max=('S', 'max'),
                           n=('S', 'size')).sort_index()
    grp['F'] = grp['month_max'].cummax()
    grp['M'] = grp['n'].cumsum()
    grp['tau'] = np.array([
        (x.to_timestamp(how='end') - T0).days / 30.4375
        for x in grp.index
    ])
    return grp
```