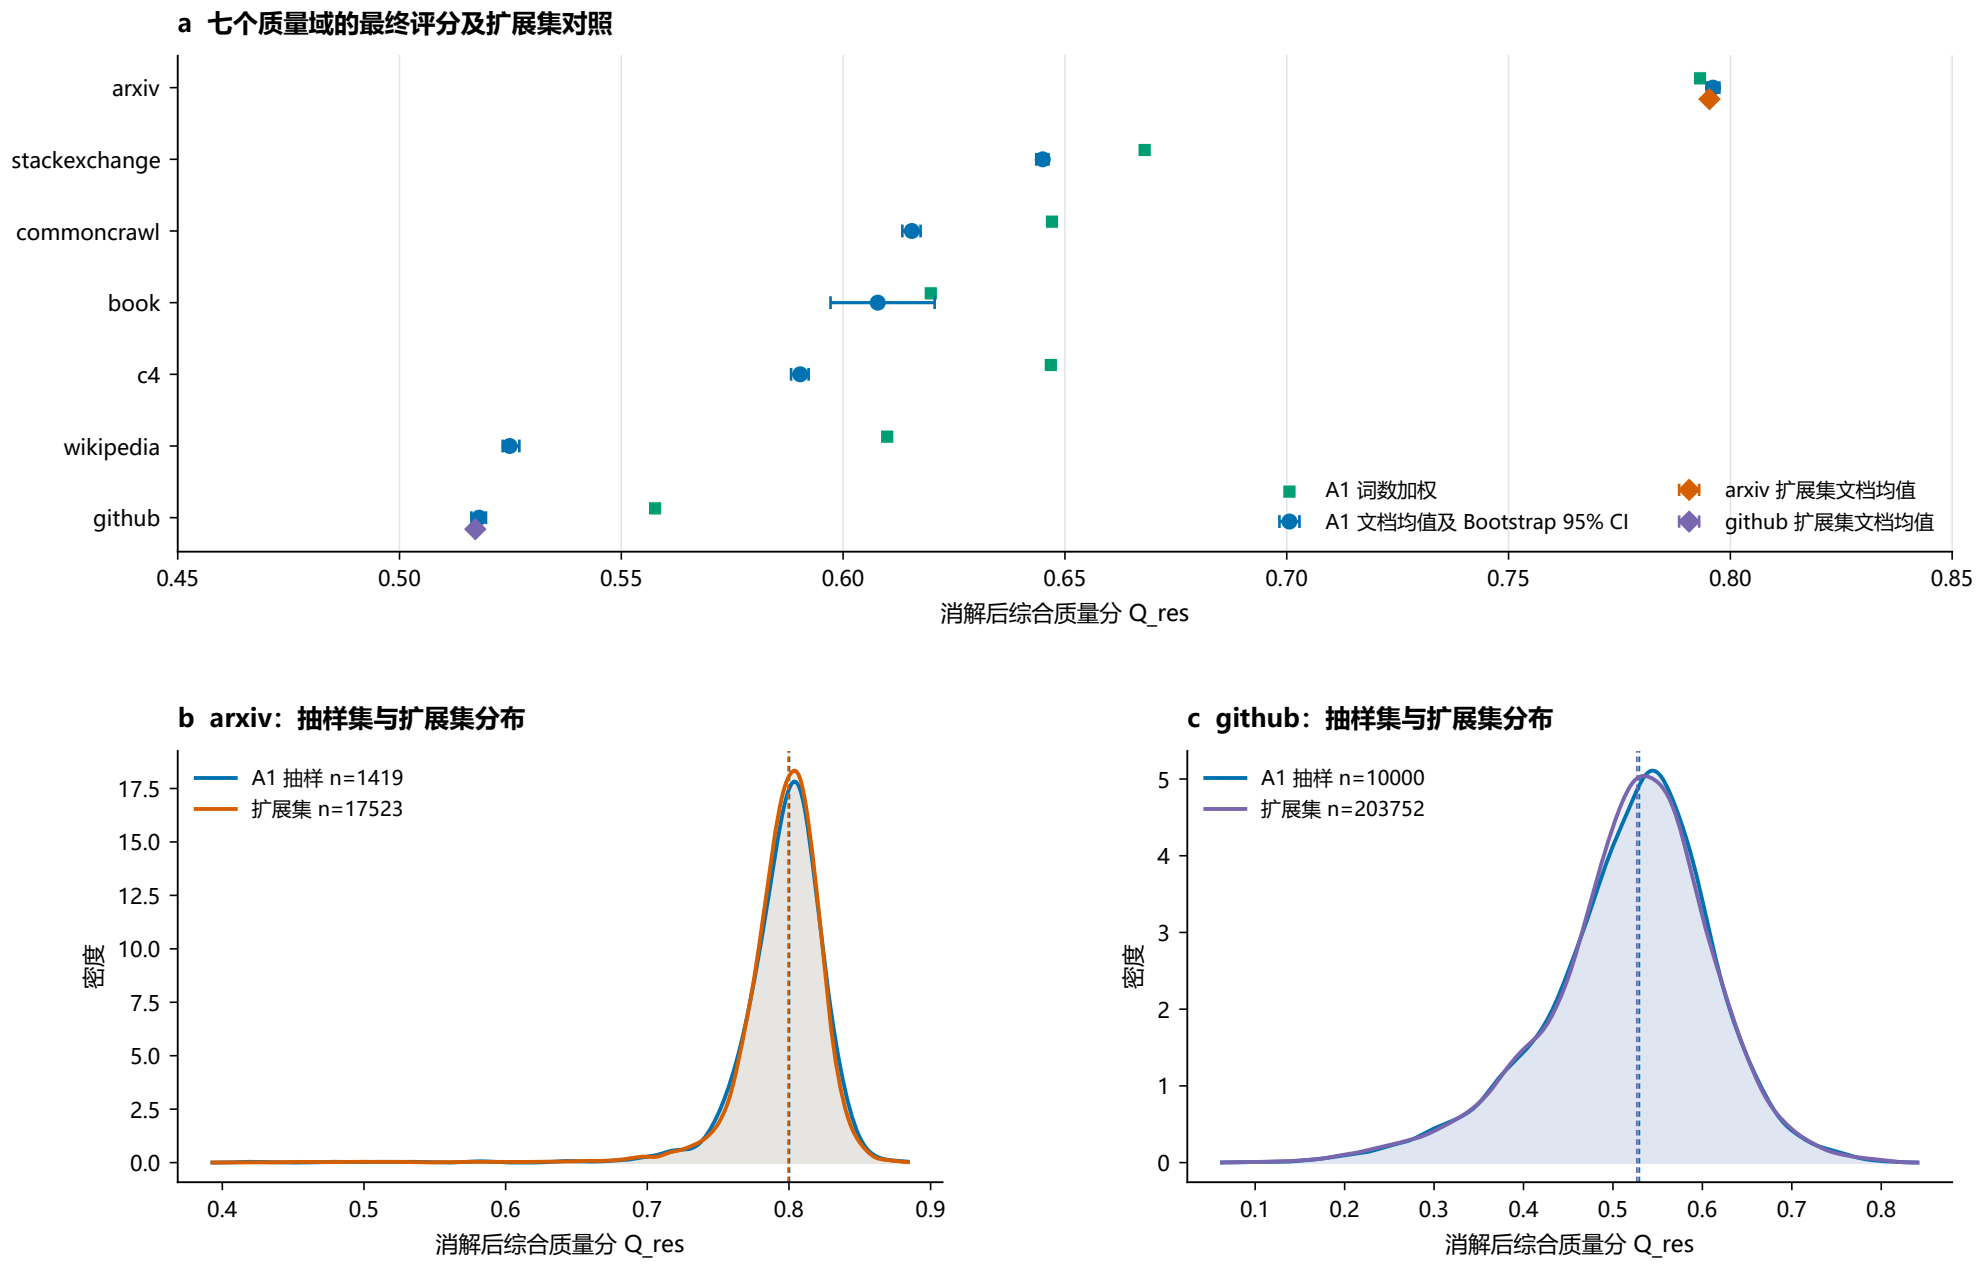
a 七个质量域的最终评分及扩展集对照
arxiv
stackexchange
commoncrawl
book
c4
wikipedia
github
A1 词数加权
A1 文档均值及 Bootstrap 95% CI
arxiv 扩展集文档均值
github 扩展集文档均值
0.45
0.50
0.55
0.60
0.65
0.70
0.75
0.80
0.85
消解后综合质量分 Q_res
b arxiv：抽样集与扩展集分布
A1 抽样 n=1419
扩展集 n=17523
密度
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
0.4
0.5
0.6
0.7
0.8
0.9
消解后综合质量分 Q_res
c github：抽样集与扩展集分布
A1 抽样 n=10000
扩展集 n=203752
密度
0
1
2
3
4
5
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
消解后综合质量分 Q_res