中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生数学建模竞赛

题　目：<u>算力约束下提升大语言模型能力的资源配置建模</u>

摘要：

针对大语言模型训练中的数据质量、领域配比、模型与数据规模、上下文开销以及能力前沿，本研究建立一条按证据来源分层的求解链。先对 A 组全部质量记录作字段语义转换与去重，继而用独立配方检验配比响应；在 B 组拟合标度律并检查迁移；最后在题给成本代理下求条件配置，并在 C 组冻结日期和评测协议后考察能力变化。模型输出按原始记录、半合成、估算与外推分开解释。

问题一中，A1–A3 共读入 272,505 条记录，因 11,419 个重复 ID 而得到 261,086 个唯一 ID。由 22 个源字段构成的操作性质量指数，在唯一集合中的均值为 0.445436。A1 预先冻结的相反极端信号阈值下，冲突比例为 11.6319%；该比例描述不同评分器意见相反，不等同人工质量真值。对 17 域配比的 512 个训练配方作五折模型选择，二次 Ridge 在 256 个同尺度留出配方上的 MAE 为 0.14207，优于训练均值基线 0.22560。但把原值预测直接搬到 60M 和 1B，MAE 上升至 1.4531 和 2.9411，表明跨尺度只能谨慎解释排序。

问题二中，B1 的 1176 行可由两项幂律以极小误差重现，留一个模型尺寸的 MAE 为 0.000108；固定参数用于 B2 半合成轨迹时 MAE 达 1.1784，揭示内部拟合与迁移能力的明显落差。质量弹性仅能在 B6 半合成质量量尺下条件估计；A/B 没有共同的质量锚点，因而不能声称已识别完整的质量、配比和规模联合作用。

问题三用三档预算、三类质量成本和 C7 五个上下文情景求解 180 组配置。题设注意力项与传统训练项相等的解析临界上下文为 30,000；C7 中 32,768 和 131,072 已越过该值。在 B1 实测尺寸范围内，10^{24} FLOPs 档最多仅用预算的 11.70%，说明高预算的真正最优解处于已验证范围之外。优化中的质量收益仅列 B6 条件情景。

问题四以 2025 年 3 月 13 日为 C1 截止日，剔除 C4 中晚于该日的 475 条记录。C8 的 44 项任务形成 6208 个精确协议组，不能把同名异协议成绩直接合并。C6 高可比桥接只有 7 条，Loss–平均能力相关的区间跨零；六项能力的短期留出上，加入时间项均未改进仅规模基线。由于 C1 仅覆盖 278 天，12/24 个月输出只作为未校准情景，不作为已经验证的能力预测。研究的主要方法贡献是将来源独立性、单位、协议和支持域直接嵌入模型验证与优化约束，避免由表面高拟合推出过强结论。

关键词：数据质量　领域配比　广义标度律　算力约束优化　能力前沿

目录

1 问题重述与证据边界 **4**
1.1 决策变量与四问关系 4
1.2 数据层级与排除规则 4
1.3 解释范围 4
2 建模假设、符号与识别条件 **4**
2.1 限制性假设 4
2.2 主要符号 5
3 问题一：质量评价与领域配比响应 **5**
3.1 质量字段转换与去重 5
3.2 相反极端信号的定义与结果 6
3.3 17 域配比响应、模型选择与留出 6
3.4 本问边界 8
4 问题二：规模标度律与质量项的可识别性 **8**
4.1 B1 主模型与留尺寸检验 8
4.2 跨来源误差 8
4.3 质量弹性、替代率与不可识别性 9
5 问题三：外生上下文下的算力配置 **10**
5.1 优化对象、量纲与质量处理成本 10
5.2 解析降维与一阶条件 11
5.3 三档预算的条件解 11
5.4 结构转移的操作性定义 13
6 问题四：评测可比性与能力前沿边界 **13**
6.1 时间冻结和模型属性 13
6.2 C8 逐任务协议审计 13
6.3 规模关联、时间项与短期留出 14
6.4 Loss–能力桥接 14
6.5 12 和 24 个月的情景范围 15
7 模型评价与后续验证 **16**
7.1 可复核性 16
7.2 局限与针对性改进 16
7.3 阶段结论 17
参考文献 **18**
参考文献 **18**
附录 A 附录：复算路径与 AI 辅助记录 **19**
1.1 可运行入口 19
1.2 人工复核的关键节点 19

1.3 AI 使用说明 19

1 问题重述与证据边界

1.1 决策变量与四问关系

题目要求描述参数量 N、训练 Token 数 D、数据质量 Q、17 域配比向量 $\boldsymbol{p}$ 与验证 Loss 的关系，在外生上下文长度 L_{ctx} 和算力预算 C_{max} 下给出资源配置，并评估由 Loss 到下游能力的迁移。经典计算最优训练工作以参数和数据量的权衡为主 [1]，Pythia 提供同系列检查点 [2]，RegMix 将配比选择表述为回归问题 [3]。这些公开研究只界定可借鉴的方法，不为本题附件的统计真实性背书。

四问并非四个可独立拼接的回归。质量字段来自 A1–A3，配比–Loss 来自 A4–A15，规模–Loss 来自 B1 等表，下游能力来自 C1–C8。若不同数据集没有共同的 Q、$\boldsymbol{p}$ 和同一验证 Loss，就不存在由简单表连接推出的完整 $L(N, D, Q, \boldsymbol{p})$。因此本文明确区分可识别的子关系与条件情景，前者进入经验结论，后者用于说明成本机制和数据需求。

1.2 数据层级与排除规则

A1–A3 的记录可能重复，三个文件不能被当作独立样本的直接拼接。A4–A11 有公开 RegMix 仓库对应的八个原始 CSV，本文对这八份附件作字节比较，结果 8/8 一致；该核验不覆盖 A1–A3、B 或 C。A12–A15 为估算 Loss，不能作为跨规模实测验证。A16 的 17 域映射包含直接、近义和未核实推断三个等级，不能把推断当成标注真值。

B1 虽标为已有训练轨迹，但被简单幂律几乎精确重现；对其生成机制未有独立证据。B2、B6 及其补充是半合成数据，B10 是估算表。C1 是同一次排行榜快照，C3 含来源不同的历史条目；C4 的发布时间跨度越过 C1 截止日。C8 逐任务 JSON 中的 `task_hashes`、版本与有效样本量决定可比性，`chat_template` 只是评测元数据，不作为模型指令或论文文本。赛题附加 PDF 中的浅色段落仅纳入来源审计，不作为结论依据。

1.3 解释范围

本文所有质量、规模和能力数字均保留原始量纲。$N_B = N/10^9$、$D_B = D/10^9$ 只用于 B 组拟合；算力公式中的 N, D 始终为实际计数。标准误和区间对应所注明的抽样单元，不能用逐行区间代替跨来源不确定性。附录记录 AI 辅助过程与队伍复核要求。

2 建模假设、符号与识别条件

2.1 限制性假设

在问题一，配方按表中 `index` 一对一连接，四舍五入造成的配比和误差通过逐行归一化修正；验证目标预先设为 13 个验证域 Loss 的等权均值。A1 仅用来冻结质量分位尺度与冲突阈值，A2/A3 不重新估计这些阈值。质量指数权重用于比较候选数据的操作性尺度，不假定它就是人工质量或下游效用。

问题二将 B1 数据视为特定模型族与验证口径的记录，参数 E, A, B, α, β 仅在该数据口径下估计。B6 的 Q 与 A1 的 Q 不共享观测点，使用 B6 质量弹性时必须标记为情景。问题三的成本式是题设代理，不表示真实硬件的端到端耗时；上下文长度按 C7 离散取值。问题四的 C1 提交时间只作为评测观察时间，不冒充模型训练或公布时间。

2.2 主要符号

表 2.1　主要符号与量纲

符号	单位	含义
N, N_B	个、十亿个	可训练参数量及 B 组计量变量
D, D_B	Token、十亿 Token	训练数据量及 B 组计量变量
Q, Q_0	无量纲	B6 半合成质量情景与基准值
$\boldsymbol{p}$	无量纲	17 个输入域的 Token 占比，$\sum p_d = 1$
L	交叉熵	与指定来源和验证集合对应的 Loss
$C_{\max}$	FLOPs	训练总预算上限
L_{ctx}	Token	外生上下文窗口长度
η	无量纲代理系数	题设长上下文成本系数 2×10^{-4}
S_{ik}	分数	模型 i 在任务 k 的 0–100 能力分数

所谓“质量提升与扩参等价”只指给定参考点的 Loss 微分替代，不自动考虑成本。所谓“结构转移”在本文只指预算活跃状态或变量边界集合改变，不把平滑成本份额变化解释为相变。

3 问题一：质量评价与领域配比响应

3.1 质量字段转换与去重

原始 A1、A2、A3 分别有 51,230、17,523 和 203,752 行；A2 与先前数据重叠 1,419 个 ID，A3 重叠 10,000 个 ID。全部记录进入来源分层诊断，合并域统计只给重复 ID 一次权重，最终有 261,086 个唯一 ID。A1 提供文本内容，扩展文件没有同等原文可核查；后者的质量结论不能被称为经过全量人工阅读。

字段形状与方向先按数据集说明核对 [4]。对 `fluency_en` 和 `ad_en` 的二元 logits 取正向类别的 softmax 概率；对四个 ModernBERT 六级 logits 分别求 0 至 5 等级的期望并除以 5；QuRating 四个分量各自归一化后再平均。三个 DSIR 分数是域相关度而非统一的好坏标签。对于直接体现重复和异常字符的结构字段，按方向转换；对长度、句数等方向不明的字段，以 A1 中位分位为中心而非单调追求最大值。

令 F_j^{A1} 为 A1 第 j 个有效字段的经验分布，$r_{ij} = F_j^{A1}(x_{ij})$。缺失字段取中性分位 0.5，按字段组构成

$$Q_i = 0.8\,\overline{r}_{\text{ML},i} + 0.1\,\overline{r}_{\text{DSIR},i} + 0.1\,\overline{r}_{\text{struct},i}. \tag{3.1}$$

对方向不明的结构字段采用 $\max(0, 1 - 2|r_{ij} - 0.5|)$；因这是一项启发式假设，另算 ML 权重降低到 0.6 和保守调和平均的替代指数。权重不是由人工评分或下游 Loss 校准的估计量。唯一 ID 的均值为 0.445436；其逐记录近似 95% 区间为 $[0.444946, 0.445925]$，并未处理同一来源或近重复文本带来的相关性。图 3.1 展示领域均值；A16 的 17 个配方域中只有 3 个直接映射，另有 3 个近义和 11 个未经核实的推断映射，因此域质量排序不能作为配比优化的硬约束。

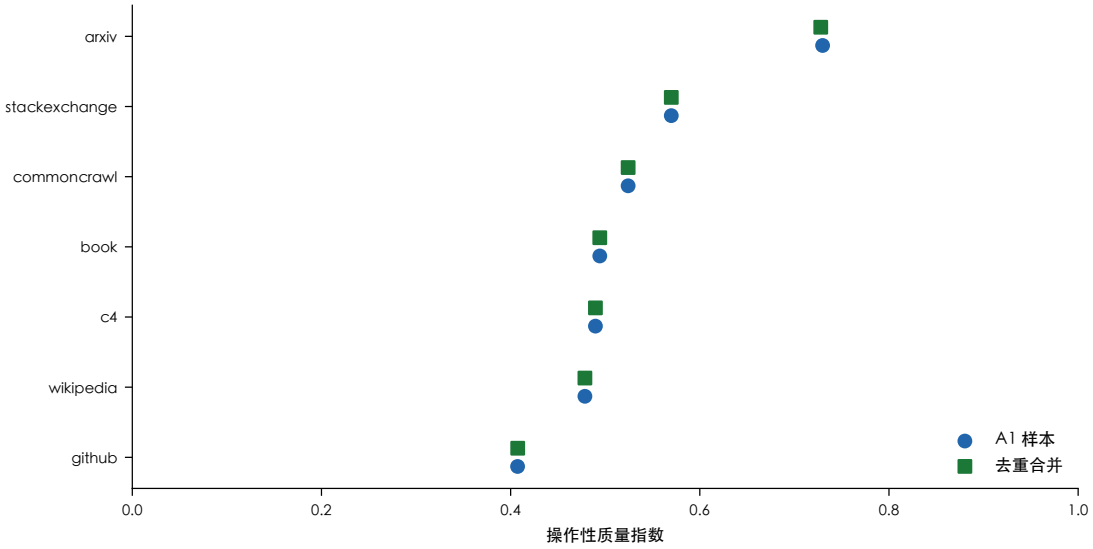


图 3.1　A1 与去重扩展集的领域质量均值。指数为事先定义的操作性尺度，不是人工真值。

3.2 相反极端信号的定义与结果

为了避免“指标冲突”依赖事后选阈，先在 A1 冻结语义、流畅性、无广告三个组的 20% 与 80% 分位。若某记录至少一个组位于高端、另一个组位于低端，记为冲突。这个定义比较有区别的信号组，避免同一个评分器的多维 logits 被误当独立意见。A1 冲突率为 11.6319%，A2 为 4.4684%，A3 为 5.6603%，去重后的合并率为 6.7587%。图 3.2 用 Wilson 区间表达按记录计数的不确定性。不同来源的比例差异可能由采样策略、域组成、阈值参照共同造成，不能解释为某来源的人类质量优劣。

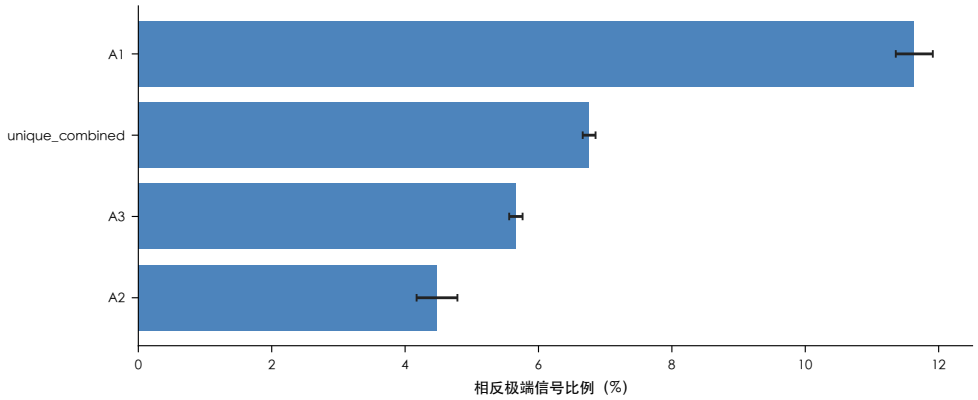


图 3.2　A1 冻结阈值下相反极端质量信号的来源比例及 Wilson 95% 区间。

3.3 17 域配比响应、模型选择与留出

RegMix 的经验是先用多种小模型配比拟合响应，再考虑放大 [3]。本题 17 个输入域与 13 个验证域不同，不把两组列按名称机械相乘。对于配方 m，预先定义等权目标 $Y_m = 13^{-1}\sum_{v=1}^{13} L_{mv}$，并按 `index` 一对一连接输入配方和验证 Loss。所有配比非负，CSV 行和只存在小于 0.005 的四舍五入误差，逐行除以行和。候选模型为线性 Ridge 与

二次 Ridge，二次特征含 p_d 及所有 $p_d p_e$，惩罚系数从 $\{0.01, 0.1, 1, 10, 100\}$ 中按五折训练集 MAE 选择。

A4/A5 的 512 行用于训练和选型，选中二次 Ridge、惩罚系数 10，五折 MAE 0.17723。A6/A7 的 256 行从未进入拟合，MAE 0.14207、$R^2 = 0.5921$，低于训练均值基线 MAE 0.22560。图 3.3 给出模型形式和惩罚强度的交叉验证敏感性；其纵轴严格是训练集交叉验证 MAE，不把它误标为测试误差。

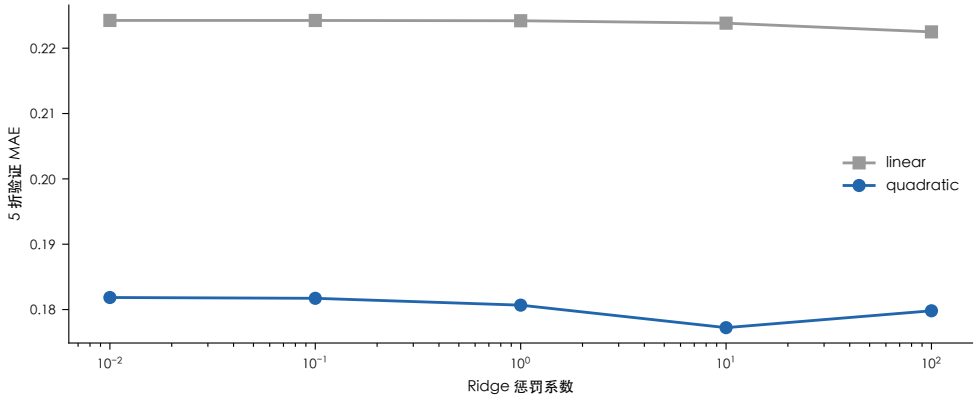


图 3.3　线性与二次 Ridge 配比响应在训练集五折中的 MAE 敏感性。

跨规模迁移提供更严苛的反证。固定 1M 拟合的模型直接预测 60M 与 1B 配方表，原值 MAE 上升为 1.4531 和 2.9411，R^2 显著为负；但秩相关仍为 0.7799 和 0.6369。图 3.4 将同尺度与跨尺度的观察值、预测值分开显示。由此可以使用同尺度响应比较候选配方，却不能将其绝对 Loss 外推到大模型；若要跨尺度预测，至少还需要独立规模校准或直接训练。A12–A15 的 10B/70B Loss 为估算，不能用来抵消此失败。本文没有报告超出训练配方支持域的“最优配比”。

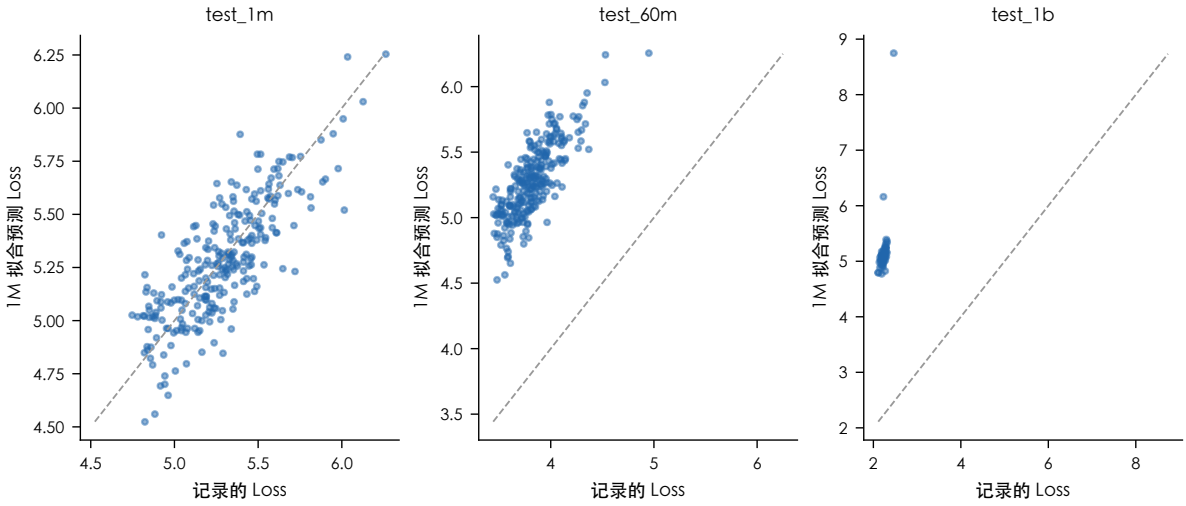


图 3.4　配比模型在 1M 留出与 60M、1B 跨尺度表中的原值偏差。虚线为预测等于记录值。

3.4 本问边界

质量指数回答“不同评分信号如何被统一和诊断”，配比模型回答“固定小模型验证口径下配方怎样关联 Loss”。两者没有一批共同的训练实验来估计质量、配比和规模之间的交互；把高 Q 域直接加权到最优配方会重复使用不可比的数据。问题三因而固定 A4 的平均配比，仅对 B6 的质量变量作明示条件情景。

4 问题二：规模标度律与质量项的可识别性

4.1 B1 主模型与留尺寸检验

在 B1 的 1176 条 N_B, D_B, L 记录上拟合

$$L(N_B, D_B) = E + AN_B^{-\alpha} + BD_B^{-\beta}, \qquad N_B, D_B > 0, \quad A, B, \alpha, \beta > 0. \tag{4.2}$$

采用带边界的非线性最小二乘和三个初值，得到 $E = 1.689798$、$A = 0.353980$、$B = 1.240306$、$\alpha = 0.339977$、$\beta = 0.279878$。样本内 MAE 为 0.000105。按八个模型尺寸整组留一重新拟合，而不是随机打散相邻检查点，MAE 仍为 0.000108；仅用 $6N_BD_B$ 作单自变量幂律的留尺寸 MAE 为 0.05564。图 4.5 中点几乎落在对角线上。

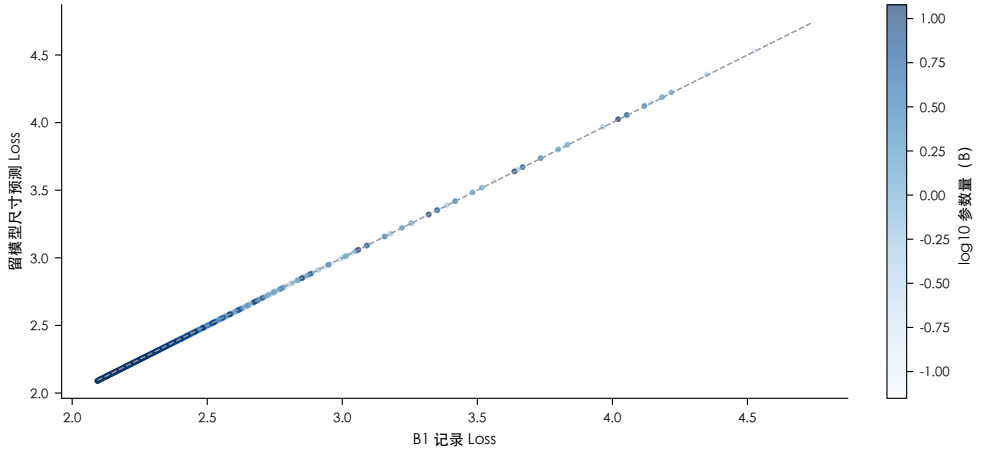


图 4.5　B1 留模型尺寸的预测与记录 Loss；过近重合需结合来源生成机制审查。

近乎完美的误差远小于跨族差异，也与附件中明显的四舍五入幂律结构相符。它证明式 (4.2) 可以压缩当前 B1 表，但不证明独立公开训练轨迹同样遵从这些系数。图 4.6 用留一尺寸重新拟合的参数范围展示 α, β 对当前八个尺寸的稳定性；该范围不是基于独立实验的 95% 置信区间。

4.2 跨来源误差

固定 B1 的全部参数，对 B2 半合成训练轨迹、B4 跨族表、B5 文献整理表和 B10 大模型估算表直接预测。四者 MAE 依次为 1.1784、0.2273、0.1707、0.000614。B2 的偏差不因同样高的排序相关而消失；B10 本身由拟合公式估算，接近零的误差不是独立验证。图 4.7 中 B2 残差远大于 B1，B4/B5 也存在族间偏移。因此 E 很可能混合了词表、验证集和训练族的口径差异。将 B2 加入同一个最小二乘只会掩盖迁移失败，并不能自动修

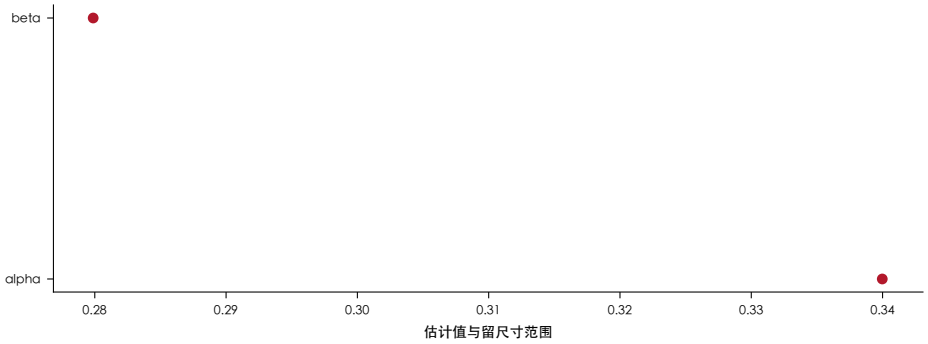


图 4.6　B1 标度指数在留一模型尺寸拟合中的范围。

复它。

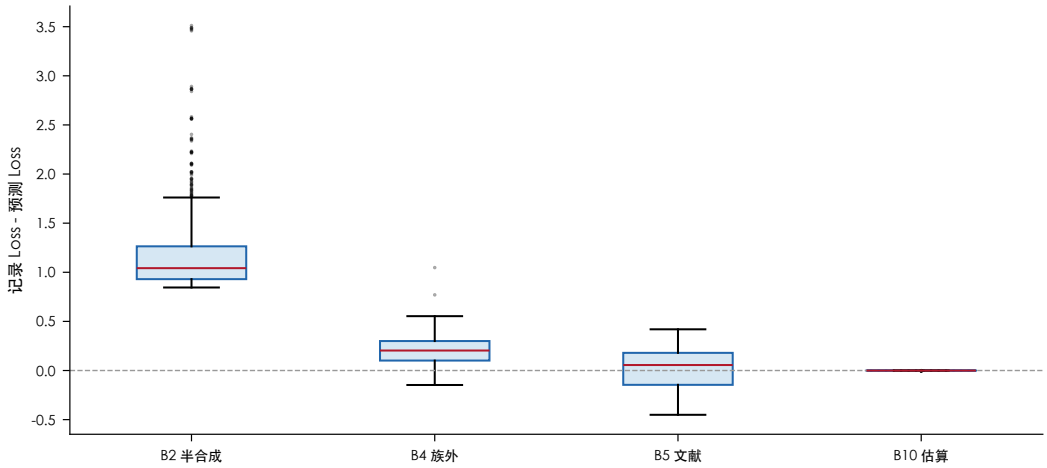


图 4.7　固定 B1 系数后的跨来源 Loss 残差；B2 为半合成，B10 为估算。

4.3 质量弹性、替代率与不可识别性

只在 B6 半合成网格中引入有效 Token 量

$$D_{\text{eff}} = D_B Q^{\gamma}, \qquad L_{\text{B6}} = E + AN_B^{-\alpha} + B(D_B Q^{\gamma})^{-\beta} + \delta_{\text{B6}}. \tag{4.3}$$

固定 B1 系数后得到 $\gamma = 0.8047$、$\delta_{\text{B6}} = 0.0834$，B6 内部 MAE 0.07760。图 4.8 展示质量分层残差，表明单一幂指数仍留有结构性偏差。A1 的质量指数与 B6 Q 没有共同记录；两者虽然都写作 Q，却不能互相数值代入。

式 (4.3) 在给定参考点的损失弹性为

$$\epsilon_N = -\frac{\alpha A N_B^{-\alpha}}{L}, \quad \epsilon_D = -\frac{\beta B (D_B Q^{\gamma})^{-\beta}}{L}, \quad \epsilon_Q = \gamma \epsilon_D. \tag{4.4}$$

若只求局部等 Loss 替代，$\mathrm{d}N_B/\mathrm{d}Q = -L_Q/L_N < 0$；质量提高带来的损失减少可以被参数减少抵消。若问“质量提高 ΔQ 相当于扩参多少”，则取 $L_Q/L_N \cdot \Delta Q > 0$。在 $N_B = 1, D_B = 300, Q = 0.5$ 且完全接受 B6 条件式时，$\Delta Q = 0.1$ 对应约 0.110 B 的参数增量；该数值不含质量处理算力、不保证有限步准确，也不是 A 组质量指数的换算系数。

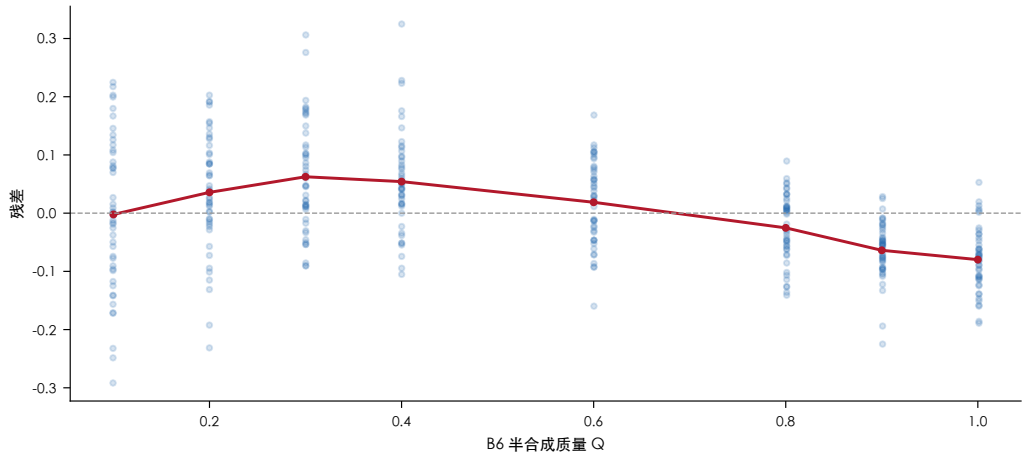


图 4.8　B6 半合成质量网格的拟合残差及按质量值的均值。

无法识别的对象同样重要：A4/A5 同时改变 $\boldsymbol{p}$ 却缺少逐配方统一 Q，B1/B6 改变 N, D, Q 却缺少相同 17 域配方，因而 $Q \times \boldsymbol{p}$ 和规模与配比的交互没有联合实验支持。后续优化只在固定配比、分层标明质量假设后进行。

5 问题三：外生上下文下的算力配置

5.1 优化对象、量纲与质量处理成本

题设给出的三项总成本代理写为

$$C(N, D, Q; L_{\text{ctx}}) = (6 + \eta L_{\text{ctx}})ND + D\,[g(Q) - g(Q_0)]_+, \qquad \eta = 2 \times 10^{-4}, \tag{5.5}$$

其中 N, D 是实际参数与 Token 数，$[z]_+ = \max(0, z)$。本文使用 $Q_0 = 0.5$，这是 B6 半合成质量尺度上的基准，而非 A1 质量指数的中位数。按题设比较

$$g_{\text{e}}(Q) = 10^7 \exp(6Q), \qquad g_{\text{p}}(Q) = 5 \times 10^9 Q^4, \qquad g_{\text{l}}(Q) = 2 \times 10^9 \ln(1 + 10Q). \tag{5.6}$$

g 的单位是每 Token 处理 FLOPs 代理。17 域配比固定为 A4 的平均训练配方，所有 17 个分量和为 1；问题一没有证据支持把这个配方称为最优，因此优化只对 N, D, Q 作条件分析。固定质量主情景取 $Q = Q_0$。半合成质量情景只借用式 (4.3) 的弹性 γ，将质量因子写为 $(Q/Q_0)^\gamma$，使 $Q = Q_0$ 时严格回到 B1 基线；B6 的数据集偏移 δ_{B6} 不转移到 B1。此归一化是明确的条件假设，不等同对 B6 全曲线的跨源验证。两种情景均不增加未经校准的独立配比收益。

给定预算 $C_{\max}$ 与外生 L_{ctx}，求

$$\min_{N,D,Q} \; E + AN_B^{-\alpha} + B\{D_B(Q/Q_0)^\gamma\}^{-\beta} \quad \text{s.t.} \quad C(N, D, Q; L_{\text{ctx}}) \le C_{\max}, \tag{5.7}$$

固定质量情景把 γ 置零。B1 实测区间为 $N_B \in [0.070542, 11.965825]$、$D_B \in [0.134, 299.893]$。这个矩形仍是观察到的轨迹点的宽松外包络，矩形内部不代表所有组合都曾被训练。另给 $N_B \le 1000, D_B \le 20000$ 的宽范围纯外推情景；大模型名录 B9 只证明一些尺寸在表

中出现，不证明式 (4.2) 在该范围有效。

5.2 解析降维与一阶条件

因为损失对 D 单调下降，对于任意给定的 N, Q，最佳 Token 数由预算或数据上界决定：

$$D^*(N,Q) = \min\left\{D_{\max}, \frac{C_{\max}}{(6+\eta L_{\text{ctx}})N + [g(Q)-g(Q_0)]_+}\right\}. \tag{5.8}$$

由此把三维优化变为有界的 $(\log N, Q)$ 搜索，使用差分进化和多个局部起点互相核对。若结果落在 $D_{\min}$ 以下便判不可行；最后再以式 (5.5) 直接重算各成本。内部、$Q > Q_0$ 且预算活跃时，拉格朗日条件给出 $-L_N = \lambda(6+\eta L_{\text{ctx}})D$、$-L_D = \lambda\{(6+\eta L_{\text{ctx}})N + \Delta g\}$、$-L_Q = \lambda D g'(Q)$。当最优点处于边界时，应以单侧导数与互补松弛替代内部条件；本文记录实际活跃边界而非强行报告一个不存在的内部 KKT 点。

训练项与注意力项相等当且仅当

$$6ND = \eta N D L_{\text{ctx}} \quad\Longleftrightarrow\quad L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30{,}000. \tag{5.9}$$

C7 给出 2048、4096、8192、32768、131072 五档；后两档超过该阈值。临界值只是成本份额相等的位置，不能凭此宣称优化解不连续。图 5.9 显示三类 g 下，在中档预算的成本份额随上下文连续变化。

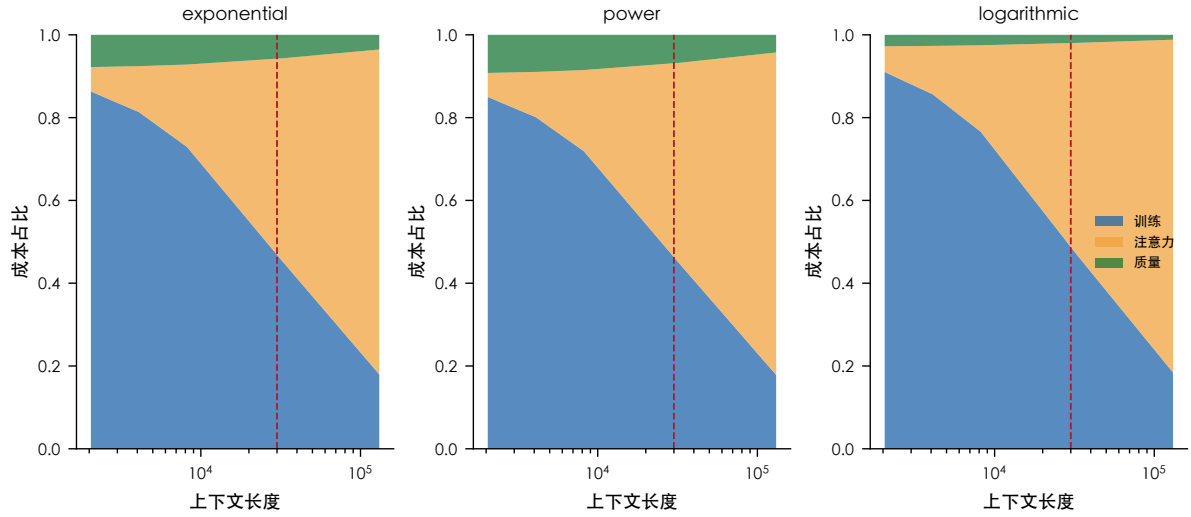


图 5.9　10^{22} FLOPs、B6 条件质量情景中，上下文长度对训练、注意力与质量处理成本份额的影响。红虚线为解析阈值 30,000。

5.3 三档预算的条件解

表 5.2 给出指数型质量成本、$L_{\text{ctx}} = 2048$ 的示例。固定质量行只使用 B1 规模–数据 Loss 子模型；条件质量行还依赖半合成 B6 的质量指数。高预算行的两种情景都先触及 B1 的 N, D 上界。图 5.10 另显示宽范围外推时的参数量和 Token 决策，只有情景意义。

在全部 180 组情景中，预算重算的最大相对超出仅 4.44×10^{-16}，三项成本份额和的最大偏差为 2.22×10^{-16}。图 5.11 更重要地揭示，当约束为 B1 尺寸外包络时，最高

表 5.2　指数质量成本和短上下文的 B1 范围内条件解

预算 FLOPs	情景	N_B	D_B	Q	预测 Loss	使用率
10^{19}	固定质量	0.2213	7.0497	0.5000	2.9989	100%
10^{19}	B6 条件质量	0.2763	5.0047	0.6261	2.9892	100%
10^{22}	固定质量	5.2024	299.8930	0.5000	2.1432	100%
10^{22}	B6 条件质量	7.0775	203.2635	1.0000	2.1115	100%
10^{24}	固定质量	11.9658	299.8930	0.5000	2.0934	2.30%
10^{24}	B6 条件质量	11.9658	299.8930	1.0000	2.0571	2.42%

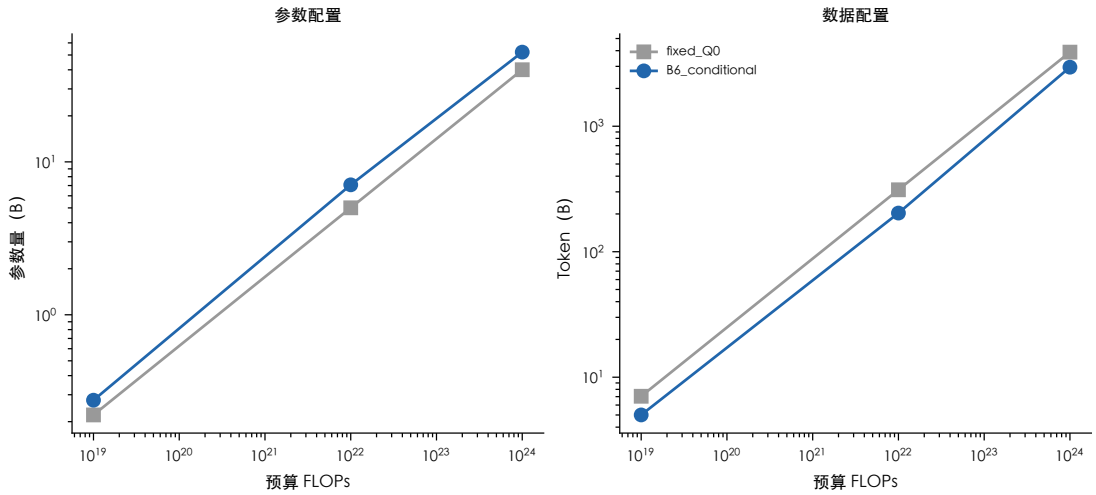


图 5.10　三档预算下的参数与 Token 配置；宽范围框用于外推敏感性，不代表 B1 已验证区间。

档预算的使用率仅 2.30%–11.70%，所以该档在经验支持域中没有预算受限的内部最优。仅扩大数值搜索盒便让宽范围情景用尽预算，恰恰说明高预算结论依赖外推假设。

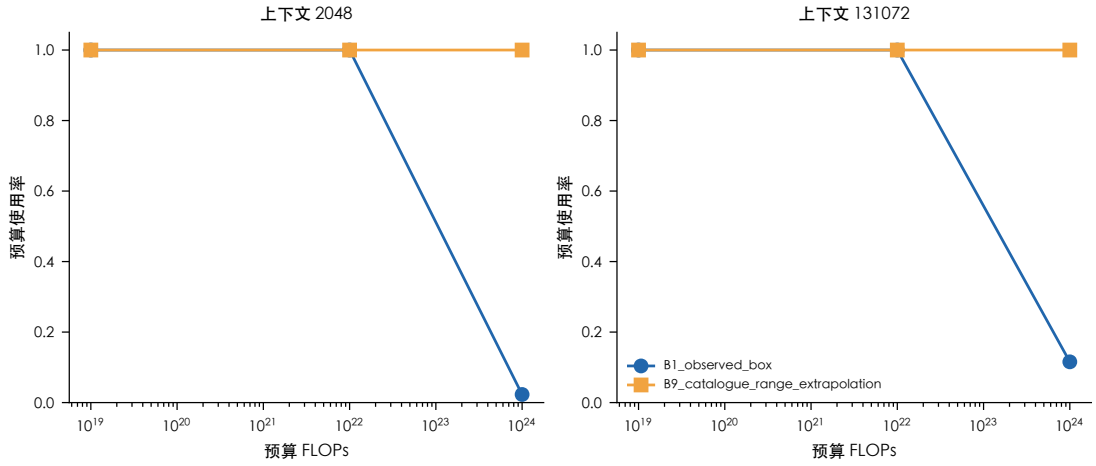


图 5.11　B1 尺寸外包络与宽范围外推盒的预算使用率对比。

5.4 结构转移的操作性定义

预先把“结构转移”定义为活跃约束集合发生变化：预算是否活跃、N, D, Q 哪些达到预设上下界。图 5.12 显示低中预算活跃，而高预算在 B1 盒中不再活跃。这是已定义优化域内的边界切换，并非现实训练策略的相变。成本份额跨越 50% 只有连续竞争意义；若要声称真实技术策略转移，需要高预算同一 Loss 口径的新训练记录、质量干预成本和边界外检验。

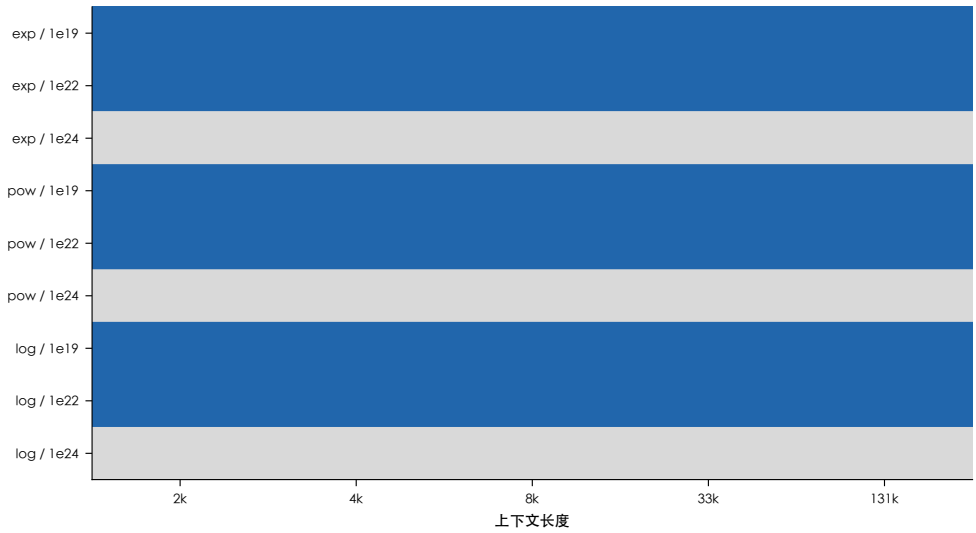


图 5.12　B1 尺寸外包络中预算约束的活跃状态；蓝色为预算用尽，灰色为先达数据范围边界。

6 问题四：评测可比性与能力前沿边界

6.1 时间冻结和模型属性

以 C1 最后提交日 2025 年 3 月 13 日作为观察截止日。C1 有 4576 条六任务完整分数，最早日期 2024 年 6 月 8 日，跨度仅 278 天。C4 有 3523 个模型条目，其中 475 条发布日期晚于截止日；若不剔除，会把后来发布的信息用于过去的预测。C4 的训练 FLOPs、Token 总数仅 1390、1424 条非空，且 C1 与 C4 的模型名并非共同 ID。以唯一的规范化模型基名、公布时间不越界、参数量比例在 0.5–2 之间的保守规则作暂定匹配，仅得 106 条，占 C1 的 2.32%；即使这 106 条也需逐个核对身份。因而不能把 C4 完整案例的训练算力分布投射为全部上榜模型的分布。

C1 的 `Type` 区分预训练、持续预训练、聊天后训练、领域微调、模型合并等；`Hub License` 不等于“开放权重”的充分证据。C4 的 `Open model weights?` 只有在匹配成立且时间有效时才使用。下文规模–时间回归限于 C1 中 266 个唯一预训练模型，不把后训练分数与预训练规模效应合并。

6.2 C8 逐任务协议审计

C8 共 1958 个 JSON，4 个无法解析。按 C1 截止日期的日精度判断，其余文件均未越界。对剩余文件按模型选截止日前最新版本，仅提取任务数值成绩、metric 名、

`task_hashes`、任务版本、原始与有效样本量。得到 1861 个模型、44 个任务的 80,038 个分数记录；任务、metric、hash、version、有效样本量精确相同才进入同一个协议组，共形成 6208 组。多个 JSON 版本不按文件数重复计模型。原 JSON 中的 `chat_template` 与自然语言指令字段完全跳过。

IFEval、GPQA diamond、MMLU-PRO、MATH algebra hard 的最常见单协议组仅覆盖该任务模型的 38.88%、23.42%、20.03%、13.62%。图 6.13 表明逐任务数据对“同名即同协议”的假设不支持。因此六任务的 C1 综合分只能先作为 C1 自己的统一面板分析，不能用 C8 中来自不同哈希的分数无条件重算。

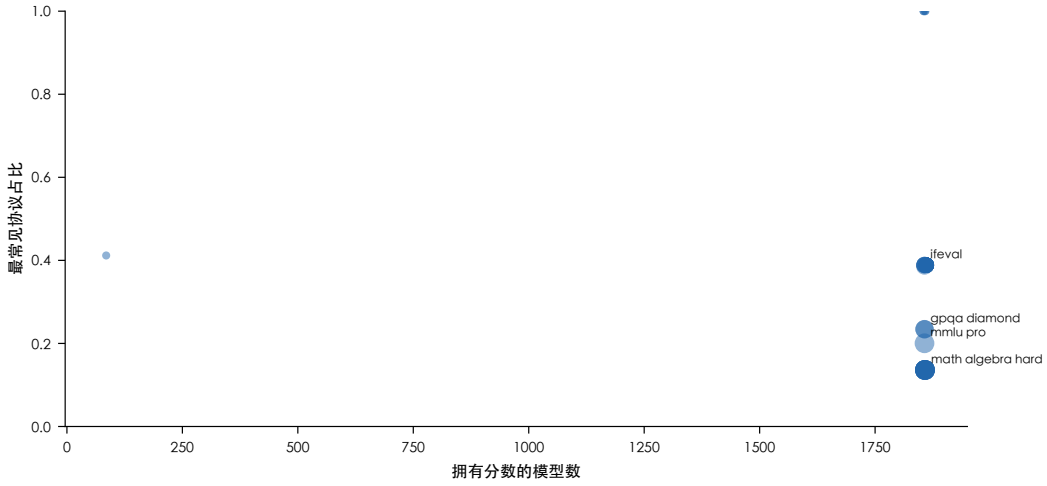


图 6.13　C8 任务模型覆盖数与最常见协议组的占比。每点为一项任务，标出四项典型任务。

6.3 规模关联、时间项与短期留出

在 266 个预训练模型中，对每个 C1 任务分数 S_{ik} 拟合描述式

$$S_{ik} = a_k + b_k \log_{10} N_{B,i} + c_k t_i + \varepsilon_{ik}, \tag{6.10}$$

其中 t_i 为距 C1 首日的月数，仅表示提交观察时间。用 HC3 稳健标准误描述系数不确定性；最后 60 天留出，不参与短期模型估计。规模系数和时间系数均是条件关联，不是资源扩大或技术进步的因果贡献。由于同一时期上榜模型的系列、训练数据、后训练与评测选择共同变化，时间残差不具有唯一机制解释。

六项任务的短期留出均出现“规模 + 时间”MAE 高于“仅规模”MAE。以 IFEval 为例，两者分别为 10.589、7.046 分；MATH Lvl 5 分别为 6.967、3.305 分。完整六任务误差见图 6.14。这并不证明技术不进步，而是说明附件中的提交日期和样本选择不能支撑一个稳定的月度提升项，更不能分解出可信的“非规模技术进步占比”。

6.4 Loss–能力桥接

C6 的 75 条 Loss 与排行榜分数配对被标为高可比 7 条、中可比 68 条。全部配对的平均能力与 Loss 的 Pearson 相关为 -0.510，但高可比子集仅 -0.397，其 Fisher 95% 区间 $[-0.885, 0.507]$ 跨越零。图 6.15 用相同标尺展示这种来源层级差异。相关方向并不足

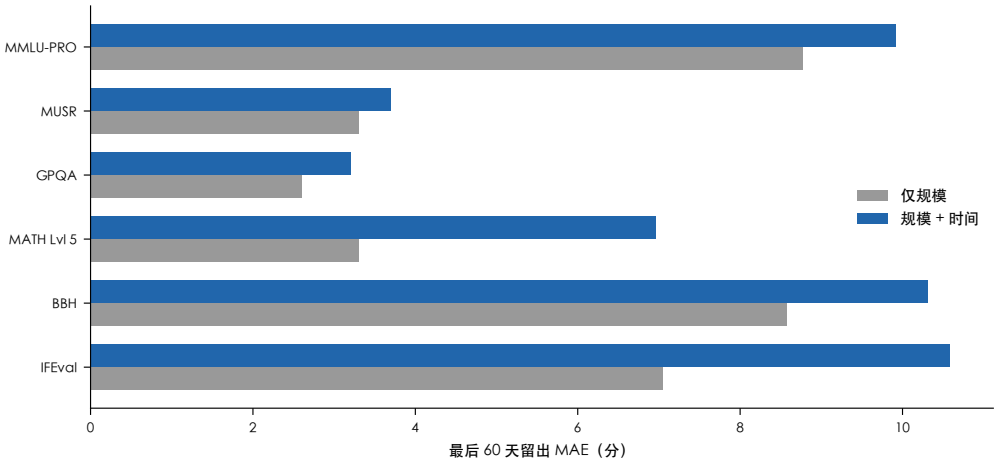


图 6.14　最后 60 天留出中，六任务的仅规模与规模加时间回归 MAE。

以校准式 (4.2) 的 Loss 到能力转换；把全部 75 条混合回归只会提升表面样本量而降低可比性。

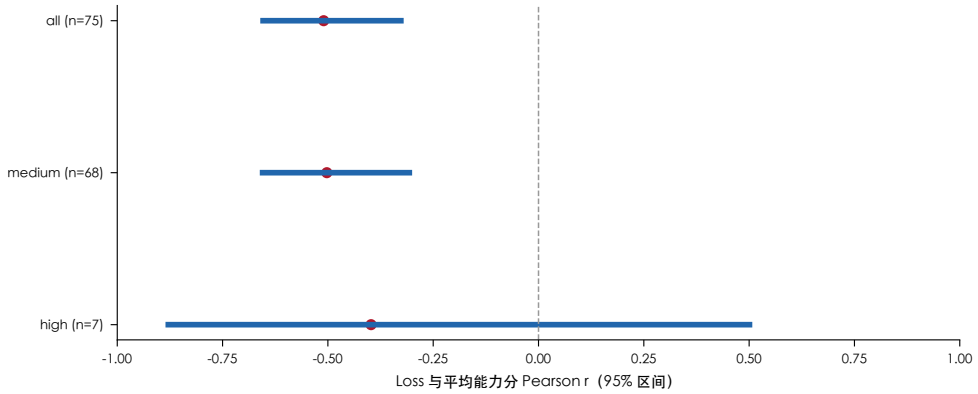


图 6.15　按 C6 可比等级分层的 Loss–平均能力相关与 Fisher 95% 区间。

6.5 12 和 24 个月的情景范围

以每月预训练模型的任务 90% 分位作为操作性前沿；一月和三月的提交模型数及类型不同，该分位数仍有选择偏差。以最后观察月的分位值为起点，分别给出持平、短期线性斜率和斜率敏感性包络，所有任务分数截在 $[0, 100]$。图 6.16 展示 12 与 24 个月的计算结果。包络由 278 天内的月份变化外推，既不是已校准预测区间，也没有 12/24 个月滚动回测覆盖率；当某任务近月分位下降，持续斜率甚至触到 0 分边界，这进一步说明不能把机械外推当作合理技术预言。

若要得到可以检验的长期能力预测，至少需要同协议、跨 24 个月的独立纵向面板，模型系列或任务版本的稳定标识，以及 C4 训练算力、Token 和开放权重状态的可核查匹配。在此之前，本文的实证结论是长期预测不可验证，而非给出缺乏覆盖率依据的具体“最可能分数”。

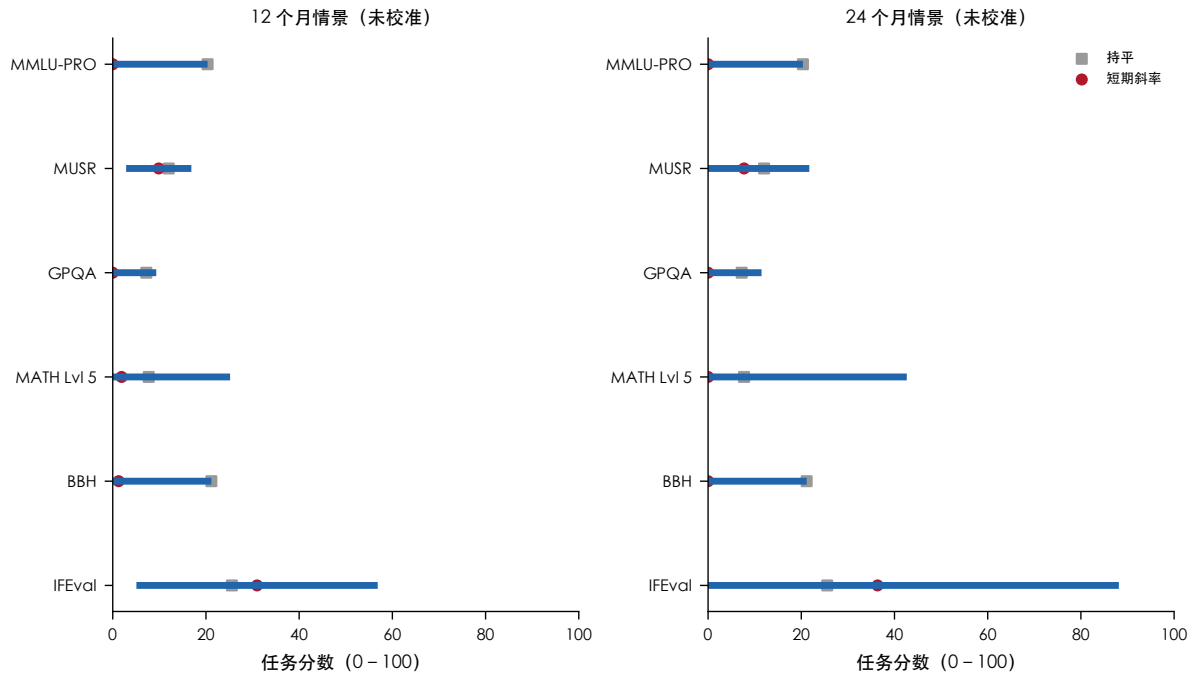


图 6.16　基于不足 12 个月历史的 12/24 个月前沿情景。横线为斜率敏感性包络，不是预测置信区间。

7 模型评价与后续验证

7.1 可复核性

本求解把 A、B、C 三组的数据入口分开，所有实证表由四个问题脚本生成，再由独立算术验证器读取结果与原始数据重算关键恒等式。15 项检查全部通过，包括重复 ID、留出 MAE、B1 公式值、全部 180 个预算成本以及 C8 协议分组计数。这个结果只能证明实现与记录之间的一致性，不能证明源文件的真实性；目前只有有官方原始直链的八个 RegMix 配方/Loss CSV 完成逐字节对照。

配比学习的同尺度留出有效，却在跨尺度原值预测中失败；标度律在 B1 内部精度极高，却在 B2 和跨族资料上出现偏移。两个失败直接限制了问题三能够声称的经验最优范围。问题四的短期留出也没有支持简单月度技术趋势。因此模型的优点在于明确暴露迁移限制，允许在数据不足时输出条件解，而不把来源混杂后的高拟合解释为普遍规律。

7.2 局限与针对性改进

第一，A1 质量指数缺少人工偏好或同配方训练实验校准。下一步应固定至少两组内容分布相近、质量处理不同的语料，在同一个训练族、验证集和预算上实施干预，估计质量收益与处理成本；否则不能将 A 指数换算为 B6 的 Q。第二，B1 的潜在公式化结构和族间 Loss 偏移需要原始检查点、训练日志与统一验证集重新测量。仅增加拟合表的样本行数不会解决共同来源问题。

第三，高预算优化受到 B1 支持范围边界阻断。若要对 10^{24} FLOPs 给出实际配置，需新增同一 Loss 口径的大模型、多 Token 检查点及质量干预实验，并检验不同上下文

成本代理与真实训练 FLOPs 的偏差。第四，能力前沿需要更长的同协议历史，按任务 hash、样本量、模型版本和发布日期冻结面板；C4 缺失字段应针对性搜集可核查原始报告，不能由 2.32% 的暂定匹配样本推断总体。

7.3 阶段结论

在当前附件可核查范围内，问题一给出可复算的质量冲突与同尺度配比模型，问题二给出 B1 的条件标度式和明确的族外失败，问题三给出预算守恒的条件配置及高预算不可识别边界，问题四给出评测协议、时间泄漏与长期预测不可校准的定量证据。论文仍是研究初稿，质量量尺和来源独立性完成进一步验证之前，不把宽范围优化与 12/24 个月情景作为可实施决策。

参考文献

参考文献

[1] Hoffmann J, Borgeaud S, Mensch A, 等. An empirical analysis of compute-optimal large language model training. Advances in Neural Information Processing Systems 35, 2022. https://proceedings.neurips.cc/paper_files/paper/2022/hash/c1e2faff6f588870935f114ebe04a3e5-Abstract.html（访问日期：2026 年 9 月 23 日）.

[2] Biderman S, Schoelkopf H, Anthony Q G, 等. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. Proceedings of Machine Learning Research 202: 2397–2430, 2023. https://proceedings.mlr.press/v202/biderman23a.html（访问日期：2026 年 9 月 23 日）.

[3] Liu Q, Zheng X, Muennighoff N, 等. RegMix: Data Mixture as Regression for Language Model Pre-training. International Conference on Learning Representations, 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/5f67d864aae6115374fed7beddd119e0-Abstract-Conference.html（访问日期：2026 年 9 月 23 日）.

[4] OpenDataLab. SlimPajama-Meta-rater dataset card. https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater/blob/main/README.md（访问日期：2026 年 9 月 23 日）.

附录 A 附录：复算路径与 AI 辅助记录

1.1 可运行入口

问题一至四的唯一计算入口分别为 `求解/问题一/问题一.py`、`求解/问题二/问题二.py`、`求解/问题三/问题三.py`、`求解/问题四/问题四.py`。依赖顺序是第一问先于第二、三问；第四问可独立读取 C 组。图由 `求解/公共/绘制证据图.py` 从已落盘的结构化结果生成，不在绘图时重新估计模型。独立检查入口为 `求解/公共/独立验证.py`；图形文件的行数、字段和渲染记录见同名 `stats.json` 与 `qa.json`。

1.2 人工复核的关键节点

在提交前，队伍应核实 PDF 中隐藏的浅色诱导段落与题面正文的区别，复核 A1 中评分器正向类别和 ModernBERT 等级顺序，确认 B1 的原始训练测量来源，实施 A/B 质量锚点实验，逐一检查 C8 哈希组和评测时间，并在自己的 TeX 环境中检查正式字体、图例、目录、引用和 45 页正文门槛。附件中的估算或半合成文件需保留标签，不能在结果表中悄然改称独立观测。

1.3 AI 使用说明

本初稿的思路整理、公式排布、数据审计、Python 脚本、可视化和 LaTeX 文本均由 Codex 辅助完成，借助本地建模核心与 scientific-skills 相关工作流。所有数值需由参赛队伍运行和独立理解；最终参赛披露应按照当届规则说明 AI 工具、具体环节、人工复核和最终贡献。本节是草案记录，不能替代队伍的正式声明。